

摘 要

实例图像目标导航 (IIN) 任务是具身视觉领域的核心任务之一, 它要求智能体在未知环境中, 定位目标图像中所包含的特定物体实例。该任务的核心挑战在于: 智能体需要在不同视角下识别物体, 定位, 同时还需要排除干扰。在既有方法中, 传统的鸟瞰图 (BEV) 方法存在三维几何信息缺失、实例纹理特征丢失等问题, 而基于 3D 高斯 (3DGS) 的导航方法语义存在着标签与几何纹理参数脱节的问题。

针对上述问题, 本文提出了一种基于语义增强 3D 高斯泼溅的模块化视觉导航算法框架 **GSGuide**。该框架设计并实现了三阶段模块化导航策略, 包括**环境探索与语义地图构建**, **目标定位与相机位姿对齐**, 以及**智能体规划路径与导航**。在目标定位与相机位姿估计阶段, 提出了图像匹配初始粗定位以及图像扭曲 (Warping) 渲染精修的高效定位策略。同时, 该框架还通过为每个高斯引入了可训练语义向量, 构建了同时编码了几何、纹理与细粒度语义信息的统一地图表示方案。所提框架使得智能体能够精准地识别和定位目标物体, 并能导航至目标所在位置。

基于 Habitat 仿真平台和具有挑战性的 HM3D 数据集, 论文对所提方法完成了仿真实验。实验结果表明, **GSGuide** 的导航成功率从原始 GaussNav 的 0.725 提升至 0.778, SPL 指标达到了 0.585, 同时在所有语义分割损失指标上均取得了显著改善, 验证了所提方法在实例级目标识别与定位方面的有效性, 不仅在理论上丰富了具身视觉导航的地图表示方法与目标定位技术, 也在实践中为服务机器人的物品查找、室内巡检等实际应用提供了可行的技术方案。

关键词: 3D 高斯泼溅 语义增强 实例图级图像目标导航 图像扭曲

ABSTRACT

Instance ImageGoal Navigation (IIN) is a core embodied vision task, requiring an agent to locate a specific object instance from a goal image in an unexplored environment. Its core challenges lie in cross-view object recognition, precise localization, and robust distractor rejection. Traditional Bird’s-Eye View (BEV) methods lack 3D geometry and instance textures, while 3D Gaussian Splatting (3DGS)-based navigation suffers from misalignment between semantic labels and geometric-texture parameters.

To tackle these issues, we propose **GSGuide**, a modular visual navigation framework based on semantically enhanced 3D Gaussian Splatting. It features a three-stage pipeline: **environment exploration and semantic map construction, target localization and camera pose alignment, and path planning and navigation**. In the localization stage, we design an efficient two-step strategy: coarse localization via image matching, followed by refinement via image warping rendering. By adding trainable semantic vectors to each Gaussian, we build a unified map encoding geometry, texture, and fine-grained semantics, enabling accurate target recognition, localization, and navigation.

Extensive experiments on the Habitat simulator with the HM3D dataset show that GSGuide achieves a 0.778 success rate (up from GaussNav’s 0.725) and an SPL of 0.585. It also significantly reduces all semantic segmentation losses, validating its effectiveness in instance-level recognition and localization. This work advances embodied navigation map representations and localization techniques, and supports real-world applications including service robot object retrieval and indoor inspection.

Keywords: 3D Gaussian Splating Semantic Enhancement Instance ImageGoal
Navigation Image Warping

目 录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 研究现状	2
1.2.1 可微分渲染领域的相关研究	2
1.2.2 相机定位领域相关研究	3
1.2.3 视觉导航领域相关研究	5
1.3 本文主要工作与贡献	6
1.4 论文结构安排	6
第二章 理论基础	7
2.1 3DGS 渲染方法	7
2.1.1 原始 3D 高斯泼溅技术	7
2.1.2 特征与语义增强的 3DGS 扩展	8
2.2 图形扭曲与对齐技术	9
2.2.1 传统光度误差位姿优化	9
2.2.2 Warping Loss 高效位姿修正	9
2.2.3 使用鲁棒特征匹配的初始位姿估计	10
2.3 虚拟环境与 IIN 任务	10
2.3.1 Habitat 仿真平台与 HM3D 数据集	10
2.3.2 实例级图像目标导航任务	11
2.3.3 基于地图的 IIN 方法演进	11
第三章 基于语义增强 3DGS 的视觉导航算法 GSGuide	13
3.1 任务总体概览	13
3.2 环境探索与语义高斯构建	15
3.2.1 简化后的 3D 高斯表示	15
3.2.2 语义高斯构建	16
3.3 目标定位与相机位姿估计	21
3.3.1 分类器	21
3.3.2 匹配与定位	22

3.4	智能体导航	23
第四章	实验与结果分析	25
4.1	实验准备	25
4.1.1	实验环境	25
4.1.2	实验用数据集	25
4.1.3	智能体配置	25
4.1.4	智能体的动作空间	26
4.1.5	评估指标	26
4.2	与现有方案的对比	27
4.2.1	端到端 baseline 方法	27
4.2.2	先进方法对比	28
4.2.3	SOTA 对比	28
4.3	消融实验	29
4.3.1	消融实验设置与结果	29
4.3.2	语义渲染监督有效性	29
4.3.3	位姿精修 Warping Loss 有效性	30
4.3.4	消融实验结论	31
4.4	误差分析	32
4.4.1	语义错误识别	32
4.4.2	场景建立质量不完善	33
第五章	总结与展望	35
5.1	研究总结	35
5.2	研究展望	36
致谢		39
参考文献		41

第一章 绪论

1.1 研究背景与意义

视觉定位作为具身智能与计算机视觉领域的核心任务，要求智能体能够通过视觉感知的方法估计相机在预先构建的环境地图中的位姿。得益于近年来大规模且逼真的三维场景数据集的出现以及用于测试具身导航仿真器的开发，具身视觉导航在近年来取得了显著的发展。

在具身视觉导航中，一个关键问题是描述目标物体的方法。向智能体分配任务的常见方式是下达自然语言指令，类似于“导航到目标 A”、“到达目标 B”等。但当场景中相同类型的物体包含多个不同的实例时，这种分配任务的方式会产生较大的歧义，智能体常常会出现误识别或者无法识别的问题。为解决这一歧义，Krantz 等人提出了实例级目标导航 IIN^[1]。

如图1.1所示，在 IIN 任务中，智能体接收到一张包含了特定目标物体的图像，目标是在限定时间步内找到这个特定的物体实例的位置并到达该物体附近。这个任务要求智能体首先能够识别目标物体的具体类别，其次能够从多个不同角度来观察具有相同类别的目标物体，以确定所观察的物体实例是否与目标物体相吻合。

为解决上述的问题，现有方法所采取的策略主要是通过引入鸟瞰图（2DBEV）来处理该任务。这种显式的地图表示方式能够大幅降低内存开销，但对于三维场景中存在的大量的物体细节，其表示能力依然受到较大局限性，所保存的语义信息和 2D 的几何信息对于智能体多视角观察候选目标物体这一需求支撑力有限。此外，BEV 地图也难以保存目标物体的实例级信息，而这一信息对于区分同类多个物体或者需要细粒度物体交互的任务至关重要。

为克服 BEV 地图局限性，Lei^[2]等人又针对 IIN 任务提出一种全新的基于 3D 高斯泼溅的导航框架 **GaussNav**^[2]。**GaussNav** 通过使用语义高斯地图的表示方法，将几何、语义与实例级特征的表示融为一体，得以成功应用在**边界探索、语义高斯构建、高斯导航**三阶段任务流程。同时，Gennady Sidorov 等人又针对相机位姿定位提出了 **GSplatLoc**^[3]——一种新颖的视觉定位框架。该框架将基于结构的粗位姿估计与基于高斯渲染而优化的图像扭曲位姿优化策略整合到一个统一的端到端




图 1.1 实例 IIN 任务

流程中，完成相机位姿估计。这些技术在视觉导航中的目标物体描述与相机定位等具有挑战性的任务中，表现出显著的性能。

本文也基于 **GaussNav**^[2] 框架，融合了 **GSplatLoc**^[3] 中针对高斯渲染优化后的位姿精修算法，提出了一个系统整合了几何、语义与实例级特征的地图表示的导航框架——**GSGuide**。

1.2 研究现状

本文首先简要讨论可微分渲染领域的相关研究，然后对相机定位进行全面的概述，最后在对实例级图像目标导航进行讨论。

1.2.1 可微分渲染领域的相关研究

为实现逼真的三维场景构建，早期的方法主要围绕神经辐射场 (NeRF)^[4] 提出。NeRF^[4] 利用单个多层感知器 (MLP) 来表示场景，通过沿像素光线行进并查询 MLP

获取不透明度和颜色值来执行体绘制。MLP 表示可以通过多视角信息优化一最小化渲染损失，从而实现高质量的新视角合成。但 NeRF^[4]的主要局限性在于训练速度较慢，且对存储需求较高，在 IIN 这种对于实时性要求较高的任务中，其适用性受限。

与 NeRF^[4]不同的是，三维高斯溅射 (3DGS)^[5]采用可微分光栅化技术，对需要光栅化的基元进行迭代处理，这与传统图形学中的光栅化方式类似。利用三维场景天然的稀疏性，3DGS^[5]能够以高保真的表示方式捕捉三维场景，同时能够显著提升渲染效率，降低存储开销。

关于三维高斯溅射技术发展的全面综述^[6]强调了该方法的通用性及其在各个领域的应用。凭借这些优势，越来越多的研究者开始探索各种创新方向，例如可变形或动态高斯^[7-8]、网格提取与物理模拟^[9-10]，以及在同时定位与地图构建 (SLAM) 中的应用^[11-12]。

近些年来，3DGS 技术在语义增强与轻量化方向取得了重要进展，为导航任务提供了更加强大的场景表示能力。

SeG-Gaussian^[13] 提出语义引导的 3D 高斯优化框架，利用语义掩码识别重建薄弱区域，通过空间正则化抑制高斯重叠，显著提升了稀疏观测下的语义重建质量。但该方法的语义信息仅作为优化引导信号，并未嵌入高斯本身的参数表示中，无法直接支持后续的语义感知导航决策。

Gsplatloc^[3] 在 3DGS 中引入原生稠密特征场，无需预训练蒸馏即可实现特征渲染，在保持实时性的同时显著提升了跨视角匹配鲁棒性。然而其特征向量是通用视觉特征，缺乏明确的语义含义，无法直接用于目标类别过滤和实例区分，在存在多个相似物体的 IIN 任务中容易产生误匹配。

SAGE-3D^[14] 则将 3DGS 升级为可执行、语义对齐、物理对齐的环境基础，发布了包含 1000 个室内场景的 InteriorGS^[14] 数据集。但该方法的语义对齐是在高斯构建完成后进行的独立后处理步骤，无法实现语义与几何参数的端到端联合优化，仍然存在语义错位问题。

鉴于高斯表示的显式特性提供了丰富的环境数据，3DGS^[5]能够增强基于地图的视觉导航中的决策能力，可以有效地用于指导自主智能体的导航。

1.2.2 相机定位领域相关研究

视觉定位是机器人导航的核心技术，旨在估计相机相对于预构建地图的位姿。

早期的视觉重定位方法主要依赖图像检索技术，即通过查询图像与已知位姿的图像数据库进行比对来推断近似位置。尽管这类方法计算效率高，但可扩展性较差，且对于动态环境中的定位精度会显著下降。

结构化的特征匹配方法通过利用运动恢复结构（SFM）生成的三维点云来提升定位性能。这类方法在查询图像提取的特征与三维地图之间建立显式的 2D-3D 对应关系，通常结合随机抽样一致性（RANSAC）算法，使用透视 n 点（PnP）求解器来计算相机位移^[15]。虽然这类方法能够实现较高的定位精度，但在处理大规模环境时，会带来巨大的内存开销。

位姿回归方法采用深度神经网络直接从输入图像估计相机位姿，大幅度降低了对大规模三维地图的依赖。这类方法将环境结构整合到网络架构中，能够实现端到端的训练。然而，受限于泛化能力，其性能通常不如基于结构的方法。绝对位姿回归方法（APR）技术在计算效率和精度之间取得了一定的平衡，而场景坐标回归（SCR）通过学习紧凑的场景表示进一步提升了性能。但场景坐标回归方法需要进行大量的优化才能达到最优精度，这限制了其在实时场景中的应用^[16]。

同样，神经辐射场^[4]和 3D 高斯泼溅技术^[5]的出现，实现了高保真的新视角合成，可以在训练阶段实现数据增强，提升特征匹配能力，从而推动了视觉定位技术的发展。基于 NeRF^[4]的方法虽然有效，但往往存在推理速度慢、训练时间长以及存储开销较大的问题，在 IIN^[1]这种对于实时性要求较高的任务中，其适用性受限。

随着 3DGS 技术的发展，基于 3DGS 的定位流程开始被广泛应用于 IIN 任务中。

GSCPR^[17] GS-CPR [15] 提出基于 3D 高斯泼溅的高效相机位姿精修方法，利用 3DGS 渲染高质量参考图像和深度图，结合通用 3D 基础模型 MAST3R 建立 2D-2D 对应关系，无需训练专用特征提取器即可实现高精度位姿优化。但该方法为纯几何的定位框架，完全不利用语义信息，无法区分同一类别的不同实例，这对于需要精确识别目标实例的 IIN 任务来说是致命的缺陷；此外，它依赖外部的全局位姿估计器提供初始值，不具备实例级的粗定位能力，且难以满足实时导航的需求。

HGSLoc^[18]提出分层 3D 高斯定位框架，结合全局特征检索与局部渲染精修，有效解决了大尺度场景下的定位漂移问题。然而其粗定位阶段采用的全局特征检索方法，对于外观相似的不同实例区分能力不足，在 IIN 任务中容易将相似物体

误判为目标。

这些方法虽然在定位精度上有所提升，但均未充分考虑 IIN 任务中“实例级区分”的特殊需求。本文正是针对上述问题，基于 GSplatLoc^[3]核心框架设计了“语义过滤 + 细粒度特征匹配 + 渲染精修”的三阶段定位策略，在统一的 3D 高斯泼溅流程中结合了基于结构的关键点匹配与基于渲染的位姿精修，利用快速可微渲染和光度扭曲损失最小化提升了定位精度。

1.2.3 视觉导航领域相关研究

实例级图像目标导航任务 (IIN)^[1]自 2022 年提出以来，经历了从基于 BEV 地图到模块化方法到基于 3DGS 的新一代方法演进。2025 年，GaussNav^[2]提出了一种基于 3DGS 的模块化视觉导航框架，首次将 3DGS^[5]引入了 IIN 任务，取得了突破性的进展，而在此之后又有更多的研究者提出了相关工作。

UnitedVLN^[19]提出了基于通用 3D 高斯泼溅的连续视觉语言导航框架，通过统一的高斯地图表示实现了跨场景的泛化导航，在多个 VLN 基准上取得了 SOTA 性能。该方法首次证明了 3DGS 不仅适用于单场景的实例导航，还能支持跨场景的连续长程导航任务，显著拓展了 3DGS 在具身智能领域的应用边界。但该方法主要面向自然语言指令导航设计，其语义表示仅包含粗粒度的类别信息，缺乏对实例级细粒度特征的编码能力，无法有效区分同一类别的不同物体实例，难以直接应用于需要精确识别特定实例的 IIN 任务；此外，其位姿估计依赖于外部 SLAM 系统，没有针对实例级目标定位进行专门优化，在存在多个相似物体的场景中容易出现定位错误。

上述工作虽然在不同方面推动了 3DGS 导航技术的发展，但仍存在两个核心局限性，也是本文工作的主要切入点：

- **语义表示不充分：**大多数方法（如 GaussNav^[2]、UnitedVLN^[19]）仍采用静态语义标签或粗粒度语义表示，无法实现语义与几何、纹理参数的端到端联合优化，导致语义错位和实例区分能力不足；
- **实例定位精度不足：**现有定位方法对于相似实例的区分能力有限，且缺乏针对 IIN 任务的专用位姿精修机制，在复杂场景中容易出现目标误匹配和定位偏差。

基于此，引出本文主要工作与贡献：**基于语义增强的 3D 高斯泼溅的模块化视**

觉导航框架 **GSGuide**。

1.3 本文主要工作与贡献

本文对既有的 GaussNav^[2]与 GsplatLoc^[3]两个核心框架进行了研究并进行了优化工作，提出了提出了一种基于语义增强 3D 高斯泼溅的模块化视觉导航框架 **GSGuide**。主要贡献包括：

- **高斯语义信息融合与监督优化：**引入 Yolo26^[20]语义分割模型输出的物体实例语义，为高斯新增可微语义标签。复用原版 3DGS 中 RGB 颜色渲染逻辑，实现渲染通道数自适应适配 RGB 和语义渲染两种模式。实现了语义高斯的高效构建。
- **对齐目标图像的具体位姿：**利用 GSplatLoc^[3]提供的基于高斯渲染优化后的图像扭曲技术，通过将目标图像与高斯渲染结果进行对齐，实现了多视角生成与目标位姿精确估计。
- **目标导航：**利用优化后的语义高斯表示，结合基于 LightGlue+Disk^[21-22]的特征提取与匹配方案的目标位姿估计，实现了目标导航。

1.4 论文结构安排

本文结构安排如下：第一章系统介绍本文的相关背景与意义；第二章综述了三维重建、位姿对齐、视觉导航的基础理论知识；第三章详细介绍本文工作的具体方法与实现细节；第四章展示了在仿真环境中的实验设置、结果与分析；第五章总结了全文工作，并对未来研究方向进行展望。

第二章 理论基础

本章系统阐述本文工作所依赖的核心理论与技术基础，包括 3D 高斯泼溅 (3D Gaussian Splatting, 3DGS)^[5] 的渲染原理、基于图形扭曲的位姿对齐技术，以及具身智能领域的虚拟仿真环境与实例图像目标导航 (Instance ImageGoal Navigation, IIN)^[1] 任务定义。同时，结合现有研究的局限性，给出本文提出的语义增强 3DGS 表示、高精度特征匹配初始位姿估计与高效位姿精修方法的理论依据。

2.1 3DGS 渲染方法

3D 高斯泼溅 (3DGS)^[5] 是 2023 年提出的一种新型的神经渲染技术，凭借其实时的渲染速度、高保真的成像质量和高效的训练特性，迅速成为三维场景表示与重建领域的研究热点，为视觉定位、具身导航等下游任务提供了全新的场景表示方式。

2.1.1 原始 3D 高斯泼溅技术

3D 高斯的核心思想是使用大量各向异形的 3D 高斯基元离散化表示连续的三维场景。其中，每个高斯通过一组可优化参数完整编码其几何外观与属性。其原始参数集定义为：

$$\Psi_i = \{\mathbf{y}_i, \mathbf{q}_i, \mathbf{s}_i, \alpha_i, \mathbf{c}_i\} \quad (2-1)$$

其中， i 代表第 i 个高斯， $\mathbf{y}_i \in \mathbb{R}^3$ 为高斯中心的三维世界坐标， $\mathbf{q}_i \in \mathbb{R}^4$ 为表示旋转的单位四元数， $\mathbf{s}_i \in \mathbb{R}^3$ 为三个轴向上的缩放因子， $\alpha_i \in [0, 1]$ 为不透明度， $\mathbf{c}_i \in \mathbb{R}^3$ 为通过球谐函数 (Spherical Harmonics, SH) 编码视角的相关颜色。

3DGS 的渲染过程基于可微分光栅化实现，分为三个核心步骤：

1. 视锥裁剪与深度排序：筛选出位于相机视锥内的高斯，并按照深度从近到远排序；
2. 2D 投影：将 3D 高斯的均值和协方差矩阵投影到图像平面，得到 2D 椭圆的中心和协方差矩阵；
3. Alpha 混合：对每个像素，按照深度顺序累加所有覆盖该像素的高斯的颜色贡献，最终得到渲染图像：

$$C(p) = \sum_{i \in N(p)} \mathbf{c}_i \alpha_i T_i \quad (2-2)$$

其中 $N(p)$ 为覆盖像素 p 的高斯集合, $T_i = \exp\left(-\sum_{j=1}^{i-1} \alpha_j\right)$ 为累积透射率。

与神经辐射场 (NeRF)^[4]相比, 3DGS^[5]避免了耗时的光线步进操作, 同时训练速度提升一个数量级以上, 为需要快速场景重建和在线渲染的几秒级实时性应用提供了可行方案。

2.1.2 特征与语义增强的 3DGS 扩展

原始的 3DGS 仅能编码场景的几何与外观信息, 无法直接支持语义理解、特征匹配等高级视觉任务。为此, 研究者们提出了多种增强的 3DGS 表示:

- **特征 3DGS (Feature-3DGS):** 在原始的 3DGS 参数基础上, 为每个高斯新增一个 V 维度的特征向量, 通过蒸馏预训练的 2D 特征提取器的输出结果进行联合优化。复用原有 RGB 渲染框架, 仅在渲染时自适应通道数, 即可同时输出 RGB 图像和特征图, 实现了几何、外观与视觉特征的统一表示。GSplatLoc^[3]正式基于这一框架, 将轻量级 XFeat^[23]特征蒸馏到 3DGS^[5]中, 通过 2D-3D 特征匹配实现粗略位姿估计。
- **语义高斯 (Semantic Gaussian):** GaussNav^[2]方法针对导航任务的需求, 对原始 3DGS^[5]进行了轻量化的改造, 将高斯约束为各项同性 (仅保留单个缩放因子), 赋给每个高斯添加离散于一类别标签。将 Mask R-CNN^[24]的语义分割结果在初始化点云阶段赋予每个高斯的语义标签, 为实例级目标识别提供了基础。

而现有增强型高斯表示存在明显的局限性: GSplatLoc^[3]的特征向量是通用视觉特征, 缺乏明确的语义; GaussNav^[2]的语义标签是离散类别, 而且仅在初始化点云阶段为离散语义标签赋值, 但并不参加后续的监督与优化过程。为解决这一问题, 本文提出的 GSGuide 框架在原始 3DGS^[5]参数基础上, 遵从 GaussNav^[2]论文所用到的 6 个 COCO ID^[25]类别和一个背景类别, 为每一个高斯新增一个 7 维度的可训练的语义向量 $\mathbf{l}_i$, 并使用在 COCO-Stuff^[26]数据集上预训练的 Yolo26^[20]语义分割模型所输出的语义信息与实例识别结果联合进行训练。COCO ID 编号与语义类别以及对应向量索引关系如表 2.1 所示:

可微的语义向量能够同时编码类别于一和实例特征, 使每个高斯成为几何、外观与细粒度语义的统一载体, 为后续的语义感知位姿估计和实例级目标匹配提供了更强大的表示能力。

表 2.1 COCO ID 编号与语义类别以及对应 7 维向量索引关系表

语义类别	背景	椅子	沙发	电视机	盆栽植物	马桶	床
对应的 COCO ID 类别	-	56	57	58	59	61	62
对应语义向量索引	0	1	2	3	4	5	6

2.2 图形扭曲与对齐技术

视觉定位与导航的核心是精确估计相机在三维场景中的位姿。基于 3D 高斯渲染的位姿精修技术通过最小化渲染图像与真实观测图像的差异，能够显著提升初始位姿的精度。其中，图形扭曲（Warping）技术是实现高效位姿优化的关键。

2.2.1 传统光度误差位姿优化

早期基于神经渲染的位姿精修方法（例如 iNeRF^[27]）采用迭代渲染的策略：在每次优化步骤中，根据当前估计的位姿渲染图像，计算其与查询图像的光度误差（如 L1 损失、SSIM 损失），然后通过反向传播更新位姿参数。这种方法虽然原理简单，但每次迭代都需要完整的渲染过程，因而计算成本较高，效率较低，难以满足 IIN 任务的实时性要求。

2.2.2 Warping Loss 高效位姿修正

为解决传统方法的效率问题，PNeRF^[28]首次提出了**单次渲染 + 图形扭曲 (Warping) 的位姿**的位姿优化框架。其核心思想是：仅需要根据初始粗位姿渲染一次参考图像和深度图，然后通过扭曲函数将参考图像的像素投影到查询图像平面，计算像素级差异作为损失函数（Warping Loss），避免了重复渲染。

GSplatLoc^[3]将原本设计为 NeRF^[4]服务的 Warping Loss 与 3DGS 框架适配，与其快速渲染能力相结合，进一步提升了位姿精修效率。

具体而言，对于一张查询图像 q 和一个粗略位姿 $(\mathbf{R}, \mathbf{t})$ ，参考图像像素 p_i 的深度为 $z_r(p_i)$ ，那么扭曲函数 $W(\cdot)$ 定义为：

$$W(p_i, \mathbf{R}, \mathbf{t}, \mathbf{R}', \mathbf{t}') = \Pi(\mathbf{R}(\mathbf{R}'^{-1}\Pi^{-1}(p_i, z_r(p_i)) - \mathbf{R}'^{-1}\mathbf{t}') + \mathbf{t}) \quad (2-3)$$

其中 $\Pi(\cdot)$ 为相机投影函数， $\Pi^{-1}(\cdot)$ 为反投影函数， $\mathbf{R}$ 为相机旋转矩阵， $\mathbf{t}$ 为相机平移向量。

基于扭曲函数的 RGB 损失定义为：

$$\mathcal{L}_{rgb-warp} = \sum_{p_i} \|Y(q, W(p_i, \mathbf{R}, \mathbf{t}, \mathbf{R}', \mathbf{t}')) - Y(q_r, p_i)\|_2 \quad (2-4)$$

其中 $Y(q, p)$ 为查询图像 q 在像素 p 处的 RGB 值, $Y(q_r, p_i)$ 为参考图像 q_r 在像素 p 处的 RGB 值。

实验表明, 该方法在 RTX 3060 GPU 上仅需约 1.25 秒即可完成 250 次迭代的位姿优化, 显著快于 NeRF-based 方法。

2.2.3 使用鲁棒特征匹配的初始位姿估计

Warping Loss 的优化效果高度依赖估计的初始粗位姿的质量。如果初始位姿偏差过大, 后续的位姿精修容易陷入类似随机的对齐步骤。GSplatLoc^[3]采用 XFeat^[23]特征提取器进行 2D-3D 匹配, 虽然速度快, 但依赖于预先训练好的带有 64 维蒸馏特征的高斯, 在场景较大的空间中, 或者相似物品较多的情况中, 匹配精度受限, 存储开销较大, 效率也会下降。

为提升初始位姿的鲁棒性, 本文所提的 GSGuide 框架采用 DISK 局部特征提取器^[22] + LightGlue 特征匹配器^[21]的组合方案。DISK^[22]能够提取高重复率、高辨识度的关键点和描述子, 而 LightGlue^[21]作为一种基于 Transformer 的轻量级特征匹配器, 能够在保持高精度的同时实现实时匹配。GaussNav^[2]方法已验证了该组合在实例级目标匹配任务中的有效性。

本文从所有参与 3DGS 训练的图像中提取 DISK^[22]特征, 与导航目标图像通过 LightGlue^[21]进行匹配, 将最为相似的训练图像作为估计初始位姿, 为后续基于 Warping Loss 的精修算法提供了可靠的初始值, 也大幅度降低了位姿估计时间和存储开销。

2.3 虚拟环境与 IIN 任务

在具身视觉导航领域, 虚拟环境为导航算法的开发与评估提供了标准化、可重复的测试平台。

2.3.1 Habitat 仿真平台与 HM3D 数据集

Habitat^[29]是由 Meta AI 开发的高性能具身智能仿真平台, 专为大规模室内导航任务设计。它支持物理真实的渲染、刚体物理模拟和多智能体并行训练, 能够在单 GPU 上实现每秒数千帧的仿真速度, 大幅提升了算法的开发效率。

本文采用的 Habitat-Matterport 3D (HM3D)^[30]数据集是目前最大规模的真实室内场景 3D 重建数据集, 包含 1000 多个真实住宅和商业建筑的高质量 3D 扫描模型, 覆盖 400 多个房间类型和 200 多个物体类别。每个场景都提供了精确的几何重建、语义标注和相机参数, 被广泛应用于具身导航、三维视觉等领域的研究。

2.3.2 实例级图像目标导航任务

实例级图像目标导航 IIN^[1] 任务的设定如下：在一个未知环境中，仅向智能体提供一张目标物体的图像，智能体需要通过自主探索环境，找到并导航到该目标物体的具体实例。与传统的物体目标导航（ObjectNav）不同，IIN^[1] 要求智能体区分同一类别的不同实例（如两把外观相似的椅子），并且目标图像的拍摄视角、相机参数与智能体的观测可能存在显著差异。

IIN 任务的核心挑战包括：

1. **跨视角目标识别**：智能体需要从不同视角识别目标物体，克服视角变化带来的外观差异；
2. **相似实例区分**：存在多个同类物体的环境中，准确区分目标实例与干扰实例；
3. **探索与利用的平衡**：智能体需要在探索位置环境和利用已有信息定位目标之间取得平衡。

2.3.3 基于地图的 IIN 方法演进

现有 IIN 方法主要基于鸟瞰图（Bird's-Eye View, BEV）^[31-33] 地图表示，通过投影语义信息到 2D 平面实现环境建模。然而，BEV 地图丢失了场景的 3D 几何信息和物体的纹理细节，无法进行细粒度的实例级匹配，导致智能体需要频繁靠近物体进行验证，降低了导航效率。

GaussNav^[2] 方法首次将 3DGS 引入 IIN^[1] 任务，提出了语义高斯地图表示，通过保留物体的纹理细节，实现了直接从目标图像到场景实例的匹配，无需额外的验证步骤，将 HM3D 数据集上的 SPL 指标从 0.347 提升至 0.578。

本文所提框架 GSGuide 在 GaussNav^[2] 的基础上，通过引入可训练语义向量增强高斯的细粒度表示能力，结合 DISK+LightGlue^[21-22] 的高精度位姿估计和 GSplat-Loc^[3] 中提到的 Warping Loss 的高效位姿精修，进一步提升语义高斯地图的重建精度和实例匹配的准确性，从而实现更高效、更鲁棒的 IIN 导航。

第三章 基于语义增强 3DGS 的视觉导航算法 GSGuide

本章提出了基于语义增强 3DGS 的视觉导航算法 **GSGuide**，给出具体实现方法，包括任务总体概览，环境探索与语义高斯地图构建过程，高斯导航实现逻辑以及路径规划实现方法。

3.1 任务总体概览

在实例级图像目标任务（IIN）中，当新回合 e 开始时，智能体将获得一张目标图像 I_g ，该图像展示了指定的物体实例 O_g 。智能体的目标是在环境中导航至该指定实例 O_g 所在的位置。在每个时间步 t ，智能体获取观测信息包括 RGB 图像 I_t 、深度图像 D_t 以及传感器位姿数据 P_t 。智能体需要利用这些观测信息来决策并执行动作 a_t 。当智能体执行停止动作时，仅当智能体处于目标物体指定的空间范围内，该回合才判定为成功。

如图3.1所示，为完成上述 IIN 任务，本文提出了一种极简的面向视觉导航的模块化框架，主要包含三个阶段：环境探索与语义地图构建、目标定位与相机位姿对齐、导航。




图 3.1 面向视觉导航的模块化框架整体流程

在一个全新的环境中，智能体需要先通过探索环境，收集环境观测数据，包括 RGB 图像、语义、深度等，利用这些信息来构建一个语义高斯地图作为后续的导航基础；随后，利用已有的构建好的语义高斯地图，与目标图像中的实例物体进行相似度匹配，确定目标物体；利用包含目标物体的初始训练位姿信息作为初始位姿，通过图像对齐技术逐步从初始位姿对齐到目标图像拍摄位姿，作为最终

导航点；获得最终导航点后，整个 IIN 任务简化为点导航任务，进而进入智能体动作规划与执行阶段。

下面对这三个主要阶段的核心进行详细描述，GSGuide 算法的整体流程如算法3.1所示。

算法 3.1 GSGuide: 基于语义增强 3DGS 的视觉导航算法

Input: 目标图像 I_g , 初始位姿 P_0

Output: 导航动作序列 $\{a_1, a_2, \dots, a_T\}$

/* 第一阶段：环境探索与语义高斯地图构建 */

```

1 for 每个探索时间步  $t$  do
2   获取观测:  $I_t, D_t, P_t$ ; 语义分割  $I_t \rightarrow C_t$ ;
3   高斯致密化: 渲染  $\hat{D}_t, \hat{S}_t$ , 计算  $M(p)$ , 初始化新高斯;
4   for 每个优化迭代 do
5     可微渲染  $\hat{I}_t, \hat{D}_t, \hat{P}_{seg}$ ;
6      $\mathcal{L}_{total} = \lambda_{rgb}\mathcal{L}_{rgb} + \lambda_{depth}\mathcal{L}_{depth} + \lambda_{seg}\mathcal{L}_{seg}$ ;
7     梯度下降更新  $\Psi_i = \{\mathbf{c}_i, \boldsymbol{\mu}_i, r_i, o_i, \mathbf{l}_i\}$ 
8   end
9 end
```

/* 第二阶段：目标定位与相机位姿估计 */

```

10 分类  $I_g \rightarrow \hat{\mathbf{l}}_g$ ; 查询地图  $\rightarrow$  候选集  $\mathcal{O}$ ;
11 for 每个  $o_i \in \mathcal{O}$  do
12   提取  $\mathcal{P}_i$ , 生成视角图像集  $\mathcal{S}_i$ 
13 end
14 匹配  $I_g$  与  $\bigcup_i \mathcal{S}_i \rightarrow \hat{P}_g$ ;
15 图像对齐精修  $\hat{P}_g \rightarrow P^*$ ;
```

/* 第三阶段：智能体导航 */

```

16 高斯  $\rightarrow$  3D 体素  $\rightarrow$  2D BEV  $M_{2D}$ ;
17 FMM 计算距离场  $D_{fmm}$ ;
18 while 未到达目标 do
19   选  $D_{fmm}$  局部极小点为航点  $w$ ;
20   根据角度与距离计算并执行动作  $a_t$ 
21 end
```

3.2 环境探索与语义高斯构建

3.2.1 简化后的 3D 高斯表示

与原始的 3DGS^[5]不同, 本文所使用的高斯是经过简化的。遵从原始 GaussNav 论文, 本文保留了原始 3D 高斯的基元表示核心与可微分渲染能力, 将高斯核心参数表示为:

$$\Psi_i = \{\mathbf{c}_i, \boldsymbol{\mu}_i, r_i, o_i, \mathbf{l}_i\} \quad (3-1)$$

其中, i 代表第 i 个语义高斯; $\mathbf{c}_i \in \mathbb{R}^3$ 代表每个高斯的 RGB 颜色向量; $\boldsymbol{\mu}_i \in \mathbb{R}^3$ 表示每个高斯中心坐标; $r_i \in \mathbb{R}$ 表示每个高斯的半径; $o_i \in [0, 1]$ 表示每个高斯的透明度; $\mathbf{l}_i \in \Delta^6$ 表示每个高斯所代表的 7 个语义类别的概率分布, 满足非负性与归一化约束。

原始 3DGS 为了实现照片级别的真实感渲染, 使用 3 阶球谐函数 (Spherical-Harmonics, SH) 编码每个高斯的颜色。每个高斯的 RGB 通道各需要 9 个颜色系数总共 27 个颜色系数。这样可以实现同一个物体的不同观察视角对应的不同颜色编码, 以达到例如金属物体不同角度的反光颜色不一样的效果。

而 IIN 任务中, 导航的核心需求是识别物体、理解几何场景, 对实时性要求较高, 而不是照片级别的真实感渲染。因此本文抛弃了基于球谐函数的颜色编码方式, 而是将每个高斯简化为只使用 3 维 RGB 颜色向量的颜色编码方式。具体原因如下:

1. 物体的整体颜色和纹理特征已经足够支撑实例级匹配需求;
2. Habitat-Sim 模拟器提供的虚拟场景中本身并没有基于球谐函数的不同角度的颜色表示方式。

这样以来, 渲染质量虽略有下降, 但换来的是参数量减少 90%, 渲染速度大幅提升, 更加贴合 IIN 任务的实时性需求。

同时, 本文还将高斯约束为各向同性 (仅保留单个缩放因子)。原始 3DGS 使用各向异性来拟合三维场景结构。对于每个高斯而言, 各个方向因缩放因子不同, 不同的高斯看起来更像是大小、朝向均不同的椭球体。这需要每个高斯存储 3 个缩放因子, 分别对应 x, y, z 三个轴的长度以及 1 个四元旋转参数来表示椭球体的方向。这种方法对于拟合平面、柱体等平面或者细长结构的拟合能力很强, 几何重建度较高。

而本文则进一步将所有高斯约束为各向同性，退化为一个完美球体。这样以来，三个轴的缩放因子完全相同，只需要一个标量半径 r 即可表示；球形的各向同性使得高斯不再旋转参数。这原因如下：

1. 智能体在探索与导航时只需知道障碍物与物体的大致位置，不需要毫米级别的精确度；
2. 球形高斯已足够表示场景的整体结构与物体的实例形状；

这种方法进一步降低了参数数量，从原始的 3 个缩放因子与一个旋转四元数变为一个标量半径 r ，几何参数减少 86%，在进一步降低内存占用的同时显著的提升渲染效率，贴合 IIN 任务的实时性要求。

3.2.2 语义高斯构建

原始的 3DGS 的 RGB 渲染过程如下：给定一组 3D 高斯和相机位姿，首先将所有高斯按照深度从近到远进行排序；随后将每个 3D 高斯投影到图像平面形成 2D 椭圆；最后通过 alpha 混合操作按照深度顺序累加每个像素的颜色贡献，得到最终的渲染图像。像素 $p = (u, v)$ 的渲染颜色可以表示为：

$$\hat{I}(p) = \sum_{i=1}^n c_i f_i(p) \prod_{j=1}^{i-1} (1 - f_j(p)) \quad (3-2)$$

其中，权重函数 $f_i(p)$ 定义为：

$$f_i(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \boldsymbol{\mu}\|^2}{2r^2}\right) \quad (3-3)$$

其中，通过 3D 高斯的投影计算得到 2D 高斯的中心 $\boldsymbol{\mu}$ 和半径 r ：

$$\boldsymbol{\mu}^{2D} = K \frac{E_t \boldsymbol{\mu}}{d}, r^{2D} = \frac{fr}{d}, d = (E_t \boldsymbol{\mu})_z \quad (3-4)$$

公式中， K 为相机内参矩阵， E_t 为包含了相机旋转和平移信息的外参矩阵， f 为相机的焦距， d 为第 i 个高斯在相机坐标系下的深度值。

与原版 3DGS 不同，本文提出的 GSGuide 框架可同时可微渲染深度图和轮廓图，用于后续的高斯致密化和参数更新。像素 p 处的渲染深度 $\hat{D}(p)$ 和轮廓 $\hat{S}(p)$ 分别为：

$$\hat{D}(p) = \sum_{i=1}^n d_i f_i(p) \prod_{j=1}^{i-1} (1 - f_j(p)) \quad (3-5)$$

$$\hat{S}(p) = \sum_{i=1}^n r_i f_i(p) \prod_{j=1}^{i-1} (1 - f_j(p)) \quad (3-6)$$

语义高斯的迭代渲染过程包含两个交替执行的步骤：高斯致密化与语义地图更新。高斯致密化是指在每一帧新观测到来时初始化新的高斯，而语义高斯更新步骤则是通过可微渲染技术优化所有高斯参数。流程如图3.2所示，智能体的 RGB




图 3.2 语义高斯渲染流程

观测通过 Yolo26 模型进行语义分割，得到分割结果 C_t 。在高斯致密化过程中的高斯初始化阶段，为每个高斯的语义标签 l 赋予初始值。随后，通过可微渲染技术，将所有高斯的语义渲染结果与真实语义图进行对比，计算出所有高斯的语义损失，进行参数更新。

GaussNav 在实现过程中仅将语义信息赋予高斯离散语义标签，在优化阶段跳过了梯度跟踪。本文通过优化语义标签渲染过程，采用与 RGB 相同的渲染逻辑，但不参与 α 混合操作，而是选取贡献度最大的高斯所带有的语义为每个像素渲染一个 v 维语义向量，经 *softmax* 将 v 维向量表示为各语义类别概率，实现了语义标签的梯度跟踪，实现后续的语义监督与优化过程。

在时刻 t ，高斯致密化会通过比较基于 $t-1$ 时刻高斯在当前位姿 P_t 的渲染结果与真实 RGB 观测图像，在现有已经构建好的高斯因没有覆盖而无法表示的区域新增高斯。本文参考 Keetha^[11]等人方法，基于致密化掩码 $M(p)$ 确定需要添加高

斯的像素位置。计算公式如下：

$$M(p) = (\hat{S}(p) < 0.5) + (D(p) < \hat{D}(p))(L_1(\hat{D}(p)) > 50 \cdot MDE) \quad (3-7)$$

式中, $(\hat{S}(p) < 0.5)$ 表示现有高斯密度不足的区域, $(D(p) < \hat{D}(p))(L_1(\hat{D}(p)) > 50 \cdot MDE)$ 表示真实深度中位于预测深度方向的前方且深度误差大于 50 倍中值深度误差 (MDE) 的区域。

完成当前帧的高斯致密化后, 本文通过可微渲染和梯度下降优化更新所有高斯中的所有参数。这一过程等价于键辐射场拟合到已知位姿图像的经典问题, 通过计算 RGB、深度、语义分割损失以及他们的加权损失, 来更新每个高斯中的参数。具体而言, 总损失定义如下:

$$\mathcal{L}_{total} = \lambda_{rgb}\mathcal{L}_{rgb} + \lambda_{depth}\mathcal{L}_{depth} + \lambda_{seg}\mathcal{L}_{seg} \quad (3-8)$$

其中, $\mathcal{L}_{rgb}$ 为渲染图像与真实 RGB 观测图像的 L_1 和 SSIM 组合损失, 具体定义为:

$$\mathcal{L}_{rgb} = \lambda_{L1} \cdot L1(I_{render}, I_{gt}) + \lambda_{SSIM} \cdot (1 - SSIM(I_{render}, I_{gt})) \quad (3-9)$$

深度损失定义为:

$$\mathcal{L}_{depth} = \mathcal{L}_{depth} = \frac{1}{|M|} \sum_{(h,w) \in M} |D_{render}[h, w] - D_{gt}[h, w]| \quad (3-10)$$

其中, $D_{render} \in \mathbb{R}^{1 \times H \times W}$ 代表渲染得到的深度图, $D_{gt} \in \mathbb{R}^{1 \times H \times W}$ 代表真实深度图, M 代表有效像素掩码, $|M|$ 代表掩码 M 中有效像素的数量。

语义损失包含了 $\mathcal{L}_{ce}$ 交叉熵损失、 $\mathcal{L}_{dice}$ DICE 损失, 以及基于 IoU 的 Focal IoU 损失 $\mathcal{L}_{focal_iou}$ 。语义总损失定义为:

$$\mathcal{L}_{seg} = \lambda_{ce}\mathcal{L}_{ce} + \lambda_{dice}\mathcal{L}_{dice} + \lambda_{focal_iou}\mathcal{L}_{focal_iou} \quad (3-11)$$

交叉熵损失是图像分割和目标分类中最基础的损失函数。其核心思想是对于每个像素预测出一个概率分布, 交叉熵衡量这个预测分布与真实标签分布之间的相似程度。真实标签对应类别的预测概率越接近 1, 损失就越小, 反之则越大。交叉熵损失定义为:

$$\mathcal{L}_{ce} = CrossEntropy(P_{seg}, Y_{gt}) \quad (3-12)$$

其中, $P_{seg} \in \mathbb{R}^{1 \times C \times H \times W}$, $Y_{gt} \in \mathbb{N}^{1 \times 1 \times H \times W}$, P_{seg} 表示语义渲染概率图, Y_{gt} 表示真实语义标签, C 表示渲染通道数, 即语义类别数。

Dice 损失函数源于 Sørensen-Dice 系数，是图像分割任务中广泛采用的一致性评价指标，其值越接近 1 表示预测区域与真实标注区域的重叠程度越高。Dice 损失定义为 1 减去 Dice 系数，因此优化 Dice 损失本质上是对评价指标本身的直接优化，这一特性使其在动机层面相较于交叉熵损失更契合分割任务的核心目标。特别在小目标分割和类别不平衡场景下，Dice 损失能够更有效地引导模型关注边界细节和小区域的精确分割。

Dice 损失定义为：

$$\begin{aligned}
 \text{Intersection}_c &= \sum_{h=1}^H \sum_{w=1}^W \mathbf{P}_{\text{semantic}}[0, c, h, w] \cdot \mathbf{Y}_{\text{gt_onehot}}[0, c, h, w], \\
 \text{Union}_c &= \sum_{h=1}^H \sum_{w=1}^W \mathbf{P}_{\text{semantic}}[0, c, h, w] + \sum_{h=1}^H \sum_{w=1}^W \mathbf{Y}_{\text{gt_onehot}}[0, c, h, w], \\
 \text{Dice}_c &= \frac{2 \cdot \text{Intersection}_c + \epsilon}{\text{Union}_c + \epsilon}, \\
 \mathcal{L}_{\text{dice}} &= 1 - \frac{1}{C} \sum_{c=1}^C \text{Dice}_c,
 \end{aligned} \tag{3-13}$$

其中各参数定义如下：

- $\mathbf{P}_{\text{semantic}} \in \mathbb{R}^{1 \times C \times H \times W}$ ：模型预测的语义概率图，第 $[0, c, h, w]$ 个元素表示位置 (h, w) 处属于类别 c 的概率，取值范围为 $[0, 1]$ ；
- $\mathbf{Y}_{\text{gt_onehot}} \in \mathbb{R}^{1 \times C \times H \times W}$ ：真实语义标签的 one-hot 编码，当位置 (h, w) 的真实类别为 c 时， $\mathbf{Y}_{\text{gt_onehot}}[0, c, h, w] = 1$ ，否则为 0；
- Intersection_c ：第 c 类的预测结果与真实标签的逐元素乘积之和，即两类区域的交集像素数；
- Union_c ：第 c 类的预测概率图与真实标签的逐元素求和，即两类区域的并集像素数（未扣除重叠部分）；
- Dice_c ：第 c 类的 Dice 系数，取值范围为 $[0, 1]$ ，值越大表示预测与真实的一致性越高；
- C ：语义类别总数； H, W ：特征图的高度和宽度；
- $\epsilon = 1e - 5$ ：数值稳定性平滑项，避免计算时分母为零导致数值不稳定。

Focal 损失函数由 Lin^[34] 等人提出, 旨在解决密集目标检测与分割任务中难易样本极端不均衡的问题。在 3D 高斯语义渲染任务中, 不同语义类别 (如背景与前景、小物体与大物体) 的像素数量存在显著差异, 传统 IoU 损失对简单样本和困难样本同等对待, 导致模型训练偏向于占主导地位的类别。为此, 本文引入 Focal IoU 损失, 通过动态加权机制聚焦于难分类样本, 定义为:

$$\begin{aligned}
 \text{Intersection}_c &= \sum_{h=1}^H \sum_{w=1}^W \mathbf{P}_{\text{semantic}}[0, c, h, w] \cdot \mathbf{Y}_{\text{gt_onehot}}[0, c, h, w], \\
 \text{Union}_c &= \sum_{h=1}^H \sum_{w=1}^W \mathbf{P}_{\text{semantic}}[0, c, h, w] + \sum_{h=1}^H \sum_{w=1}^W \mathbf{Y}_{\text{gt_onehot}}[0, c, h, w] - \text{Intersection}_c, \\
 \text{IoU}_c &= \frac{\text{Intersection}_c + \epsilon}{\text{Union}_c + \epsilon}, \\
 \text{FocalIoU}_c &= 1 - \text{IoU}_c \cdot (1 - (1 - \text{IoU}_c)^\gamma), \\
 \mathcal{L}_{\text{focal_iou}} &= \frac{1}{C} \sum_{c=1}^C \text{FocalIoU}_c,
 \end{aligned} \tag{3-14}$$

其中各参数定义如下:

- $\mathbf{P}_{\text{semantic}} \in \mathbb{R}^{1 \times C \times H \times W}$: 模型预测的语义概率图, 第 $[0, c, h, w]$ 个元素表示位置 (h, w) 处属于类别 c 的概率;
- $\mathbf{Y}_{\text{gt_onehot}} \in \mathbb{R}^{1 \times C \times H \times W}$: 真实语义标签的 one-hot 编码, 当位置 (h, w) 的真实类别为 c 时, $\mathbf{Y}_{\text{gt_onehot}}[0, c, h, w] = 1$, 否则为 0;
- Intersection_c : 第 c 类的预测结果与真实标签的交集像素数;
- Union_c : 第 c 类的预测结果与真实标签的并集像素数;
- IoU_c : 第 c 类的交并比, 衡量预测区域与真实区域的重合程度;
- $\gamma = 2.0$: Focal 参数, 控制难分类样本的权重增强程度, γ 越大, 困难样本获得的权重越高;
- $\epsilon = 1e - 5$: 数值稳定性平滑项, 避免计算 IoU 时分母为零;
- C : 语义类别总数; H, W : 特征图的高度和宽度。

Focal IoU 损失通过在标准 IoU 损失^[35]基础上引入调制因子 $(1 - \text{IoU}_c)^\gamma$ 实现动态样本加权：当 IoU_c 接近 1（简单样本）时，调制因子趋近于 0，损失被显著降低；当 IoU_c 较小（困难样本）时，调制因子趋近于 1，损失保持较大值。这种机制迫使模型在训练过程中更多地关注语义边界模糊、类别混淆等困难样本，从而提升整体语义渲染的准确性和鲁棒性。

联合使用三个不同的语义损失从像素级、区域级和困难样本三个维度对分割结果施加互补约束。交叉熵损失提供逐像素的分类监督，确保每个像素点的预测概率分布与真实标签一致；Dice 损失从集合重叠的角度优化整体一致性，特别关注小目标和前景区域的精确分割；Focal IoU 损失则动态调整难易样本的权重，迫使模型聚焦于语义边界模糊、类别混淆等困难样本。三者协同作用形成多层次、多粒度的语义监督体系：交叉熵损失保证基础分类准确性，Dice 损失增强区域一致性，Focal IoU 损失提升困难样本的识别能力，从而显著提升语义高斯地图的渲染质量，为后续的目标定位与导航任务奠定坚实基础。

3.3 目标定位与相机位姿估计

利用构建完成的语义高斯地图，本文提出高斯导航算法，流程如图3.3所示。




图 3.3 目标定位与路径规划流程

首先，对目标图像 I_g 进行分类，预测目标物体的语义标签 $\hat{l}_g$ ；然后利用该语义标签查询语义高斯地图中所有同类别实例物体，并与目标图像进行匹配，从而确定初始位姿 $\hat{P}_g$ ；最后通过路径规划模块生成可行路径并输出智能体动作序列。

3.3.1 分类器

考虑到直接将目标图像与场景中所有可导航点的渲染结果进行匹配会导致搜索空间过于庞大，导致计算效率极低。因此，本文首先通过分类器预测目标图像中的物体实例语义类别；得到类别后信息后，可以在场景中通过检索相同类比的

物体进行后续匹配，进而大幅度降低搜索空间，提升效率。

本文使用 Yolo 团队官方提供的预训练好的 Yolo26^[20]模型作为分类器进行分类。

3.3.2 匹配与定位

根据分类器预测的目标类别 $\hat{l}_g$ ，提取语义高斯地图中包含所有该类别的候选物体实例，加载相应的拍摄相机位姿。

假设相机坐标系到 Habitat 世界坐标系的转换矩阵为 $c2w$ ，候选物体在该相机视角坐标系下的平移向量为 t_c^o 。本文定义物体到世界坐标系的旋转矩阵由前向、右向和向上三个向量构成：前向向量为从训练视角相机指向候选物体的向量 t_c^o ，向上的向量定义为 $[0, -1, 0]$ ，右向向量与前向和向上的向量共同构成右手坐标系。则物体到世界坐标系的平移向量 t_w^o 为：

$$t_w^o = c2w \times t_c^o \quad (3-15)$$

旋转矩阵与平移向量共同构成物体到世界坐标系的刚体变换矩阵 $o2w$ 。

本文定义围绕 y 轴和 x 轴的旋转矩阵分别为 $R_y(\theta)$ ， $R_x(\theta)$ ，用于后续生成水平和垂直方向上的新视角。水平和垂直方向新视角生成方式如下：

$$c2w_h(\theta) = o2w \times R_y(\theta) \times w2o \times c2w \quad (3-16)$$

$$c2w_v(\theta) = o2w \times R_x(\theta) \times w2o \times c2w \quad (3-17)$$

设每个候选实例 i 所对应的候选图像集合为 S_i 。当场景中拥有 n 个与目标同类别候选实例时，所有候选的渲染图像集合为：

$$S = S_1, S_2, \dots, S_n \quad for i = 1, 2, \dots, n \quad (3-18)$$

针对候选图像，本文采用 LightGlue+DISK^[21-22]进行特征点提取与匹配作为初始估计位姿，再使用 GSplatLoc^[3]提出的 Warping Loss 图像扭曲技术基于粗位置对齐目标图像拍摄相机位姿。具体而言，在分类器输出类别信息后，搜索范围可缩小在同类别的候选实例中，目标物体的识别可形式化为选择匹配点数量最多的候选实例：

$$i_{max} = \operatorname{argmax}\{\max_{s \in S_1} \Omega(s), \max_{s \in S_2} \Omega(s), \dots, \max_{s \in S_n} \Omega(s)\} \quad (3-19)$$

式中 $\Omega(\cdot)$ 表示渲染图像 s 和目标图像 I_g 中提取关键点坐标及其特征描述子:

$$(K_t, V_t) = DISK(s), \quad (K_g, V_g) = DISK(I_g) \quad (3-20)$$

然后使用 LightGlue 算法进行特征匹配, 得到关键点匹配对:

$$(\hat{K}_t, \hat{K}_g) = LightGlue((K_t, V_t), (K_g, V_g)) \quad (3-21)$$

匹配关键点数量即为 Ω 的值。匹配点数量最多的候选实例即为目标物体, 选取其位姿作为初始位姿。

确定目标实例后与初始位姿 $(\mathbf{R}, \mathbf{t})$ 后, 根据初始位姿 $(\mathbf{R}, \mathbf{t})$ 渲染图像 q_r 以及对应的深度图 d_r , 随后最小化 Warping Loss 来优化最终的位姿 $(\mathbf{R}', \mathbf{t}')$ 。

Warping Loss 定义为渲染图像与目标图像的所有像素级别的 RGB 差异总和:

$$\mathcal{L}_{rgb-warp} = \sum_{p_i} \|Y(q, W(p_i, \mathbf{R}, \mathbf{t})) - Y(q_r, p_i)\|_2 \quad (3-22)$$

其中, 扭曲函数 $W(\cdot)$ 定位为:

$$W(p_i, \mathbf{R}, \mathbf{t}, \mathbf{R}', \mathbf{t}') = \Pi(\mathbf{R}(\mathbf{R}'^{-1}\Pi^{-1}(p_i, z_r(p_i)) - \mathbf{R}'^{-1}\mathbf{t}') + \mathbf{t}) \quad (3-23)$$

其中, $Y(q_r, p_i) \in \mathbb{R}^3$ 表示渲染图像 q_r 上位于 i 处的像素 $p_i \in \mathbb{R}^3$ 的 RGB 颜色值。扭曲函数 $W(\cdot)$ 通过对参考图像 q_r 上的像素 p_i 执行坐标变换, 找到其在目标图像 q 上对应的像素。具体而言, 函数 W 利用渲染深度 z_r 将像素 p_i 反投影到渲染图像 q_r 对应的三维相机坐标系中, 再通过优化后的位姿 $(\mathbf{R}', \mathbf{t}')$ 将其转换到目标图像 q 的相机坐标系, 最终投影到目标图像 q 的平面上。

使用迭代优化后的估计位姿 $(\mathbf{R}', \mathbf{t}')$ 作为目标物体拍摄的相机位姿, 将其转换为世界坐标系下的位置与智能体可导航点。至此, IIN 任务被转化为点目标导航任务。

在这里, 本文提供一个实际成功基于初始位姿精修成功的案例。如图3.4所示: 左边为智能体接收到的目标图像, 中间为初始粗位姿下的渲染图像, 右侧为经过 Warping Loss 后的渲染图像。可以看出精修后拍摄位姿更加贴近于目标图像的拍摄位姿。

3.4 智能体导航

语义高斯梯度并非为路径规划设计, 因此本文首先基于优化后位姿观察得到的高斯转换为点云, 然后将点云体素化为 3D 体素网格 M3D, 最后将 3D 体素网格



图 3.4 位姿精修成功案例可视化

投影为 2D 鸟瞰图 (BEV) 网格 M2D。本文使用语义高斯的 2D 投影而非预探索阶段的 2D 几何地图, 以保持整个流程表示的一致性。由于语义高斯使用深度图像生成的点云进行初始化, 且在优化过程中不进行高斯剪枝, 因此其 2D 投影与预探索阶段的 2D 几何地图本质上是等价的。给定 2D BEV 网格地图 M2D 智能体起始位置和目标位置, 本文使用快速行进法 (FMM) 生成最短距离场。距离场中的每个点存储从起始点到该点的最短路径长度。智能体在其运动范围内选择距离场的局部极小值点作为下一个航点, 确保路径不与障碍物相交。根据当前状态与航点的角度和距离, 智能体计算并执行相应动作。迭代上述过程直至到达目标位置

在这里, 本文提供一个实际导航成功案例的可视化过程图。如图3.5所示, 当




图 3.5 导航成功案例可视化过程

智能体在环境中被随机初始化时, 系统会向其提供一张展示目标物体的目标图像。智能体利用已构建好的高斯以及处理过目标位置, 并向目标物体移动, 最终到达目标物体。

第四章 实验与结果分析

本章对论文所提方法完成了实验与结果分析。首先给出了实验设置，包括实验环境、实验用数据集、智能体配置及动作空间，以及实验用评估指标。然后，与当前已有的各类 baseline 和 SOTA 方法进行了对比实验，并给出了实验结果分析。随后，通过消融实验，评估了本文所提方法中各个组件的有效性，并评估了所提方法的计算效率，最后进行了误差分析。

4.1 实验准备

4.1.1 实验环境

本文使用 Hello Robot Stretch 平台^[36]开展实验，使用 Habitat-sim 仿真器^[29]。在本地服务器搭建完整的开发环境，保证各阶段实验顺利进行。

1. **硬件环境：**本实验使用本地服务器进行训练测试，主要硬件配置如下：

处理器 (CPU): Intel Core i7-14700K

内存 (RAM): 32GB

显卡 (GPU): RTX 4090

2. **核心软件环境：**

Python: 3.9.16

Pytorch: 2.1.1

CUDA: 12.8

Habitat-sim: 0.1.0

4.1.2 实验用数据集

遵从 GaussNav 原论文，本文在 Habitat 仿真器^[29]中使用 Habitat-Matterport3D 数据集 (HM3D)^[30]展开实验。HM3D 数据集由真实环境的 3D 重建场景构成。目标图所包含的物体实例属于 COCO 数据类别中的六个，如表2.1所示。

4.1.3 智能体配置

遵循 GaussNav 论文，本文同样采用 Hello Robot Stretch^[36]平台的实体化参数。仿真智能体是一个零转弯半径的刚体圆柱体，高度为 1.41 米，半径为 0.17 米，在离地高度 1.31 米处装有一个前向的 RGB-D 相机。在每个时间步 t ，智能体的观测

包括以自我为中心的 RGB 图像、深度图像、目标图像以及传感器位姿读数。智能体相机与目标相机的规格全部统一为 512×512 。智能体相机使用标准针孔相机模型，水平视场角定义为 90 度，水平焦距 f_x 计算公式为

$$f_x = \frac{w}{2 \cdot \tan(\frac{\theta_h}{2})} \quad (4-1)$$

其中， θ_h 是相机在水平方向上能够捕捉到的最大角度， w 是相机图像的宽度。垂直焦距 $f_y = f_x$ 。

相机主点，即相机光轴图像平面的交点。在无畸变的针孔相机中，主点恰好位于图像的中心，计算方式为：

$$c_x = \frac{w}{2}, \quad c_y = \frac{h}{2} \quad (4-2)$$

其中， h 是相机图像的高度。

4.1.4 智能体的动作空间

采用离散动作空间进行导航，包含四种动作： $\{\text{STOP}, \text{FORWARD}, \text{TURN_RIGHT}, \text{TURN_LEFT}\}$ 。STOP 动作会停止当前任务回合；FORWARD 动作会在每个时间步内使智能体向前移动 25cm；TURN_RIGHT 和 TURN_LEFT 动作会使智能体在原地顺时针或者逆时针旋转 25 度。

4.1.5 评估指标

在高斯渲染阶段，除了使用原始 3DGS 使用的 SSIM、PSNR、RMSE、L1 和 LPIPS 指标来评估 RGB 重建质量外，本文还针对高斯语义渲染质量引入了 DICE 系数和 Focal IoU 系数来评估语义渲染质量。原 GaussNav 论文中并没有针对语义渲染情况做出评估，因此本文也对比了语义是否参与监督与优化的渲染质量。

同时，遵循 krantz 等人^[31]的方法，本文使用导航成功率（Success）以及归一化逆路径长度（SPL）^[37]作为成功率和效率的评估指标。当智能体调用 STOP 动作时，系统判定智能体目前所在位置和目标位置的直线欧式距离是否小于等于 1 米，若小于 1 米则判定成功 $Success = 1$ ，否则判定失败 $Success = 0$ 。

SPL 具体计算公式为：

$$SPL = \frac{1}{N} \sum_{i=1}^N S_i \cdot \frac{l_i}{\max(p_i, l_i)} \quad (4-3)$$

其中 N 为任务回合总数， S_i 为第 i 个任务回合的二值成功指示符号， l_i 为从起始位置到目标的最短路径距离， p_i 为智能体实际走过的路径长度。SPL 值越高，表示导航效率越高。

4.2 与现有方案的对比

为证明论文所提方法的有效性, 本文选取了领域内多种 baseline 方法以及先进方法进行了对比实验。其中, Baseline 方法包括了 RL Baseline^[1]和 OVRL-v2^[38], 先进方法包括了 Mod-II^[31], SOTA 方法包括了 GaussNav^[2]。为确保实验公平性, 所有实验均在相同的 HM3D 验证集 (包含 36 个场景、1000 个测试任务)、场景特定地图设置和硬件环境下进行。对比结果如表格4.1所示。

表 4.1 与现有导航方案的对比

对比方法	Success $\uparrow$	SPL $\uparrow$
RL Baseline ^[1]	0.083	0.035
OVRL-v2 ^[38]	0.006	0.002
Mod-II ^[31]	0.573	0.313
GaussNav ^[2]	0.725	0.578
GSGuide (Ours)	0.778	0.585

一方面, 传统的实例目标图像导航会在每一个 episode 中重新生成场景地图。不同的是, 本文所提出的框架会为同一个场景构建一个可以复用的地图。表格中第一部分呈现了几种基线方法, 第二部分对比了本文所提出的框架与 SOTA 方法 (包括 GaussNav^[2]) 在本文所使用的特定场景数据集上的性能对比。

4.2.1 端到端 baseline 方法

本文评估了两种代表性的端到端方法在 IIN 任务上的性能。

RL Baseline^[1]构建了一个端到端的强化学习网络, 该网络直接接收智能体的 RGB 图像、深度图像、目标图像、GPS 坐标和航向角作为输入, 通过独立的视觉编码器和位置编码器提取特征, 经两层 LSTM 融合后输出动作决策。该网络使用近端策略优化 (PPO) 算法从头开始训练, 最终仅取得了 0.083 的成功率和 0.035 的 SPL。这一结果表明, 纯端到端的强化学习框架难以同时掌握 IIN 任务所需的场景语义理解、跨视角实例识别和长期空间记忆等核心能力, 导致导航性能和效率均处于较低水平。

OVRL-v2^[38]是当前图像目标导航 (ImageGoal Navigation) 任务的代表性基线方法, 其核心是通过自监督预训练学习通用的视觉表示。本文将在 ImageGoal 任务上预训练的 OVRL-v2 模型应用于 IIN 任务, 发现其性能极差, 成功率仅为 0.006,

远低于基于地图的模块化方法。这一显著的性能下降主要源于三个方面的不匹配：一是场景数据集从 Gibson^[39] 切换到了 HM3D，二是机器人本体从 Locobot^[40] 变为了 Hello Robot Stretch^[36]，三是任务目标从”导航到图像拍摄位置”转变为”导航到图像中的特定物体实例”。这进一步验证了端到端方法在处理需要精细实例区分和空间推理的 IIN 任务时存在固有局限性。

4.2.2 先进方法对比

本文评估了当前 IIN 任务的先进方法，并统一使用场景特定地图 (Scene Map) 设置进行公平对比。场景特定地图允许智能体在同一场景的不同导航回合中复用预先构建的地图，避免了重复探索的开销，这也是本文方法采用的实验设置。

Mod-IIN^[31] 是一个系统性解决 IIN 任务的模块化方法，它将任务分解为探索、目标实例重识别、目标定位和局部导航四个独立子任务，每个子任务均使用无需微调的现成组件实现。将模型应用于本文所使用的 HM3D 数据集进行测试，结果表明 Mod-IIN 的 *SPL* 达到了 0.313，成功率达到 0.573，这表明基于地图的模块化方法在 IIN 任务中具有较大优势。

4.2.3 SOTA 对比

GaussNav^[2] 通过引入 3D 高斯溅射技术构建语义高斯地图，实现了 IIN 任务性能显著提升。与传统 BEV 地图仅能保留 2D 几何和粗粒度语义信息不同，语义高斯地图同时编码了场景的 3D 几何结构、每个高斯的语义标签以及物体的精细纹理特征。这使得智能体能够直接从地图中渲染出物体实例的多视角 (NVS) 描述性图像，与目标图像进行特征匹配从而精确确定目标实例与目标位置，无需像 BEV 地图方法那样对潜在候选对象进行额外的近距离验证。实验结果显示，GaussNav 在场景特定地图设置下取得了 0.725 的成功率和 0.578 的 *SPL*，充分证明了语义高斯地图表示在实例级导航任务中的显著优势。

本文提出的 GSGuide 方法在 GaussNav 的基础上，通过两个关键创新进一步提升了导航性能：

1. **语义渲染监督机制**：通过为每个高斯引入可训练的语义向量，并在优化过程中持续监督语义渲染质量，解决了原始 GaussNav 中语义标签与几何纹理参数脱节的问题。这使得语义高斯地图能够更准确地编码场景的细粒度语义信息，提升了实例级目标识别的可靠性。
2. **位姿精修 Warping Loss**：通过最小化渲染图像与目标图像之间的像素级光度

损失，实现了亚像素级的位姿优化。这种稠密对齐方式能够有效修正基于稀疏特征匹配得到的初始位姿偏差，特别适用于纹理较少或存在遮挡的场景。

实验结果表明，GSGuide 的导航成功率从 GaussNav 的 0.725 提升至 0.778（相对提升 7.31%），同时 SPL 从 0.578 提升至 0.585（相对提升 1.21%）。这一结果验证了两个核心改进的有效性：语义渲染监督机制主要提升了目标识别的准确性，而位姿精修 Warping Loss 则优化了目标定位的精度。两者协同作用，使 GSGuide 在 HM3D 数据集上取得了当前最优的导航性能。

4.3 消融实验

4.3.1 消融实验设置与结果

为了系统验证本文提出的语义渲染监督机制和位姿精修 Warping Loss 两个核心改进的有效性，本文设计了三组对照消融实验。

表 4.2 消融实验导航性能结果

消融实验设置	Success $\uparrow$	Δ Success	SPL $\uparrow$	Δ SPL
GSGuide	0.778	–	0.585	–
GSGuide w.o. Supervised Segmentation	0.723	-0.055	0.577	-0.008
GSGuide w.o. Warping loss	0.748	-0.030	0.582	-0.003

表 4.3 消融实验语义渲染指标结果

消融实验设置	交叉熵损失 $\downarrow$	Dice 损失 $\downarrow$	Focal IoU 损失 $\downarrow$
GSGuide	1.501	0.867	0.915
GSGuide w.o. Supervised Segmentation	1.801	0.891	0.971
GSGuide w.o. Warping loss	1.501	0.867	0.915

4.3.2 语义渲染监督有效性

本实验移除了本文提出的语义渲染监督机制，即完全遵从原始 GaussNav 的语义处理流程：仅在高斯初始化阶段通过 Mask R-CNN 的分割结果为每个高斯分配一次性静态语义标签，在后续的可微渲染优化和高斯致密化过程中禁用语义标签梯度跟踪，不再引入任何语义损失进行监督，仅保留原始 3DGS 的 RGB 和深度重建损失。

导航性能的消融实验结果如表 4.2 所示，移除语义渲染监督后，模型的成功率

从 0.778 下降至 0.723，相对下降幅度为 7.07%；SPL 从 0.585 小幅下降至 0.577，相对下降幅度为 1.37%。

语义渲染指标如表 4.3 所示，移除监督后交叉熵损失从 1.501 上升至 1.801，相对上升 20.0%；Dice 损失从 0.867 上升至 0.891，相对上升 2.8%；Focal IoU 损失从 0.915 上升至 0.971，相对上升 6.1%。

深入分析表明：

1. **语义错位问题：**静态语义标签并不会跟随高斯的 3D 几何纹理参数同步更新，在多层迭代优化后，高斯的位置、大小可能发生变化，但语义标签保持不变，导致语义错位问题，进而引起物体边界模糊、覆盖不完整不连续等问题。
2. **误差传递效应：**语义误差会传递到后续的实例匹配阶段。由于语义标签不准确，在检索相同类别的候选物体时可能会遗漏真正的目标，或者引入无关的干扰物体，导致物体实例匹配得分受到影响，进而引发部分目标匹配混淆。
3. **对 SPL 的有限影响：**SPL 的小幅度下降说明语义渲染监督主要影响目标识别的准确性，对于已经确定的目标实例，后续的导航路径规划效率受到的影响较小。这是因为路径规划主要依赖场景的几何结构，而非精细的语义信息。

进一步分析发现，移除语义渲染监督后的模型性能 (0.723/0.577) 与原始 GaussNav (0.725/0.578) 几乎完全持平，性能差异小于 0.3%，在统计上不显著。这一对照结果严格证明：语义渲染监督是本文方法相对于 GaussNav 的核心性能提升来源，其他实验设置（如相机参数统一、训练超参数调整）对最终结果的影响可以忽略不计。

为进一步展现语义监督机制的有效性，本文可视化对比了语义参与监督前后的渲染效果。如图 4.1 所示，含有不同语义信息的实例物体本文选用了不同的颜色进行可视化。

本文选取了三个视角进行对比，可以明显看出，相较于优化前优化后高斯覆盖更加完整、连续，物体表面覆盖断层减少，这为导航点计算提供了更准确的参考。

4.3.3 位姿精修 Warping Loss 有效性

本实验移除了本文提出的位姿精修 Warping Loss 模块，即在目标匹配阶段仅使用 DISK+LightGlue 的特征匹配结果直接估算目标的 3D 位置，不再通过光度对



图 4.1 语义渲染监督机制优化前后对比

齐损失对目标的位姿进行精细化优化。

导航性能结果如表 4.2 所示，移除 Warping Loss 后，模型的成功率从 0.778 下降至 0.748，相对下降幅度为 3.86%；SPL 从 0.585 下降至 0.582，相对下降幅度为 0.51%。

语义渲染指标如表 4.3 所示，移除 Warping Loss 后各项指标保持不变，因为位姿精修模块与语义优化在流程上处于前后两个阶段，是完全独立的两个环节，因此移除位姿精修模块对语义渲染质量没有影响，主要作用于位姿优化阶段。

深入分析表明：

1. **特征匹配的局限性：**传统的局部特征匹配方法主要基于稀疏关键点估算目标的位置，对于纹理较少的物体（如光滑的墙壁、白色家具）或存在部分遮挡的物体，可用的关键点数量大幅减少，容易引起较大的定位偏差。
2. **光度对齐的优势：**本文引入 warping loss 最小化渲染图像与目标图像之间的像素级光度损失，能够使相机位姿尽可能优化到目标图像拍摄位姿。相比于仅使用稀疏特征匹配，这种稠密对齐方式显著提升了定位准确性。

SPL 的微小变化同样说明，位姿精修主要影响目标定位的精度，只要能够正确识别目标并确定其大致位置，导航路径的长度不会发生显著变化。

4.3.4 消融实验结论

消融实验结果充分验证了本文提出的两个核心改进的有效性，通过定量分析可以得出以下结论：



图 4.2 语义信息错误导致位姿错误估计

- **语义渲染监督**是性能提升的主要来源，贡献了 7.07% 的成功率提升，同时显著改善了所有语义渲染指标（交叉熵损失下降 20.0%，Dice 损失下降 2.8%，Focal IoU 损失下降 6.1%），解决了原始 GaussNav 中语义标签与几何纹理脱节的问题；
- **位姿精修 Warping Loss** 贡献了 3.86% 的成功率提升，进一步优化了目标定位的精度，但对语义渲染质量几乎没有影响；
- 两个模块具有良好的协同效应，联合使用时取得了最佳性能；
- 语义渲染监督主要影响目标识别阶段，而位姿精修 Warping Loss 主要影响目标定位阶段，两者作用于不同环节，形成互补。

两者协同作用使本文方法在 HM3D 数据集上均取得了优于 GaussNav 的性能。

4.4 误差分析

本文提出的 GSGuide 框架仍然有提升空间。为了明确未来的改进方向，本文分析了框架的主要误差来源。具体而言，误差主要来自于语义错误识别和场景建立质量不完善两个方面：

4.4.1 语义错误识别

前期语义分割依赖于 Yolo26 语义分割模型，在某些场景中存在一定的误识别。具体而言，Yolo26 有时会将一个物体归为错误的语义类别。例如图4.2所示，目标图像的 GT COCO ID 被标记为 56（椅子），而 Yolo26 却将其归为 59（床），进而在初始位姿估计时出现严重偏差，导致可导航点计算失败。



图 4.3 场景“漏洞”

4.4.2 场景建立质量不完善

如表4.4所示，尽管本文提出的 GsGuide 框架展现出良好的综合重建性能，其

表 4.4 场景构建质量

Avg. PSNR $\uparrow$	Avg. RMSE $\downarrow$	Avg. L1 $\downarrow$	Avg. MS-SSIM $\uparrow$	Avg. LPIPS $\downarrow$
29.71	4.75	4.75	0.966	0.176

平均峰值信噪比（PSNR）达到 29.71 dB，深度估计的均方根误差（RMSE）与平均绝对误差（L1）均为 4.75 cm，表明深度估计精度较高且误差分布均匀无显著离群值；同时，平均多尺度结构相似性指数（MS-SSIM）高达 0.966，平均感知图像块相似度（LPIPS）低至 0.176，说明重建结果在结构纹理一致性和人眼视觉感知质量方面均和 HM3D 场景高度一致，但因 HM3D 场景构建本身存在一定的质量不佳问题，会一定程度上影响后续的目标点计算和导航过程。

具体而言，在将优化后位姿观察所得到的点云体素化转为 2DBEV 网格时，会出现可导航点计算错误的情况。可导航点的估计高度依赖于 HM3D 场景数据集的构建质量，当场景中存在物体遮挡、场景建立质量不完善等问题时，物体 3D 边界框会受到严重影响，进而影响后续可导航点计算环节。如图4.3红框部分，因为场景构建质量不完善导致部分实例或者地面等出现“漏洞”，这在某些情况下会导致可导航点无法计算。例如图中的因床左侧地面出现“漏洞”，系统会在体素化时不考虑地面可通行区域，从而忽略该区域的可导航点计算。

又如图4.4红框所示，HM3D 场景数据集的构建质量不佳使得 Yolo26 无法识别到实例“椅子”，导致这部分语义缺失，初始位姿匹配出现严重偏差，后续的位姿



图 4.4 实例缺失语义信息

精修则更类似于随机过程。

第五章 总结与展望

5.1 研究总结

具身视觉导航作为智能机器人感知与决策的核心技术，是实现家庭服务、工业巡检、公共服务等场景自主化的关键基础。随着应用场景的不断拓展，导航任务对场景建模的精度、目标识别的鲁棒性与导航决策的效率提出了更高要求。其中，实例图像目标导航（IIN）要求智能体仅通过单张目标物体图像，在未知环境中定位并导航至该特定实例，需解决位置环境探索、同类别实例区分抗干扰三大核心挑战。然而，现有主流方法普遍采用二维鸟瞰图（BEV）作为地图表示，虽具备内存占用低、路径规划便捷的优势，但存在三维几何信息缺失、实例纹理特征丢失等固有缺陷，难以支撑高精度的实例级目标定位与匹配，成为制约 IIN 任务性能提升的核心瓶颈。3D 高斯泼溅（3DGS）技术凭借其显式的三维几何表示、高保真的纹理渲染能力与实时可微分渲染特性，为突破上述瓶颈提供了全新的技术路径。GaussNav^[2]首先使用了 3D 高斯地图表示，将目标物体的语义信息与几何信息联合表示，避免了每回合都需要重新构建地图的计算成本，提升了目标定位效率和准确度。但语义信息仅参与高斯标签的赋予阶段，未参与后续的监督优化阶段，导致一定程度上的语义覆盖不完整、语义信息缺失等问题。针对上述问题，本文基于 GaussNav^[2] 基础框架，融合 GSplatLoc^[3] 的位姿精修算法，构建了一套集几何、语义与实例特征于一体的语义高斯导航系统，实现了仅输入单张目标图像即可完成目标实例定位与高效导航的完整流程。研究从地图表示设计、在线构建机制、目标定位算法与系统性能验证四个层面系统开展，取得了以下主要成果与创新：

1. **语义增强的高斯地图表示与联合优化机制：**针对传统 BEV 地图无法保留物体三维几何与纹理细节的问题，本文在 GaussNav^[2] 框架基础上新增语义渲染通道，采用 YOLO26^[20] 语义分割网络输出的像素级语义信息，在高斯初始化与致密化的全流程中为每个高斯赋予多维语义向量，并将语义损失与 RGB、深度损失共同纳入高斯参数的监督优化过程。该机制实现了几何、纹理与语义信息的端到端联合学习，显著提升了语义高斯地图的实例区分能力与跨视角匹配精度。
2. **两阶段目标位姿精修与高效匹配策略：**针对传统方法目标定位精度不足、需

多次验证导致导航效率低下的问题，本文融合 GSplatLoc^[3] 的可微分渲染位姿精修算法，提出“初始粗定位 + 渲染精修”的两阶段目标定位框架。首先通过多视角渲染与关键点匹配实现目标实例的粗定位，再利用可微分渲染优化目标相机位姿，大幅提升了目标定位的精度。同时，位姿精修过程仅需单次前向渲染即可完成梯度计算与参数更新，有效降低了内存开销与计算延迟。

3. **目标导航：**利用优化后的语义高斯表示，结合基于 LightGlue+Disk^[21-22]的特征提取与匹配方案的目标位姿估计，实现了目标导航。

通过以上研究，本文构建了基于 3D 高斯泼溅的实例级视觉导航完整技术体系，突破了传统 BEV 地图在三维信息保留与实例特征表征上的核心局限，实现了从“语义级导航”到“高精度实例级导航”的跨越。研究不仅在理论上丰富了具身视觉导航的地图表示方法与目标定位技术，也在实践中为服务机器人的物品查找、室内巡检等实际应用提供了可行的技术方案，具备良好的产业化应用前景。

5.2 研究展望

尽管本文围绕实例图像目标导航任务，提出了基于语义高斯的导航方法体系并在仿真环境中验证了其有效性，但在实际应用中，真实场景的光照变化、纹理缺失、动态物体干扰以及传感器噪声等因素仍可能影响高斯地图构建质量与目标匹配精度，仍存在诸多值得进一步深入探究的问题与挑战。结合当前 3D 高斯泼溅技术与具身智能的发展趋势，本文认为后续研究可在以下几个方面继续深入，推动实例级视觉导航技术迈向更高水平。

首先，提升方法在真实物理环境中的适应性与泛化能力是未来研究的首要任务。尽管本文方法已在 HM3D 仿真数据集上展现出优异的性能，但仿真环境与真实世界之间存在不可避免的域偏移，因此，未来研究可探索结合域自适应、元学习与在线增量学习技术，实现跨场景、跨设备的快速适配，增强方法在复杂真实环境中的可靠性。

其次，引入可微分物理与动态高斯建模机制，实现更精准的场景表示与位姿估计，也是未来值得重点关注方向。未来可将可微分物理引擎与 3D 高斯泼溅相结合，引入物理一致性约束优化高斯参数，提升场景重建的精度与合理性。同时，研究动态 3D 高斯表示方法，实现对场景中运动物体的实时建模与跟踪，拓展导航系统在动态环境中的应用能力。

最后，实现大场景轻量化在线构建与人机协同交互是技术走向实际应用的必要环节。未来研究可探索高斯压缩、稀疏化与层次化表示技术，降低大场景地图的内存开销；研究增量式高斯构建与回环检测算法，实现边导航边建图的未知环境探索模式。

综上，基于 3D 高斯泼溅的实例级视觉导航仍处于快速发展阶段，面向真实复杂环境的鲁棒导航、动态场景建模与多任务协同等问题依然充满挑战与机遇。未来，随着多模态感知、可微分物理、大模型具身智能等技术的不断进步，语义高斯导航技术有望实现从实验室研究向实际应用的全面转化，为智能服务机器人在家庭、医院、商场等场景的广泛应用提供坚实的技术支撑。

致 谢

当指尖落在键盘上，敲下这最后一章致谢时，心中百感交集。既有完成毕业论文的释然与喜悦，也暗藏着即将与四年本科时光挥手告别的淡淡忧伤——这是独属于毕业季的复杂心绪，难以言喻，却又无比真切。

在此，我要向我的导师致以诚挚的谢意。您不仅是我学术道路上的引路人，更是我生活中的良师益友。从最初的选题构思到最终的论文定稿，您全程悉心指导，带领我完成了人生中第一篇真正意义上的学术论文。每当我在研究中遇到瓶颈与困惑，您总能以严谨的治学态度和耐心的讲解，与我一同剖析问题、寻找解决方案，引领我踏入科研的殿堂，拓宽了我的学术视野。在生活中，您亦如兄长般关怀备至，球场上的并肩挥拍，餐桌上的欢声笑语，深夜里的促膝长谈，都让我在异乡求学的日子里感受到了别样的温暖。

感谢我的辅导员，从大一入学的第一次班会开始，您便一路陪伴着我们，走过了大学四年的春夏秋冬，直到我们站在毕业的十字路口，写下这篇致谢的终章。是您耐心的引导，让我从初入校园时对大学生活的茫然无措，逐渐适应了独立的学习与生活节奏；是您细致的关怀，在我遇到学业困惑、生活难题时，总能第一时间为我指点迷津、排忧解难；是您真诚的鼓励，在我对未来感到迷茫时，帮我理清方向、重拾信心。四年里，您不仅是我们的老师，更是我们的朋友和引路人，用责任与爱心，守护着我们从懵懂新生到成熟毕业生的每一步成长。

感谢我的班级，让我遇见了如此温暖又优秀的集体。大一那年抱着试一试的心态加入，未曾想竟开启了一段长达四年的珍贵缘分。我们曾在期末月并肩挑灯夜战，在假期的餐桌上分享欢声笑语，在升学择校的迷茫中彼此出谋划策，在开学选课混乱里互通有无。这个集体最动人的地方，在于它永远不是少数人的舞台，而是每个人都能找到自己位置的港湾。我们相处融洽，不分彼此，谁遇到困难都会有人主动伸出援手；我们彼此成就，相互照亮，每个人的闪光点都能被看见、被珍视。是你们身上那股不服输的拼劲赋予我勇往直前的动力，是你们不离不弃的陪伴帮助我撑过无数个难熬的时刻。

感谢我的舍友，感谢我们四年朝夕相伴的时光。我们在生活中互帮互助、彼此包容，在琐碎的日常里积攒了最深厚的情谊。疫情封校时的互相投喂，深夜组队开黑的酣畅淋漓，考试前互相划重点的默契，睡前卧谈会的幽默打趣，生病时

端水送药的悉心照料……无数个细碎又温暖的瞬间，让这间不足二十平米的小屋，成为了我在求学时一个温暖安心的港湾。在这里，不用伪装，不用拘谨，可以做最真实的自己。是你们的陪伴与包容，让我学会了如何与人相处、如何分享、如何爱人。这段同吃同住、同喜同悲的岁月，将是我一生都难以忘怀的珍贵回忆。

感谢我的女友，从大二与你相遇开始，我的大学生活便不再是孤身一人。遇到困难，我们携手面对；陷入低谷，我们互相搀扶着慢慢走出；我们一起分享过彼此成功的喜悦，也共同分担过彼此失意的落寞。但好在有你的陪伴与鼓励，让我在大学四年中慢慢成长，让我在求学路上始终有温暖的依靠，让我平淡的日子也变得闪闪发光。你是我青春里最美好的遇见，也是我未来路上最坚定的同行者。

最后，我要将心底最深、最沉的谢意，献给我的父母与家人。你们永远是最坚实的后盾，最温暖的港湾。二十余载含辛茹苦的养育，四年求学路上毫无保留的守护，你们的包容、无条件的支持与爱，是我能够心无旁骛完成学业、勇敢追逐梦想的根本动力。是你们教会我热爱生活、善待世界、真诚待人；是你们在我迷茫困惑时为我点亮前行的灯塔，在我孤独无助时给予我最温暖的拥抱，在我疲惫憔悴时为我撑起一片可以安心休憩的天空。

回首望去，四年时光如白驹过隙。仿佛昨日我还是那个拖着行李箱踏入校园、对一切都充满新鲜与好奇的大一新生，转眼间我已站在毕业的十字路口，已然将要奔赴下一场山海。这四年，说长不长，说短不短，却是我人生中最珍贵、最特殊的一段时光。太多的瞬间值得铭记，太多的回忆难以割舍，那些哭过笑过、拼过爱过的日子，早已化作生命中最温暖的印记。

还有太多的话想说，还有太多的事想做，但轻舟已过万重山，前路漫漫亦灿灿。愿我们此去前程似锦，再相逢依旧如故。

参考文献

- [1] KRANTZ J, LEE S, MALIK J, et al. Instance-specific image goal navigation: Training embodied agents to find object instances[J]. arXiv preprint arXiv:2211.15876, 2022.
- [2] LEI X, WANG M, ZHOU W, et al. Gaussnav: Gaussian splatting for visual navigation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(5): 4108-4121.
- [3] SIDOROV G, MOHRAT M, GRIDUSOV D, et al. Gsplatloc: Grounding keypoint descriptors into 3d gaussian splatting for improved visual localization[C]//2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2025: 12601-12607.
- [4] MILDENHALL B, SRINIVASAN P P, TANCIK M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [5] KERBL B, KOPANAS G, LEIMKÜHLER T, et al. 3d gaussian splatting for real-time radiance field rendering.[J]. ACM Trans. Graph., 2023, 42(4): 139-1.
- [6] CHEN G, WANG W. A survey on 3d gaussian splatting[J]. ACM Computing Surveys, 2024.
- [7] LUITEN J, KOPANAS G, LEIBE B, et al. Dynamic 3d gaussians: Tracking by persistent dynamic view synthesis[C]//2024 International Conference on 3D Vision (3DV). 2024: 800-809.
- [8] WU G, YI T, FANG J, et al. 4d gaussian splatting for real-time dynamic scene rendering[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 20310-20320.
- [9] FENG Y, FENG X, SHANG Y, et al. Gaussian splashing: Dynamic fluid synthesis with gaussian splatting[J]. arXiv preprint arXiv:2401.15318, 2024, 3.
- [10] XIE T, ZONG Z, QIU Y, et al. Physgaussian: Physics-integrated 3d gaussians for generative dynamics[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 4389-4398.
- [11] KEETHA N, KARHADE J, JATAVALLABHULA K M, et al. Splatam: Splat track & map 3d gaussians for dense rgb-d slam[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 21357-21366.
- [12] YUGAY V, LI Y, GEVERS T, et al. Gaussian-slam: Photo-realistic dense slam with gaussian splatting[J]. arXiv preprint arXiv:2312.10070, 2023.
- [13] ZHANG L X, JIANG C, LAI Y K, et al. SeG-Gaussian: Segmentation-Guided 3D Gaussian Optimization for Novel View Synthesis[J]. IEEE Transactions on Visualization and Computer Graphics, 2025.
- [14] MIAO B, WEI R, GE Z, et al. Towards Physically Executable 3D Gaussian for Embodied Navigation[J]. arXiv preprint arXiv:2510.21307, 2025.

-
- [15] LIM H, SINHA S N, COHEN M F, et al. Real-time image-based 6-dof localization in large-scale environments[C]//2012 IEEE conference on computer vision and pattern recognition. 2012: 1043-1050.
 - [16] SARLIN P E, UNAGAR A, LARSSON M, et al. Back to the feature: Learning robust camera localization from pixels to pose[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 3247-3257.
 - [17] LIU C, CHEN S, BHARGAVA Y, et al. GS-CPR: Efficient camera pose refinement via 3d gaussian splatting[J]. arXiv preprint arXiv:2408.11085, 2024.
 - [18] NIU Z, TAN Z, ZHANG J, et al. Hgsloc: 3dgs-based heuristic camera pose refinement[C]//2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 1-7.
 - [19] DAI G, ZHAO J, CHEN Y, et al. Unitedvln: Generalizable gaussian splatting for continuous vision-language navigation[J]. arXiv preprint arXiv:2411.16053, 2024.
 - [20] JOCHER G, QIU J, CHAURASIA A. Ultralytics YOLO[CP/OL]. 8.0.0. 2023. <https://github.com/ultralytics/ultralytics>.
 - [21] LINDENBERGER P, SARLIN P E, POLLEFEYS M. Lightglue: Local feature matching at light speed[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 17627-17638.
 - [22] TYSZKIEWICZ M, FUA P, TRULLS E. Disk: Learning local features with policy gradient[J]. Advances in neural information processing systems, 2020, 33: 14254-14265.
 - [23] POTJE G, CADAR F, ARAUJO A, et al. Xfeat: Accelerated features for lightweight image matching[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 2682-2691.
 - [24] HE K, GKIOXARI G, DOLLÁR P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
 - [25] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[C]//European conference on computer vision. 2014: 740-755.
 - [26] CAESAR H, UIJLINGS J, FERRARI V. Coco-stuff: Thing and stuff classes in context[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 1209-1218.
 - [27] YEN-CHEN L, FLORENCE P, BARRON J T, et al. inerf: Inverting neural radiance fields for pose estimation[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2021: 1323-1330.
 - [28] ZHAO B, YANG L, MAO M, et al. PNeRFLoc: Visual localization with point-based neural radiance fields[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 38: 7. 2024:

7450-7459.

- [29] SZOT A, CLEGG A, UNDERSANDER E, et al. Habitat 2.0: Training home assistants to rearrange their habitat[J]. Advances in neural information processing systems, 2021, 34: 251-266.
- [30] YADAV K, RAMRAKHYA R, RAMAKRISHNAN S K, et al. Habitat-matterport 3d semantics dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 4927-4936.
- [31] KRANTZ J, GERVET T, YADAV K, et al. Navigating to objects specified by images[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 10916-10925.
- [32] LEI X, WANG M, ZHOU W, et al. Instance-aware exploration-verification-exploitation for instance imagegoal navigation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16329-16339.
- [33] CHAPLOT D S, GANDHI D P, GUPTA A, et al. Object goal navigation using goal-oriented semantic exploration[J]. Advances in Neural Information Processing Systems, 2020, 33: 4247-4258.
- [34] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [35] YU J, JIANG Y, WANG Z, et al. Unitbox: An advanced object detection network[C]//Proceedings of the 24th ACM international conference on Multimedia. 2016: 516-520.
- [36] Hello Robot Inc. Stretch 2 Mobile Manipulator[EB/OL]. 2026. <https://hello-robot.com/stretch-2>.
- [37] ANDERSON P, CHANG A, CHAPLOT D S, et al. On evaluation of embodied navigation agents [J]. arXiv preprint arXiv:1807.06757, 2018.
- [38] YADAV K, MAJUMDAR A, RAMRAKHYA R, et al. Ovrl-v2: A simple state-of-art baseline for imagenav and objectnav[J]. arXiv preprint arXiv:2303.07798, 2023.
- [39] XIA F, ZAMIR A R, HE Z, et al. Gibson env: Real-world perception for embodied agents[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 9068-9079.
- [40] CMU Robot Autonomy Lab. LoCoBot: An Open Source Low Cost Mobile Manipulator[EB/OL]. 2026. <http://www.locobot.org/>.