

班 级 2120012
学 号 21009200950

西安电子科技大学

本科毕业设计论文



题 目 基于无监督域适应的图像分类方法研究

学 院 人工智能学院

专 业 智能科学与技术

学生姓名 王锦瑶

导师姓名 郭雨薇

摘 要

伴随人工智能与深度学习技术的不断进步，图像分类任务在遥感、医学影像等多个领域得到了广泛应用。然而，传统深度模型在面对源域与目标域存在显著分布差异的跨域任务时，往往会出现性能大幅下降的问题，难以在新环境下保持良好的泛化能力。无监督域适应方法通过引入无标签的目标域数据，实现对深度模型的迁移与优化，已成为当前研究的热点方向。

针对现有方法在对齐层次单一、迁移效果有限等问题，本文采用了一种多层次无监督域适应方法。该方法从图像级、特征级和逻辑级三个层面对域间分布差异进行逐步建模与优化，力求实现更加细致、稳定的跨域迁移。在图像级层面，结合 Gamma 校正与颜色直方图匹配策略，统一源域与目标域图像的亮度与色彩风格，减少成像条件差异对后续特征提取的干扰；在特征级层面，引入多分支交叉注意力机制，有效增强源域与目标域高阶语义特征之间的信息交互，提升特征表达的一致性与鲁棒性；在逻辑级层面，结合监督对比学习与局部最大均值差异优化策略，在提升类内聚合性的同时增强类间可分性，从而进一步优化模型在输出空间的判别能力。

本文在 Houston、Pavia 和 Shanghai-Hangzhou 三个具有代表性的高光谱跨场景数据集上开展了系统实验。实验结果表明，所提出方法在总体分类准确率、平均分类准确率与 Kappa 系数等关键评价指标上均优于现有主流无监督域适应方法，具有良好的泛化能力与稳定性。

关键词：多层次域适应 高光谱图像分类 图像风格对齐 跨域特征交互
类别对齐优化

ABSTRACT

With the continuous advancement of artificial intelligence and deep learning technologies, image classification has been widely applied in various fields such as remote sensing and medical imaging. However, traditional deep learning models often experience significant performance degradation when faced with cross-domain tasks involving considerable distribution differences between the source and target domains, making it difficult to maintain good generalization in new environments. Unsupervised domain adaptation addresses this challenge by leveraging unlabeled data from the target domain to transfer and optimize models, and has become a prominent research focus.

In response to the limitations of existing approaches, such as insufficient alignment granularity and limited adaptation effectiveness, this thesis proposes a multilevel unsupervised domain adaptation method. The proposed method progressively models and reduces the domain discrepancy at three levels: image level, feature level, and logic level, aiming to achieve more comprehensive and stable cross-domain transfer. At the image level, Gamma correction and color histogram matching are employed to align the brightness and color style of source and target domain images, thereby mitigating the impact of imaging variations on feature extraction. At the feature level, a multi-branch cross-attention mechanism is introduced to enhance the interaction of high-level semantic features between domains, improving feature consistency and robustness. At the logic level, the method integrates supervised contrastive learning with local maximum mean discrepancy to increase intra-class compactness and inter-class separability, further enhancing the model's discriminative ability in the output space.

The proposed approach is evaluated on three representative cross-scene hyperspectral datasets: Houston, Pavia, and Shanghai-Hangzhou. Experimental results show that the method achieves higher overall accuracy, average accuracy, and Kappa coefficient compared to existing mainstream unsupervised domain adaptation methods, demonstrating strong generalization performance and stability.

Keywords: Multilevel Domain Adaptation Hyperspectral Image Classification
Image Style Alignment Cross-domain Feature Interaction Category-

level Alignment

目 录

第一章 引言	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 本文主要工作与内容安排	3
第二章 无监督域适应方法	5
2.1 无监督域适应方法概述	5
2.2 特征对齐技术	6
2.3 对抗训练与对比学习方法	7
2.4 本章小结	8
第三章 基于多层次无监督域适应的图像分类方法介绍	9
3.1 多层次无监督域适应方法框架介绍	9
3.2 图像级域适应	11
3.2.1 Gamma 校正	11
3.2.2 颜色直方图匹配	12
3.2.3 引导滤波	14
3.3 特征级域适应	15
3.4 逻辑级域适应	17
3.4.1 监督对比学习机制	18
3.4.2 局部最大均值差异方法	19
3.5 损失函数与优化策略	21
3.6 本章小结	22
第四章 模型实现与实验验证	25
4.1 实验数据与平台环境	25
4.1.1 数据集介绍	25
4.1.2 实验环境与平台配置	27
4.2 模型结构与训练设置	28
4.2.1 网络结构与核心模块	28
4.2.2 超参数与训练设置	29

4.3	实验结果与性能分析	30
4.3.1	不同数据集的分类效果评估	30
4.3.2	与主流方法对比实验	31
4.3.3	消融实验分析	33
4.4	本章小结	35
第五章	总结与展望	37
5.1	本文工作总结	37
5.2	研究不足及未来展望	38
致谢		39
参考文献		41

第一章 引言

1.1 研究背景与意义

伴随人工智能及互联网技术不断向前推进，机器学习特别是深度学习在社会与生产当中所起的作用越发突出，不过，即便深度学习较之于传统机器学习方法而言，其性能方面存在很大的优势，但要想训练出深度学习方法的模型，则必须要有大量标注数据给予支撑，否则模型的泛化能力就会受到极大影响^[1]。所以说，怎样去应对模型对于标注数据资源过度依赖这个难题，便成了深度学习向前迈进时所遇到的一个核心课题^[2]。

实际应用场景下，尤其是要解决新领域任务的时候，获得大量带标注的数据往往不太可行，怎样才能有效地借助那些已经被标注过的、和新领域任务类似的数据集，把学到的知识迁移过去，这成了深度学习里亟待解决的一大难题^[3]。不过，深度学习方法依靠的是训练集和测试集上相互独立且服从同一分布的前提条件，但不同数据集中，比如已有的数据集（源域）和新领域的数据集（目标域），可能存在数据分布差异，也就是域偏移现象。域偏移属于深度学习当中比较常见的一类状况，这违背了训练集（源域）和测试集（目标域）之间应具备独立同分布的假设。许多深度学习方法往往忽视了实践中经常遇到的分布外泛化问题，即模型在训练数据以外的数据上进行预测时，由于模型没有这些新数据的数据分布经验，所以无法正确地进行预测。换句话说，一个在源域上训练的模型，在目标域上进行评估时，性能会显著下降，即使源域和目标域之间只有很小的变化^[4]。

本课题研究是在无监督域适应的图像分类方法的基础上进行的，域适应的提出是为了解决由于域偏移导致的模型泛化能力下降的问题。由于目标域数据难以获得标签，所以又提出了无监督领域自适应（Unsupervised Domain Adaptation, UDA），它通过在目标域中收集无标签数据来调整源域训练的模型，从而通过将源域和目标域的分布对齐来避免域偏移。域适应的目标是在源域和目标域的联合分布概率不同情况下，利用源域数据和未被标记的目标域数据来训练一个模型，使得这个模型能够在目标域数据上表现得比较好。目前无监督域适应问题中的主流方法都是以源域和目标域数据分布对齐为目标，原本存在数据分布差异的源域和目标域数据，在域适应后分布对齐，然后进行迁移。

1.2 国内外研究现状

在传统的图像分类任务中，深度学习模型常常依靠大量人工标注的数据来实现良好的分类效果。但是在实际场景当中，目标域的数据往往很难得到精准的标签，所以把从源域训练好的模型直接移到目标域的时候就会遭遇显著的性能下滑，这种状况被称作“域偏移”。为了解决这一挑战，无监督域适应（Unsupervised Domain Adaptation, UDA）方法便应运而生。其主要目的就是在没有目标域标签的情形下，凭借源域带有标签的数据，通过特征对齐、对抗学习这些方法，来训练出具有跨域泛化能力的分类模型^[5]。近些年来，伴随着深度神经网络不断发展，UDA 慢慢成为了图像识别、医学诊断、高光谱图像处理这些领域里的研究热门话题^[6]。

无监督域适应方法发展主要包含以下几类策略：第一类是特征对齐的方法，代表性的如最大均值差异（Maximum Mean Discrepancy, MMD）和局部最大均值差异（Local Maximum Mean Discrepancy, LMMD）等^[7]，通过最小化源域与目标域的统计分布差异来完成域迁移；第二类是基于对抗学习的方法，如 Domain-Adversarial Neural Network（DANN），通过利用域分类器与特征提取器的对抗来提取域不变特征^[8]；第三类是基于对比学习的策略，监督对比学习（Supervised Contrastive Learning, SCL）就是这一类方法的代表，它能够增强同类样本的聚合性和异类样本的可分性，从而提升模型的判别能力。近年来，为了处理源域数据不可访问或者标签空间不一致等更加复杂的场景，研究人员也提出了一些新的方法，如伪标签蒸馏、多源迁移、标签预测引导等^[10,11]。在高光谱图像分类任务中，国内外学者将域适应和光谱空间特征融合、自注意力机制和多尺度卷积网络等技术结合起来，促进了该领域的实用化发展^[12]。

前人的研究中有一些成果是比较有代表性的，比如 Long 等人提出的 DAN 网络，该网络将 MMD 引入到了深度特征空间当中，实现了在多个核函数下的分布对齐；Ganin 等人设计的 DANN 方法则借助对抗手段来提取领域不变特征，这成为了后续对抗性 UDA 方法的典范；在多标签场景下，Singh 等人提出了一种无判别器的对抗方法^[13]，利用 Frechet 距离去衡量源目标分布之间的差别，进而简化了模型结构^[12]。Li 等在医学图像领域提出了多源域桥接的方法，在癌症病理分类任务中大大提升了迁移性能；Cai 等提出了多层级域适应框架^[13]，在图像级风格对齐、特征级交叉注意力机制和逻辑级对比损失与 LMMD 联合优化的思路下，在多个跨场景数据集上取得了较好的结果。

尽管现有研究取得显著进展，无监督域适应仍面临诸多挑战。首先，目标域的样本类别通常会存在不均衡现象，这使得伪标签的质量无法得到保证，从而影响到模型的性能，在伪标签所引导的模型训练过程中，标签误差可能会不断积累，造成“误差扩散”问题^[14,17]。第三，不同场景间存在较大光谱与空间结构差异，传统的对齐方式很难适用于跨场景的环境当中，这极大地限制了模型的泛化能力^[15,16]。第四，当源域的数据不能被访问的时候，如何才能依靠源模型实现对目标域的有效学习^[18]。第五，目前的方法在对抗训练或者多任务融合时计算量比较大，很容易出现训练不稳定的情况。在通用域适应的情况下，由于源域和目标域的标签集并不完全相同，因此如何识别并利用公共标签，防止发生负迁移，这也是需要研究者们解决的核心问题。

本课题围绕这些问题展开，旨在找到一种既适应性强又稳定的多层级无监督域适应图像分类办法，借助多分支网络，对比损失，局部分布度量这些机制来改进模型的迁移能力以及分类精确度。

1.3 本文主要工作与内容安排

本论文围绕无监督域适应在图像分类中的应用展开研究，就传统方法在跨域分类任务里所存在的诸如特征分布对齐不足、模型泛化能力受限之类的问题，采用了一种多层级无监督域适应（Multilevel Unsupervised Domain Adaptation, MLUDA）的方法。文章的主要工作与内容概括如下：

首先针对源域与目标域在成像条件、光谱特性及空间结构等方面存在明显差异的情况，在图像层面上设计了基于引导滤波的图像级域适应模块（Guided Principal Component Gamma Correction and Histogram Matching, GuidedPGC），以引导源域图像与目标域图像在风格上的统一，从而减少由于光照和成像差异导致的域偏移。其次在特征层面上采用了多分支交叉注意力机制（Multibranch Cross-Attention, MBCA），有效加强了源域和目标域深层特征之间的信息交互，提高了跨域特征提取的鲁棒性。同时在逻辑输出层引进了监督对比学习（Supervised Contrastive Learning, SCL）和局部最大均值差异（Local Maximum Mean Discrepancy, LMMD）的联合优化来进一步提升不同类别的可分性以及模型在无标签目标域上的判别能力。为了验证本文采取的方法的有效性，本文在多个跨场景的高光谱图像数据集（Houston、Shanghai-Hangzhou、Pavia）上进行了大量的实验，实验结果表明本文采用的方法在分类准确率和跨域泛化性能上都优于目前主流的域适应方法。

论文的结构安排如下：

第一章引言部分概述了本课题的研究背景与意义，介绍了无监督域适应的基本概念及其在图像分类任务上的应用价值，确定了本论文的研究目标与主要工作。

第二章对无监督领域适应相关的研究工作进行了梳理。首先总结了主流的无监督域适应方法的种类及特性；然后着重叙述特征对齐技术（如最大均值差异与局部最大均值差异）在特征分布对齐中的应用；再阐述对抗训练、对比学习于无监督域适应当中的关键地位；最后回顾了高光谱图像分类的研究现状及其在域适应任务中的困难和挑战。

第三章详细介绍了 MLUDA 方法。首先介绍了整体的多层级适应框架；然后从图像级域适应、特征级域适应以及逻辑级域适应三个方面展开介绍：在图像级域适应方面，采用 Gamma 校正、颜色直方图匹配、引导滤波等策略，减少源域和目标域在图像风格上的差异；在特征级域适应方面，引入多分支交叉注意力机制（MBCA），增强源域和目标域特征之间的信息交互；在逻辑级域适应方面，结合监督对比学习（SCL）和局部最大均值差异（LMMD）方法，提高特征空间中的类别区分性和域间对齐效果。

第四章详细阐述了模型的实现过程及实验部分。包含所用数据集（Houston、Pavia、Shanghai-Hangzhou）介绍、实验环境与平台配置、模型结构及训练参数设置、损失函数设置及优化、大量实验结果及分析等，其中有不同数据集下各个性能指标的评价结果；消融实验以分析各个模块的有效性；与主流无监督域适应方法的性能比较体现出本文采用方法的优势；通过分类图可视化来对模型的迁移效果进行解读等。

第五章对全文工作进行了总结，提出当前方法的不足之处，并对未来的工作进行了展望，展望了在源自由设定^[19]、多源域适应、轻量化模型设计等方面的进一步研究计划。

第二章 无监督域适应方法

2.1 无监督域适应方法概述

无监督域适应 (Unsupervised Domain Adaptation, UDA) 目的在于借助源域 (有标签数据) 和目标域 (无标签数据) 执行模型训练, 从而让模型在目标域上获取较好的分类效果。源域与目标域存有数据分布方面的差别, 若直接予以迁移, 经常会造成模型性能大幅下滑, 所以设计出有效的适应策略来缩减这种分布差距就成了研究的重点所在。按照适应策略的不同, 当前已有的无监督域适应方法大概能分成以下几种类型:

(1) 实例重加权方法

实例重加权方法通过给源域样本赋予不同的权重, 来减小源域和目标域样本分布之间的差距^[20]。这一类方法通常根据源域样本与目标域样本的相似性来调整权重, 使得源域中更有代表性的样本对模型训练的影响更大, 从而在目标域上表现更好。典型代表方法有基于重要性采样的重加权策略和基于和核均值匹配的重加权策略。

(2) 特征对齐方法

特征对齐方法的主要思路就是通过学习源域和目标域之间的共享特征表示, 使得不同域的特征分布差距变小。这类方法一般在特征提取过程中引入对齐约束, 如最大均值差异 (MMD)、局部最大均值差异 (LMMD)、相关性对齐等方法, 强制源域与目标域特征在统计上趋同^[21]。还有一些方法利用生成对抗网络结构, 通过对抗的方式隐式实现特征空间的对齐^[8,17]。

(3) 对抗性训练方法

对抗性训练方法利用域判别器与特征提取器之间的对抗机制, 促使特征提取器学习到不可被域判别器区分的源域与目标域的特征表示。其中代表性的方法有 Domain-Adversarial Neural Network (DANN)^[22], 在训练时利用梯度反转层完成特征提取器与域分类器的对抗训练, 从而获得域不变的特征, 提高模型在目标域的适应性。

(4) 伪标签与自训练方法

伪标签方法在无目标域真实标签时, 利用模型对目标域样本的预测结果做伪标签, 再将其用作进一步训练。这种自训练方式可不断改善目标域样本的分类边

界,进而提升模型在目标域的表现。为使伪标签更可靠,常采用置信度阈值、样本筛选、教师-学生网络等策略^[17,23]。

(5) 对比学习方法

对比学习方法通过对同类样本的特征表示进行拉近,对异类样本的特征表示进行拉远,从而增强特征的表征能力,使得源域和目标域的特征空间更加一致^[24]。监督对比学习(Supervised Contrastive Learning, SCL)和自监督对比学习均已被应用于无监督域适应任务中,尤其是在小样本或无标签情况下,取得了较好的迁移效果。

不同类别的方法在实际应用中各有优势,实例重加权方法适用于分布差异较小的情形,特征对齐方法适用于中等程度的分布差异,对抗训练和对比学习方法在大尺度分布差异或者复杂跨域场景中有更好的适应效果。为了更好地发挥各类方法的优势,近年来也有研究者提出结合多种策略的混合方法,来进一步提高无监督域适应的效果。

2.2 特征对齐技术

无监督域适应任务中,由于源域与目标域的数据分布不一致,直接把源域上训练好的模型用到目标域时,往往导致性能严重退化。于是特征对齐技术被提出,其目的是为了学习域不变特征或者最小化源域与目标域特征分布之间的差异,从而提高模型的跨域迁移能力。特征对齐方法通常作为域适应框架中的主要组成部分,贯穿于特征提取和分类决策的过程中。

最大均值差异(Maximum Mean Discrepancy, MMD)属于最先被运用到无监督域适应当中的一种典型特征对齐方法。MMD会在再生核希尔伯特空间里衡量源域和目标域特征的分布均值之差,以此来度量两个域之间的统计距离^[25]。详细来说,MMD指的是源域样本均值和目标域样本均值在高维特征空间中的欧式距离,若想让源域和目标域在特征空间中的分布更为相近,便要尽量减小MMD的值。基于MMD的深度自适应网络在多个域适应任务上收获了较好的成果,这表明特征均值对齐对于迁移学习十分有效。

但是,传统的MMD方法仅仅着眼于全局均值的对齐,忽视了类别条件分布的细粒度差异。针对这个问题,局部最大均值差异(Local Maximum Mean Discrepancy, LMMD)被提出来。LMMD既考虑到全局分布的一致,又纳入了类别标签信息,通过在各个类别内部各自把源域和目标域的均值差异减到最小,从而做到更为细致

的条件对齐。依靠类别级别的局部对齐，LMMD 可有效地规避类别混杂现象，改进分类界限的精准度，非常适合具有很大类内变动或者类别不均衡情况的跨领域任务。

实际应用中，MMD 与 LMMD 常作为正则化项与分类损失共同优化形成端到端的训练过程。特别是高光谱图像分类、医学影像分析等较为复杂的场景下，结合特征对齐的域适应方法能够展现出更佳的稳定性和泛化能力^[26]。另外近年来也有一些研究把 MMD 同对抗训练、对比学习等策略结合起来使用以获得更好的域对齐效果。

综上可得，特征对齐技术属于无监督域适应里的基础手段，其在缩减源域与目标域特征分布差异以及改善跨域迁移性能上均有着重要意义。伴随研究不断推进，怎样在维持类内判别力的情况下做到高效而细致的特征对齐，依旧是日后无监督域适应领域的关键研究点。

2.3 对抗训练与对比学习方法

无监督域适应中除了传统特征对齐策略外，对抗训练与对比学习方法也逐渐成为提升跨域迁移性能的重要手段^[27]。二者分别从不同角度出發，在域不变特征提取与特征判别能力增强方面发挥着关键作用。

对抗训练方法主要是通过构建一个域判别器和一个特征提取器之间的博弈过程^[8]，让特征提取器学习到能够迷惑源域和目标域判别的共享特征表示。其中 Domain-Adversarial Neural Network (DANN)^[28] 是对抗性域适应的典型代表。DANN 引入了梯度反转层，在训练时将域判别损失反向传播给特征提取器，使得特征提取器学习到的特征能够被域判别器无法区分。通过这种方式，源域和目标域的特征在高层表征空间中实现了对齐，从而提升了模型在目标域上的泛化能力。这种对抗性方法的适应性比较灵活，可以应对复杂的分布差异，但是也存在着训练不稳定、难以收敛的问题^[9]。

对比学习方法则利用正负样本对来提高模型对不同类别特征的判别能力，在无监督域适应中，尤其是在没有目标域标签时，监督对比学习 (Supervised Contrastive Learning, SCL) 成为了一种有效的补充手段^[13]。SCL 通过拉近同一类别样本间的特征距离，拉远不同类别样本间的特征距离，进一步优化了特征空间的结构，提升了模型的类内聚合性和类间分离性。相比于传统的分类损失函数（如交叉熵），对比学习可以更加明显地提升模型在目标域上的判别能力，尤其是当类别边界模糊

或伪标签存在噪声时的鲁棒性更高 [29]。

在实际应用中，很多先进的无监督域适应方法都会将对抗训练和对比学习结合起来，对抗训练可以做到源域和目标域之间的域对齐，而对比学习则能改善目标域样本之间的类别结构，二者互相补充，从而有效地提升了整体的迁移性能，在高光谱图像分类、医学图像分析等领域，对抗性域适应与对比学习的结合成为了提高跨域分类精度的新趋势^[9,30,31]。

综上，对抗训练与对比学习在无监督域适应当中各自从域对齐和特征判别角度出发，给出了有效的迁移手段，后续研究可以深入探寻两者之间的协同改良机制，从而做到更为稳固，高效的跨域转移效果。

2.4 本章小结

本章系统梳理了无监督域适应的核心概念与研究现状，明确了其在缓解源域与目标域数据分布差异、提升模型跨域泛化能力方面的重要作用。围绕当前主流的无监督域适应方法，重点介绍了特征对齐、对抗训练和对比学习等多种策略的代表性工作，并分析了各类方法在处理不同类型跨域任务中的优势与不足。此外，针对高光谱图像在跨场景分类中所面临的高维冗余、空间变化显著等挑战，进一步引入了本文后续实验将采用的关键技术，包括最大均值差异（MMD）及其变体、监督对比学习（SCL）、对抗性域判别机制等。这些方法分别从特征空间分布对齐、类内聚合与类间可分性增强、以及域判别对抗学习等角度，为构建更加鲁棒、可迁移的域适应模型提供了理论工具与方法支撑。本章不仅为理解无监督域适应的研究基础提供了全面参考，也为后续多层级域适应模型的设计与实现奠定了理论支撑和技术基础。

第三章 基于多层级无监督域适应的图像分类方法介绍

无监督域适应（UDA）在图像分类领域已经取得显著进展，但在高光谱图像分类任务中仍然面临诸多挑战。一方面，高光谱图像含有大量连续波段信息，数据维度高，冗余度大，造成源域和目标域之间的特征分布差异更为复杂。另一方面，受不同场景下成像条件，传感器特性以及环境改变的影响，高光谱数据在各个域之间存在明显的光谱偏移和空间结构差异，传统浅层对齐方法的效果受到限制。且由于目标域样本缺乏标签，怎样在维持特征可判别性的同时做到有效迁移，这是当下无监督高光谱分类研究的关键之处。

3.1 多层级无监督域适应方法框架介绍

针对上述问题，本文采用多层级无监督域适应（Multilevel Unsupervised Domain Adaptation, MLUDA）框架，旨在通过图像级、特征级和逻辑级三重对齐策略来系统地缩减源域与目标域在各个层次上的分布差异，进而加强模型在目标域中的泛化能力及其分类准确度。整体框架如图 3.1 所示，MLUDA 方法通过多模块协同优化，分阶段逐步减少域偏移。




图 3.1 MLUDA 整体流程图

在图像级域适应阶段，MLUDA 首先通过引导滤波辅助的图像对齐方法，对源域图像进行光照与色彩调整。具体而言，首先应用 Gamma 校正调整源域与目标域的亮度分布，弥合两域成像条件带来的整体亮度偏差；随后采用颜色直方图匹配方法对源域图像的颜色分布进行修正，使源域样本在色彩空间中更接近目标域样本，从而减少颜色域的统计差异；最后，利用引导滤波进一步在局部区域对源域图像进行平滑处理，强化图像的局部结构一致性，降低细粒度层面的域间差异。通

过这一系列图像预处理步骤，可以有效减少后续特征提取阶段由于底层感知偏差引起的特征分布漂移，为特征级对齐打下坚实基础。

特征级域适应阶段设计了多分支交叉注意力机制 (Multibranch Cross-Attention, MBCA)，以充分挖掘源域与目标域高阶特征之间的相关性。具体地，MLUDA 分别构建源域特征提取分支与目标域特征提取分支，两者在提取各自领域特征后，通过交叉注意力模块进行信息交互与融合。交叉注意力机制通过点积操作计算源域特征与目标域特征的相关性矩阵，根据相关性动态加权更新特征表示，从而在特征空间层面实现显式对齐。这种设计不仅能够促进共享特征的提取，还能够抑制领域特定噪声，提升特征表征的一致性和判别性。相比传统直接对齐特征均值的方法，多分支交叉注意力能够捕捉到更加细粒度的语义对应关系，提升跨域迁移的鲁棒性。

逻辑级域适应阶段进一步通过监督对比学习 (Supervised Contrastive Learning, SCL) 与局部最大均值差异 (Local Maximum Mean Discrepancy, LMMD) 联合优化，强化特征空间的类别结构。监督对比学习通过构建正负样本对，最大化同类样本间的相似度，最小化异类样本间的相似度，从而在特征空间内形成清晰的类别簇结构。该机制有效提升了类别区分性，特别是在目标域缺乏真实标签、伪标签可能存在噪声的情况下，仍能维持良好的判别性能。同时，为进一步减少源域和目标域在类别分布上的偏差，MLUDA 在损失函数中引入局部最大均值差异 (LMMD) 约束。与传统的全局 MMD 不同，LMMD 在类别层面分别计算源域和目标域同类样本特征的均值差异，细粒度地进行类别条件对齐，避免了类别混叠现象，提升了迁移后分类决策的一致性和准确性。

在训练流程上，MLUDA 采用端到端的多任务联合优化策略。总体损失函数由三部分组成：分类损失确保源域监督学习的正确性；对比损失优化特征空间的类内聚合性与类间分离性；域对齐损失缩小源域与目标域在类别条件下的特征分布差异。训练过程中，分别在图像输入阶段进行预处理增强，在特征提取阶段通过交叉注意力融合域间信息，在输出决策阶段通过对比学习与局部分布对齐进一步细化优化，从而实现逐层、逐步、全局到局部的多层次域适应。

总体来看，MLUDA 方法从感知层、表示层到决策层全面考虑了源域与目标域之间的差异性问题，通过引入多层次、细粒度的对齐策略，显著缓解了传统无监督域适应方法在高光谱图像跨场景分类中的性能瓶颈。实验结果表明，MLUDA

在多个公开高光谱数据集上均取得了优异的跨域分类性能验证，展现了良好的适应性与泛化能力，为高光谱图像领域的无监督域适应研究提供了一种新的思路与方法参考。

3.2 图像级域适应

为减少源域和目标域图像在成像条件、光照环境、色彩风格等方面的偏差，本文在图像预处理阶段设计了基于引导滤波的图像级域适应方法。方法流程具体如图 3.2 所示，通过对源域图像进行系列物理层面的风格对齐，降低底层感知特性上的域间差异，为后续特征提取和高阶表征对齐提供稳定一致的输入基础。其主要包含 Gamma 校正、颜色直方图匹配和引导滤波三个步骤。




图 3.2 图像级域适应流程

3.2.1 Gamma 校正

在自然成像过程中，不同设备（如航拍传感器、地面光谱仪等）受到曝光条件、感光器件响应曲线、环境光照变化等因素影响，即使是同一地物，也可能在源域和目标域中呈现出明显不同的亮度特性。这种亮度偏差会导致同一类别样本在输入空间的分布发生偏移，增加特征提取器在训练过程中的负担，不利于后续域间对齐。因此，本文在图像级域适应阶段首先引入了 Gamma 校正操作，以统一源域与目标域图像的亮度分布特性。

Gamma 校正是一种非线性灰度映射方法，通过对图像像素值施加幂律变换，使得图像整体亮度向指定标准调整。设输入图像像素值为 I_{in} ，经过 Gamma 校正

后的输出像素值 I_{out} 可表示为:

$$I_{\text{out}} = I_{\text{in}}^{\gamma} \quad (3-1)$$

其中, γ 为 Gamma 值参数, 控制校正的幅度。当 $\gamma < 1$ 时, 图像整体亮度增强; 当 $\gamma > 1$ 时, 图像整体变暗。通过合理选择 Gamma 值, 可以弥合源域与目标域在平均亮度上的差异。

在本方法中, 先计算源域图像和目标域图像各自的平均亮度值 L_S 和 L_T , 然后根据源域图像和目标域图像的平均亮度比值自适应地设置源域图像的校正 Gamma 值, 其计算公式为:

$$\gamma = \frac{\log(0.5)}{\log(L_S)} \quad (3-2)$$

其中 L_S 是归一化后的源域平均亮度。校正之后, 源域图像的亮度分布向目标域靠拢, 从而大大缩减了因为光照情况改变而引发的域间感知差别

实验表明, 经过 Gamma 校正处理后, 源域图像整体亮度均值与目标域更接近, 亮度动态范围被合理地压缩, 为后续颜色分布对齐、特征提取等工作提供了良好的基础。由于 Gamma 校正只是对像素值进行简单的非线性变换, 并没有改变图像的空间结构以及局部纹理信息, 所以也不会引入新的伪影和噪声, 从而保持了图像内容的一致性和可用性。

要注意的是, 在实际运用中, 为防止过度校正带来的信息损耗或者视觉失真现象, 本文在 Gamma 校正之后加入了归一化步骤, 把图像像素值重新缩放到 $[0, 1]$ 这个范围内, 以此保证输入给网络的数据稳定不变。为了应对不同目标域样本的亮度分布情况, 本方法采用逐个样本动态调整 Gamma 值的做式, 而不是用固定的数值, 从而增强了此法在各类跨域场景下的适应灵活度。

综上, Gamma 校正作为 MLUDA 图像级域适应流程的第一步, 有效削减了源域和目标域之间在整体光照方面的感知差异, 使得输入的数据更为一致, 从而给后续的颜色匹配以及特征提取奠定了稳固基础。

3.2.2 颜色直方图匹配

尽管 Gamma 校正能够在一定程度上对源域和目标域图像的整体亮度分布进行初步统一, 但实际应用中由于成像设备性能差异、采集环境变化、后处理流程的不同, 仍然会造成源域和目标域图像在颜色、风格上的巨大差异。特别是对于高光谱图像分类任务而言, 不同场景下同一类别地物的光谱反射特性存在较大差异, 导致高维光谱特征空间中分布差异进一步扩大。这种颜色、风格差异会直接导致

后续特征提取过程中的特征差异，导致模型在目标域上泛化性能下降。仅依靠亮度统一处理尚不能实现有效的跨域适应，还需要在颜色统计上做细致对齐。

为了实现这一目标，本文在 Gamma 校正基础上又加入了颜色直方图匹配技术，希望可以在细粒度上对源域图像的颜色分布进行调整，使源域图像颜色分布更符合目标域在颜色空间中的统计特性。颜色直方图匹配是一种经典的基于统计分布调整的方法，通过对源域和目标域颜色直方图的分析，建立像素值映射关系，从而使得源域图像的颜色分布尽可能的接近目标域。

设源域图像像素分布为 P_S ，目标域图像像素分布为 P_T ，颜色直方图匹配的目标是寻找一个单调递增的连续映射函数 $f(\cdot)$ ，使得：

$$P_T(f(x)) = P_S(x) \quad (3-3)$$

为此，通常通过源域与目标域的累积分布函数（Cumulative Distribution Function, CDF）来构建映射关系。设 $C_S(x)$ 和 $C_T(x)$ 分别为源域和目标域的累积分布函数，则映射关系可写为：

$$f(x) = C_T^{-1}(C_S(x)) \quad (3-4)$$

也就是说，对于源域中的每一个像素值，首先根据 C_S 计算其累积概率值，然后通过目标域 C_T 的逆函数查找对应的像素值，从而完成像素级别的映射。这一过程确保了源域图像经过变换后，其像素分布在统计上与目标域图像接近，从而实现了颜色层面的域对齐。

颜色直方图匹配的一般流程包括以下几个步骤：

- 对源域图像和目标域图像分别计算每个颜色通道（或主成分通道）的直方图，并归一化为概率密度函数。
- 计算各自的累积分布函数（CDF）。
- 对于源域图像的每一个像素值，查找其在源域 CDF 中的累计概率，然后在目标域 CDF 中找到具有相同累计概率的像素值，即完成像素映射。
- 将映射后的像素值重新组合成新的源域图像，完成颜色匹配。

需要注意的是，高光谱图像数据通常维度极高，直接在所有光谱波段上进行直方图匹配会导致计算复杂、映射精度不足且容易引入噪声。因此，本文首先对高光

谱数据采用主成分分析进行降维处理，仅保留前几个主成分通道（如前三个主成分），然后在降维后的主成分空间内执行直方图匹配操作。

在具体实现中，本文采用逐通道匹配策略，即分别对每一个主成分通道独立执行直方图匹配操作。这样既可以更好地适应各个主成分通道特有的分布特性，又避免了多通道联动匹配中可能出现的配准误差。此外，为避免极端值影响映射质量，在直方图计算过程中引入了裁剪处理，将像素值范围限制在主分布区域内，从而提升了匹配的鲁棒性。

实验结果表明，经过颜色直方图匹配处理后，源域图像在颜色风格上的整体分布与目标域更加一致，视觉上源域图像的色调、亮度、对比度特性与目标域趋于统一。定量分析也显示，经过 Gamma 校正与颜色直方图匹配联合处理的图像，在后续特征提取阶段，其域间分布距离显著缩小，跨域分类性能得到明显提升。

通过在图像级域适应中引入颜色直方图匹配，有效弥补了传统亮度统一方法无法消除的深层风格偏差，进一步提升了 MLUDA 框架整体的域适应能力和模型在目标域的泛化效果。

3.2.3 引导滤波

经过 Gamma 校正和颜色直方图匹配后，源域和目标域图像在亮度和颜色分布上已经取得一定的相似度，但是仍然存在局部结构细节上的差异状况，诸如纹理强度，边缘平滑性等，这些细粒度的差异在高光谱图像当中特别突出。局部细节上的差别很可能会致使特征提取器在不同域中学习不一致的局部特征表示，从而影响到分类决策的稳定性和正确性，所以，在图像级别上的域适应过程当中，还需要进一步细致地处理，以改善源域与目标域在局部结构方面的一致性。

故此，本文采用引导滤波方式。引导属于依靠局部线性模型的有效边缘保存过滤器，可以在使图像变得平滑的时候保存明显的边缘信息。该方法被普遍用于图像加强，降噪以及细节保护等工作当中，其主要思路在于：在局部窗口范围内，假定输出图像是引导图的线性转换，也就是：

$$q_i = a_k I_i + b_k, \quad \forall i \in \omega_k \quad (3-5)$$

其中， q_i 表示输出图像的像素值， I_i 表示引导图像像素值， ω_k 表示以像素 i 为中心的局部窗口， a_k 与 b_k 为线性系数，在每个窗口中独立估计。

通过最小化以下代价函数求解最优参数：

$$E(a_k, b_k) = \sum_{i \in \omega_k} ((a_k I_i + b_k - p_i)^2 + \epsilon a_k^2) \quad (3-6)$$

其中， p_i 是输入图像像素值， ϵ 是正则化参数，用于平衡拟合精度与模型复杂度。

本文方法中，源域图像经过 **Gamma** 校正与颜色直方图匹配后，再以目标域图像作为引导图，利用引导滤波对源域图像进行局部结构校正。其中，源域图像作为被滤波图像，目标域图像作为引导图，利用引导滤波使局部纹理特性向目标域靠拢，减小局部细粒度的域间差异。

本研究中引导滤波的优势体现如下：

- 边缘保持性：在对图像进行平滑处理时能够自适应地保留显著边缘信息，避免模糊语义边界，使得地物的轮廓清晰；
- 内容感知性：利用引导图调控滤波强度，使源图像局部纹理更贴近目标域；
- 高效计算性：引导滤波具有线性时间复杂度，适用于大规模高光谱图像处理。

本文采用快速引导滤波算法来优化局部均值、方差等统计量的计算速度，并对滤波窗口大小及正则化参数进行调优，从而保证在 **Houston**、**Pavia** 和 **Shanghai-Hangzhou** 等数据集上都能获得稳定、良好的局部对齐效果。

实验结果表明，经过引导滤波的源域图像在局部结构特性上与目标域更加接近，图像纹理的一致性更高，边缘细节更加清晰，整体风格与目标域更加协调。并且通过 **t-SNE** 特征可视化分析发现，经过引导滤波的源域样本在特征空间中的聚类更接近于目标域，从而提升模型的判别能力以及跨域分类效果。

综上，引导滤波作为图像级域适应中的最后一步，从局部结构层面细化了源域与目标域的一致性，显著增强了多层级域适应模型的整体效果。

3.3 特征级域适应

在实际应用中，传统的特征对齐方法，如最大均值差异（**Maximum Mean Discrepancy**, **MMD**）、局部最大均值差异（**Local Maximum Mean Discrepancy**, **LMMD**）等，虽然能够在统计意义上拉近源域与目标域特征的全局分布，但往往忽略了源域与目标域样本之间的局部语义对应关系，无法捕获细粒度的跨域特征交互信息，导致特征对齐过程存在一定的局部偏差。此外，高光谱图像具有极高的维度和复

杂的光谱-空间联合分布特性，单纯依赖传统统计对齐方法，难以充分挖掘源域与目标域样本之间潜在的相互依赖关系和结构性信息。因此，亟需设计一种更加细致、动态、内容感知的特征对齐机制，以实现更有效的特征空间域适应。

针对上述挑战，本文在 MLUDA 框架中尝试了特征级域适应模块，基于多分支交叉注意力机制（Multi-Branch Cross Attention, MBCA）。MBCA 的设计思想是，充分利用注意力机制的动态权重建模能力，通过在源域与目标域特征之间建立显式的交互关系，引导源域特征与目标域特征在局部细粒度上进行有针对性的对齐与融合，具体流程如图 3.3 所示。不同于传统静态的分布对齐方法，MBCA 能够根据源域样本特征的语义内容，自适应地在目标域样本中寻找最相关的信息，并以动态加权的方式完成特征增强，从而有效提升跨域特征的一致性和判别性。

具体而言，MBCA 模块首先通过多分支网络对源域和目标域特征进行多尺度、多方向编码，捕获不同语义层次的特征表示；随后通过点积注意力机制，在源域查询特征与目标域键值特征之间建立跨域交互映射，动态感知和建模源-目标样本之间的细粒度对应关系；最后，通过残差连接与归一化融合原始特征与交互特征，形成更加域不变、具有判别性的最终特征表示。

为缓解特征退化问题，融合后的源域和目标域特征分别表示为：

$$F'_s = \text{Norm}(F_s + F_{\text{ext}}) \quad (3-7)$$

$$F'_t = \text{Norm}(F_t + F_{\text{src}}) \quad (3-8)$$

其中， $\text{Norm}(\cdot)$ 表示透特征维度的归一化操作，能够缓解梯度消失问题，加速模型收敛。




图 3.3 特征级域适应流程图

要着重指出的是，MBCA 采用了多分支并行交互策略，也就是各个分支分别执行源目标特征交互，再把各个分支的交互结果实施加权融合。这样做能很好地

利用多尺度特征信息，加强跨域适应的稳健性，规避单个尺度下出现的特征过拟合状况。融合策略用简单的加权平均法，其权重参数可经训练自动调节，从而适配于不同的数据集以及不同域之间存在差别的情况。

在实现细节上，MBCA 模块在注意力计算时，采用了减少特征维度、低秩近似等技术，有效控制了计算开销，同时保证了注意力分配的细粒度和准确性。源-目标交互注意力权重矩阵能够对模型的跨域适应行为进行解释，帮助分析域间特征关系，对模型可解释性研究具有一定的帮助。

借助多分支交叉注意力机制，MBCA 能够在特征空间层面实现动态、细粒度的域对齐，从而有效地填补传统全局分布对准方式存在的不足^[19,20]。实验数据显示，在 Houston、Pavia、SH2HZ 等诸多跨场景高光谱数据集中，利用 MBCA 模块之后，源域和目标域样本的特征分布更为相近，分类决策界限也更为清晰，模型针对目标域的分类准确率通常会优化 5% 及更多，这有力地证实了 MBCA 在无监督领域适应任务里具备有效性和通用性。

3.4 逻辑级域适应

无监督域适应任务中，即便图像级和特征级的对齐策略已从底层感知空间到高层特征空间逐步减小了源域和目标域之间的分布差距，可实际上还是会出现分类决策不一致的情况。因为源域和目标域在类别条件分布，样本边界特点以及伪标签噪音等方面依然存在不容忽视的差别，所以传统的特征级对齐手段常常不能保障在输出空间做到精准的迁移，进而使得模型在目标域上的分类表现有所下降，要想进一步优化跨域分类的准确度和稳定性，就需要在逻辑输出层加入细粒度的域适应机制。

针对上述问题，本文在 MLUDA 框架中设计了逻辑级域适应模块，结合了监督对比学习（Supervised Contrastive Learning, SCL）和局部最大均值差异（Local Maximum Mean Discrepancy, LMMD）两种方法，从输出层面对源域与目标域样本进行双重优化，具体流程图如图 3.4 所示。

逻辑级域适应不仅在优化特征分布的一致性方面发挥了重要作用，还有效地修正了由于伪标签噪声和跨域样本异质性引起的决策边界偏移问题。通过联合优化 SCL 损失和 LMMD 损失，逻辑层能够从结构建模（聚合-分离）和分布对齐（类别条件均值对齐）两个角度，全面提升源域与目标域样本在输出空间的一致性，从而显著增强模型在无标签目标域数据上的泛化能力。




图 3.4 逻辑级域适应流程图

在实际训练过程中，MLUDA 通过端到端联合优化，将逻辑级域适应与特征提取、分类预测无缝集成，确保各阶段的优化目标协同推进。实验结果表明，引入逻辑级域适应后，模型在多个跨场景高光谱数据集上的分类准确率均有明显提升，尤其在类别间界限模糊、样本分布复杂的目标域数据上，逻辑级优化带来的性能提升尤为显著。

综上，逻辑级域适应（SCL + LMMD）作为 MLUDA 框架的重要组成部分，完成了从输入层、特征层到输出层的全流程、多层次无监督域适应闭环，有效提升了跨域分类系统的整体性能与鲁棒性。

3.4.1 监督对比学习机制

在无监督域适应任务中，源域样本通常拥有真实标签，而目标域样本由于缺乏标签，需要依赖伪标签进行训练。然而，伪标签不可避免地存在一定程度的噪声，这种噪声容易导致模型学习到错误的分类决策边界，降低在目标域上的泛化性能。传统的交叉熵损失主要依赖于单一的硬标签监督，对于伪标签中的错误难以容忍，因此需要引入更加鲁棒的训练机制来缓解这一问题。

监督对比学习（Supervised Contrastive Learning, SCL）作为一种新兴的判别式学习方法，通过直接优化特征空间中样本之间的相对关系，强化了同类别样本之间的聚合和异类别样本之间的分离，有效提升了特征表征的判别性与鲁棒性^[9]。不同于交叉熵损失仅关注单点预测，SCL 在小批量内部通过构建正负样本对，显式

建模样本之间的结构性信息，从而提高了模型对于噪声标签的容错性，特别适用于无监督域适应任务中目标域伪标签噪声较大的情况。

SCL 的基本思想是，对于每一个样本，将与其同类的其他样本作为正样本集合，与其异类的样本作为负样本集合，通过拉近正样本距离、拉远负样本距离来优化特征空间结构。具体地，设小批量样本集合为 $\mathcal{B}$ ，对于其中的样本 x_i ，其正样本集合记为 $\mathcal{P}(i)$ ，所有正负样本的集合为 $\mathcal{A}(i)$ ，样本之间的特征相似度记为 $\text{sim}(z_i, z_j)$ ，则监督对比损失函数可定义为：

$$\mathcal{L}_{\text{SCL}} = \sum_{i \in \mathcal{B}} \frac{-1}{|\mathcal{P}(i)|} \sum_{p \in \mathcal{P}(i)} \log \frac{\exp(\text{sim}(z_i, z_p)/\tau)}{\sum_{a \in \mathcal{A}(i)} \exp(\text{sim}(z_i, z_a)/\tau)} \quad (3-9)$$

其中， z_i 表示样本 x_i 在投影空间中的特征表示， τ 是温度参数，控制相似度分布的平滑程度。

为了加速收敛并提升训练稳定性，本文在 SCL 损失的计算中采用了交替训练策略，即每隔一定轮数，动态更新目标域样本的伪标签，保证正负样本对的质量。此外，为了防止目标域样本伪标签过早固定导致的误导效应，引入了置信度筛选机制，仅选择高置信度的目标域样本参与监督对比学习，从而进一步增强伪标签的鲁棒性。

通过引入监督对比学习机制，MLUDA 框架在逻辑输出层实现了类内特征的聚合与类间特征的分离，有效强化了分类决策边界的判别性和稳定性^[18,19]。实验结果表明，在多个跨域高光谱图像分类任务中，应用 SCL 机制后，模型在目标域上的分类准确率和特征分布的一致性指标均有显著提升，尤其在噪声较大的伪标签环境下，SCL 展现出了良好的鲁棒性和适应性。

综上所述，监督对比学习机制作为逻辑级域适应的重要组成部分，通过优化特征空间中的样本关系结构，从特征几何分布角度提升了无监督域适应任务中的分类性能，为 MLUDA 方法提供了坚实的判别性保障。

3.4.2 局部最大均值差异方法

在无监督域适应任务中，传统的特征对齐方法往往采用最大均值差异（Maximum Mean Discrepancy, MMD）作为分布度量指标，通过最小化源域与目标域特征分布之间的全局均值差异，促进域间特征一致性。然而，标准 MMD 方法只关注全局统计均值的对齐，忽略了类别条件分布（即同一类别样本在源域与目标域之间的一致性），容易导致类别混叠现象，即不同类别样本在特征空间中发生重叠，最

终削弱分类器的判别能力。因此，单纯使用全局 MMD 进行域对齐，难以在类别边界复杂、类别间分布差异显著的实际任务中取得理想的迁移效果。

为了解决这一问题，本文在 MLUDA 框架中引入了局部最大均值差异（Local Maximum Mean Discrepancy, LMMD）方法，作为逻辑级域适应的核心组成部分。LMMD 通过在类别条件下对源域与目标域的特征分布进行局部对齐，有效避免了全局对齐过程中类别信息的丢失，提升了跨域分类的精度与稳定性^[24]。

LMMD 的基本思想是，针对每一个类别，分别计算源域和目标域该类别样本的特征均值，并最小化它们之间的欧式距离。假设源域中第 k 类别样本集合为 $\mathcal{X}_s^k$ ，目标域中第 k 类别样本集合为 $\mathcal{X}_t^k$ ，其特征均值分别记为 μ_s^k 和 μ_t^k ，则 LMMD 损失定义为：

$$\mathcal{L}_{\text{LMMD}} = \sum_{k=1}^K \lambda_k \|\mu_s^k - \mu_t^k\|^2 \quad (3-10)$$

其中， K 为类别总数， λ_k 是类别权重系数，用于平衡不同类别在整体损失中的贡献。

在实际实现过程中，源域样本由于拥有真实标签，可以直接按照标签进行类别划分；而目标域样本则依赖于伪标签进行划分。为了缓解伪标签噪声对 LMMD 对齐效果的影响，本文在计算 LMMD 损失时引入了置信度筛选机制，即仅使用置信度高于一定阈值的目标域样本参与均值计算，从而提升类别局部对齐的准确性与鲁棒性^[29]。

具体地，LMMD 模块包括以下几个步骤：

- 类别划分：依据源域真实标签与目标域伪标签，将小批量样本按类别划分为若干子集；
- 类别均值计算：分别计算源域和目标域各类别特征均值；
- 类别权重分配：根据源域和目标域中每个类别样本数量的比例，动态调整类别权重，防止小类别对总损失的不合理放大；
- 局部损失累加：对所有类别局部均值差异进行加权累加，获得最终的 LMMD 损失。

MLUDA 框架训练时，LMMD 损失与监督对比学习（SCL）损失共同改善逻辑输出层的特征空间结构。通过局部类别对齐，LMMD 有效缩减了源域和目标域

同类样本的分布差异，从而使得分类器在源域和目标域上都能维持一样的决策边界，增强了模型的跨域判别能力。

3.5 损失函数与优化策略

为了实现源域与目标域特征分布的有效对齐，同时保障分类性能，本文在训练过程中综合设计了多种损失函数，并采用了动态调整的优化策略。整体损失函数由分类损失、域对齐损失、对比学习损失及伪标签监督损失等组成，各部分共同作用，促进模型在跨域高光谱图像分类任务中的性能提升。

首先，分类损失采用标准的交叉熵损失，以源域的有标签样本为基础进行监督学习。交叉熵损失衡量模型预测分布与真实标签分布之间的差异，其数学表达为：

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (3-11)$$

其中， N 表示源域训练样本数， y_i 为第 i 个样本的真实标签， $\hat{y}_i$ 为模型预测的类别概率。

其次，为缩小源域与目标域在特征空间中的分布差异，引入局部最大均值差异（Local Maximum Mean Discrepancy, LMMD）损失。其计算方式如下：

$$\mathcal{L}_{LMMD} = \sum_{k=1}^K \lambda_k \|\mu_s^k - \mu_t^k\|^2 \quad (3-12)$$

其中， K 表示类别总数， μ_s^k 与 μ_t^k 分别为源域与目标域第 k 类样本的特征均值， λ_k 为类别权重。

同时，为提升同类样本聚合性与不同类样本的分离性，引入监督对比学习（Supervised Contrastive Learning, SCL）损失：

$$\mathcal{L}_{SCL} = \sum_{i \in \mathcal{B}} \frac{-1}{|\mathcal{P}(i)|} \sum_{p \in \mathcal{P}(i)} \log \frac{\exp(\text{sim}(z_i, z_p)/\tau)}{\sum_{a \in \mathcal{A}(i)} \exp(\text{sim}(z_i, z_a)/\tau)} \quad (3-13)$$

其中， z_i 表示样本的特征表示， τ 为温度系数， $\text{sim}(\cdot)$ 为余弦相似度。

在目标域样本中，因缺乏真实标签，采用伪标签策略。模型通过预测概率最大值确定类别标签，仅对置信度高于阈值的样本施加伪标签监督损失，形式如下：

$$\mathcal{L}_{PT} = - \sum_{i \in \mathcal{T}_{\text{conf}}} \tilde{y}_i \log(\hat{y}_i) \quad (3-14)$$

其中， $\tilde{y}_i$ 为目标域样本的伪标签， $\mathcal{T}_{\text{conf}}$ 为高置信度样本集合。

最终总损失函数定义为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \alpha \cdot \mathcal{L}_{\text{LMMD}} + \beta \cdot \mathcal{L}_{\text{SCL}} + \gamma \cdot \mathcal{L}_{\text{PT}} \quad (3-15)$$

其中， α 、 β 、 γ 为损失项权重超参数。 α 与 γ 随训练轮数动态变化：

$$\alpha = \alpha_0 \cdot (1 + \cos(\pi \cdot t/T))/2, \quad \gamma = \gamma_0 \cdot (1 - \cos(\pi \cdot t/T))/2 \quad (3-16)$$

其中 t 表示当前轮数， T 为总轮数， α_0 、 γ_0 为初始值。 β 设置为常数，以兼顾稳定性与对比特征判别能力。

优化器选择带动量的 SGD（Stochastic Gradient Descent）优化器，动量设置为 0.9。初始学习率在 Houston 和 SH2HZ 数据集上设为 0.01，在 Pavia 数据集上设为 0.001，并采用如下学习率衰减策略：

$$\eta_t = \eta_0 \cdot (1 + \cos(\pi \cdot t/T))/2 \quad (3-17)$$

其中 η_0 为初始学习率。为防止过拟合，引入早停策略，当验证集精度连续若干轮无提升时终止训练。

通过上述多损失联合优化与动态调整机制，本文所采用的 MLUDA 方法可在不同数据集与场景下实现更高效的域适应，提升目标域分类精度与模型泛化能力。

3.6 本章小结

本章全面介绍了本文所采用的多层级无监督域适应方法（MLUDA）的整体设计框架与关键组成模块。该方法针对高光谱图像在跨场景分类中面临的分布差异显著、局部变化复杂等问题，从图像级、特征级和逻辑级三个层面展开建模，逐层对齐源域与目标域的分布，提高模型的跨域适应能力。在图像级域适应方面，通过 Gamma 校正与颜色直方图匹配方法对源域图像进行风格调整，从感知层面减少两域之间的光照与颜色偏差。在特征级域适应部分，设计了多分支交叉注意力机制（MBCA），以增强源域与目标域高维特征间的交互性与表达一致性。在逻辑级域适应中，引入监督对比学习（SCL）和局部最大均值差异（LMMD）损失函数，从输出层面进一步拉近类内特征、拉远类间特征，增强模型的判别能力与泛化稳定性。此外，本章还详细说明了模型的整体损失函数构成及优化策略。通过组合分类损失、域对齐损失、对比学习损失等多个目标函数，构建了统一的多任务训练框架，并采用权重系数调节各子任务的重要程度，实现了多层信息的协同优化。MLUDA

在结构设计与优化策略上兼顾了局部与整体、低层与高层的对齐需求，为后续的实验验证和性能分析提供了坚实的模型基础。

第四章 模型实现与实验验证

4.1 实验数据与平台环境

4.1.1 数据集介绍

本研究选用三组典型的高光谱影像数据集作为实验对象，分别是 Houston、Pavia 和 Shanghai-Hangzhou (SH2HZ) 数据集。各数据集具备不同场景、不同传感器、不同时间采集等特性，能够充分验证无监督域适应方法在跨场景高光谱图像分类任务中的适应性与鲁棒性^{[26][28]}。以下分别对各数据集进行详细介绍：

(1) Houston 数据集：

Houston 数据集是美国休斯顿地区 2013 年 (Houston13) 和 2018 年 (Houston18) 采集得到的，分别采集了大学校园和周边区域。Houston13 数据集包含 48 个有效波段，空间分辨率为 2.5m；Houston18 数据集的空间分辨率为 1m，并且也提取了 48 个有效波段。由于采集时使用的成像传感器不同，以及时间间隔较大，因此源域 (Houston13) 和目标域 (Houston18) 在光谱特性和空间结构上都存在着很大的域间差异。实验中在两个数据集中选择了 7 个共享类别进行分类任务。从图 4.1 中可以看到图像可视化结果，两组数据在颜色、亮度以及类别分布方面存在着明显的差异，这体现了跨场景高光谱图像分类时的域间偏移问题。




图 4.1 Houston 数据集

(2) Pavia 数据集：

Pavia 数据集由意大利 Pavia 市利用 ROSIS 传感器获取，包括 Pavia University (PaviaU) 和 Pavia Center (Pavia) 两个子数据集。PaviaU 数据集原始尺寸为 610×610 像素，含 103 个波段；Pavia 数据集尺寸为 1096×1096 像素，提取 102 个波段。为

确保数据一致性，在预处理阶段对无效波段进行剔除，并统一对图像尺寸进行了适配。实验中以 Pavia 为源域、PaviaU 为目标域，选取了 7 个共享类别进行无监督域适应实验。如图 4.2 (a) 所示，该任务模拟了同一城市不同区域间存在细微地物分布变化但整体环境相似的跨域场景，有助于考察模型在局部变化场景下的迁移学习效果。

(3) Shanghai-Hangzhou (SH2HZ) 数据集：

SH2HZ 数据集来源于中国长三角地区，分别使用 EO-1 Hyperion 高光谱传感器采集了上海市与杭州市部分城区的遥感影像。上海数据尺寸为 1600×230 像素，杭州数据尺寸为 590×230 像素，均保留了 198 个有效波段。如图 4.2 (b) 所示，该数据集选取“水体”、“土地与建筑”、“植被”三类共享类别进行分类。由于两地虽地理接近但城市建设风貌存在差异，且拍摄条件略有不同，因此该数据集适用于在跨城市、跨地形背景下测试无监督域适应性能。




图 4.2 Pavia 数据集与 Shanghai-Hangzhou 数据集

所有的数据集在处理的过程中都采用了标准的归一化操作（零均值、单位方差），并且加入图像增强操作（如辐射扰动、随机翻转）来提高模型的鲁棒性。通过跨域多源数据的验证可以有效的检验多层次无监督域适应（Multilevel Unsupervised Domain Adaptation, MLUDA）方法在实际场景中的迁移性能与泛化能力。这 3 个数据集涵盖了不同时间、不同地点、不同传感器条件下的高光谱图像分类任务，具有较强的代表性、跨域差异大等特点。在实际预处理过程中，统一进行了归一化

处理（标准化到零均值、单位方差），并进行了图像增强操作（包括辐射噪声扰动与随机翻转）以提升模型的鲁棒性。通过使用这些跨域数据集可以很好的验证本文所采用的 MLUDA 方法在实际应用中的迁移泛化能力和分类能力。

4.1.2 实验环境与平台配置

为了验证本文所介绍的基于 MLUDA 方法的有效性，本研究在本地服务器环境下搭建了完整的实验平台，保证各阶段实验顺利进行。具体软硬件环境配置如下：

（1）硬件环境：

实验使用本地 CPU 服务器进行模型训练与测试，主要硬件配置如下：

处理器（CPU）：Intel Xeon Silver 4210R

内存（RAM）：64 GB

存储：2 TB SSD

显卡（GPU）：无 GPU 加速（所有实验均在 CPU 上完成）

由于高光谱图像数据量大、维度高，本研究在训练过程中针对 CPU 计算特点进行了优化，包括合理设计批处理大小、减少冗余计算操作、采用多线程数据预处理等措施，以提升整体运行效率。

（2）软件环境：

本研究的软件环境配置如下：

操作系统：Windows 10 专业版

编程语言：Python 3.11.7

深度学习框架：PyTorch 2.2.2

科学计算与数据处理库：NumPy 1.26.4、Pandas 2.2.2、Scikit-learn 1.5.0

图像处理库：OpenCV 4.9.0

可视化工具：Matplotlib 3.8.4

其他辅助库：hdf5storage（用于处理.mat 格式高光谱数据）

各软件包均通过 Anaconda 环境管理器配置，并在本地独立虚拟环境中部署，确保不同库之间的版本兼容性与运行稳定性。

（3）实验平台搭建过程：

在实验平台搭建过程中，首先完成了必要的软件安装与环境配置，随后针对高光谱数据的特性编写了数据加载、预处理、增强等模块，并实现了完整的无监

督域适应训练流程。由于缺乏 GPU 加速，本研究特别注重代码运行效率优化，例如采用小批量梯度更新（Batch Size = 32）、简化模型参数量、并在数据增强阶段提前完成预处理，以降低训练时间开销。

（4）平台适配性与稳定性：

经过多轮调试和实验，当前搭建的实验平台可以稳定支持 Houston、Pavia 和 Shanghai-Hangzhou 这三组数据集上的大规模训练和测试任务。虽然由于硬件限制，每次实验的训练时间比较长，但是整体结果稳定可靠，能够满足本次研究所需的消融实验、对比实验以及可视化分析任务。

4.2 模型结构与训练设置

4.2.1 网络结构与核心模块

本研究介绍了一种多层次无监督域适应方法，旨在有效提升高光谱图像在跨场景条件下的分类性能。整体模型框架主要包括特征提取模块、分类器模块和多层次域适应模块，各模块相互配合，以实现源域与目标域间在不同特征层次上的充分对齐，增强模型的迁移泛化能力。

在特征提取方面，MLUDA 采用了双分支卷积特征提取网络（Dual-branch Convolutional Representation Network, DCRN₀₂），分别从光谱信息和空间信息两个角度对输入数据进行处理。光谱分支使用 $1 \times 1 \times 7$ 大小的卷积核，结合残差连接和光谱注意力机制（Spectral Squeeze-and-Excitation, Spectral SE），有效提取出高维光谱特征并突出重要波段；对降维后的特征图，采用空间尺寸为 1×1 、输入通道数为 C 的卷积核进行局部特征提取，辅以空间注意力机制，捕捉局部区域的空间结构特征。两个分支在经过特征提取后进行拼接融合，在光谱-空间联合特征层面为后续的跨域对齐提供了坚实基础。

在特征提取的基础上，MLUDA 设置了分类器模块。分类器由两层全连接层组成，第一层用于输出类别预测概率，结合源域真实标签及目标域伪标签进行分类训练，第二层用于输出域判别得分，配合 Sigmoid 激活函数，计算源域与目标域的区分度，进一步辅助特征对齐。同时，为提升不同层次的适应效果，本研究在图像级、特征级和逻辑级分别引入了不同的域适应策略：图像级域适应通过 Gamma 校正、颜色直方图匹配和引导滤波减少源域与目标域在成像风格上的偏差；特征级域适应采用多分支交叉注意力机制（MBCA），通过点积注意力实现跨域特征间的有效交互，提取更加领域不变的表示；逻辑级域适应则结合监督对比学习（Supervised

Contrastive Learning, SCL) 与局部最大均值差异 (LMMD) 方法, 在类别层面对源域与目标域特征分布进行精细对齐, 增强类别可分性与聚合性。

4.2.2 超参数与训练设置

为了保证训练过程中的稳定性与实验结果的可复现性, 本文对训练参数进行了细致的设定。相关配置如表 4.1 所示:

表 4.1 实验参数配置表

参数项	配置项
批量大小 (BatchSize)	32
初始学习率 (LearningRate)	0.01 (Houston、SH2HZ), 0.001 (Pavia)
优化器 (Optimizer)	SGD (带动量)
动量 (Momentum)	0.9
权重衰减 (WeightDecay)	5×10^{-4}
训练轮次 (Epochs)	100
输入尺寸 (PatchSize)	7×7、11×11、1×1
PCA 主成分数量	30
跨注意力头数 (AttentionHeads)	2
对比学习温度参数 (Temperature)	0.2
域适应权重系数 λ	$2 / (1 + e^{-10 \cdot \text{epoch} / \text{epochs}}) - 1$

在训练过程中, 为了使模型更好的适应无标签的目标域数据, 采用伪标签生成策略, 根据最大预测概率给目标域样本添加伪标签, 让模型逐渐修正目标域的特征分布。同时, 训练样本在输入时加入了辐射噪声扰动和随机翻转增强, 提高模型对光照变化、成像噪声以及局部形变的鲁棒性。

针对不同数据集的特点, 本文也进行了相应的训练策略调整, 如在 Houston 任务中, 由于源域与目标域的成像时间相差较大, 光照和地物变化较大, 所以采用动态学习率衰减策略, 在训练后期降低学习率, 使模型更好的适应目标域的细粒度变化; 在 Pavia 任务中, 由于数据量大, 类别分布比较均匀, 所以采用较小的学习率和较大的 PatchSize, 更好的捕捉局部区域的地物信息; 在 SH2HZ 任务中, 由于类别少, 场景连续性较高, 所以采用较小的 PatchSize 和较高的伪标签置信度阈值, 减少噪声标签对训练的影响。

所有任务中都使用了早停机制，即在验证集准确率连续几个 `epoch` 没有提升的时候就提前结束训练，以此来防止过拟合现象。结合这些参数设定以及训练策略，MLUDA 模型在跨场景高光谱图像分类任务上得到了不错的分类准确率，并且具有良好的迁移适应能力，这为接下来章节的实验分析打下了稳固的基础。

4.3 实验结果与性能分析

4.3.1 不同数据集的分类效果评估

为了全面评估所介绍的 MLUDA 方法的分类性能，本文在 Houston、Pavia 和 Shanghai-Hangzhou 三个跨场景高光谱数据集上进行了充分实验，并以总体分类准确率（Overall Accuracy, OA）、平均分类准确率（Average Accuracy, AA）和 Kappa 系数（Kappa）作为主要评估指标。每个数据集的分类结果如图 4.3 所示，进一步进行了可视化展示与分析，性能统计如表 4.2 所示。




图 4.3 不同数据集上的各类别分类准确率

总体而言，MLUDA 方法在 Pavia 数据集上的性能最优，其次是 Shanghai-Hangzhou，Houston 数据集相对较低。这主要由于 Pavia 的源目标域差异较小，而 Houston 跨年采集设备差异较大，导致域偏移更严重，说明所提方法在域间结构相似的场景下效果更佳，在复杂背景下仍保持一定泛化能力。

表 4.2 不同数据集性能评估指标结果

数据集	Overall Accuracy (OA) %	Average Accuracy (AA) %	Kappa (%)
Houston	74.78	73.21	60.29
Pavia	89.88	91.74	88.01
Shanghai-Hangzhou	87.09	90.69	78.55

此外，为了直观展示不同数据集间各评估指标的差异，本文绘制了对应的柱状图，如图 4.4 所示。从柱状图可以直观看到，本方法在 Pavia 数据集上各项指标均达到最高水平，而在 Houston 数据集上有待进一步优化。未来可以通过引入更强的特征对齐机制和伪标签自适应策略，进一步提升复杂场景下的分类性能。

综合分析表明，所介绍的 MLUDA 方法在不同跨场景高光谱图像分类任务中均取得了优异的性能，验证了图像级、特征级与逻辑级协同适应的有效性与普适性。




图 4.4 各数据集评估指标对比柱状图

4.3.2 与主流方法对比实验

为了进一步验证所介绍的 MLUDA 方法的有效性，本文在 Houston、Pavia 和 Shanghai-Hangzhou (SH2HZ) 三个跨场景高光谱图像数据集上，选取了具有代表性的三种主流无监督域适应方法进行对比实验，分别是深度适应网络 (Deep Adap-

tation Network, DAN)、双分支注意力对抗域适应方法 (Two-Branch Attention Adversarial Domain Adaptation, TAADA)、基于置信学习的域适应方法 (Confident Learning-Based Domain Adaptation, CLDA)。

其中, DAN 方法代表了传统基于最大均值差异特征对齐的经典域适应技术, 其特点是结构简单, 训练稳定, 但对于复杂场景下的高层次特征偏移适应能力有限; TAADA 方法结合了对抗性训练与注意力机制, 在特征抽取和域对齐上均有所优化, 代表了近年来对抗性域适应的发展方向; 而 CLDA 方法则基于伪标签置信学习策略, 能够在无监督条件下有效挖掘目标域潜在结构信息, 代表了当前跨域分类领域较为先进的技术水平。

所有方法均按照各自公开实现或文献中最优超参数设置进行训练和测试, 评估指标采用总体分类准确率 (Overall Accuracy, OA)、平均分类准确率 (Average Accuracy, AA) 和 Kappa 系数 (Kappa)。

实验结果总结如表 4.3 所示。从整体来看, MLUDA 方法在三个数据集上均取得了最优的分类性能, 并在各项指标上均优于对比方法^[11]。

在 Houston 数据集中, DAN 方法由于仅基于浅层特征对齐, 未能有效适应源目标域在成像设备、时间跨度等方面的巨大差异, 导致分类性能较低, OA 仅为 62.48%。TAADA 方法引入对抗性训练和注意力机制, 在一定程度上提升了分类效果, OA 达到 70.53%。CLDA 方法利用伪标签策略进一步改善了目标域判别性能, OA 提高到 72.07%。而本文介绍的 MLUDA 方法通过图像级、特征级和逻辑级的多层次适应, 有效缩小了低层次风格差异、深层特征分布偏移以及类别判别边界的差异, 最终在 Houston 数据集上实现了 74.78% 的 OA, 较 CLDA 进一步提高了约 2.7 个百分点。

在 Pavia 数据集中, 由于源域和目标域成像条件相近, 浅层特征偏移较小, 因此 DAN、TAADA、CLDA 方法均取得了较高的基线性能。其中, CLDA 方法在该数据集上表现较优, OA 达到 89.15%。然而, MLUDA 方法通过引入逻辑级适应 (监督对比学习与局部最大均值差异), 进一步提升了类内特征聚合性和类间特征分离性, 在 Pavia 数据集上将 OA 提升至 89.88%, AA 提升至 91.74%, Kappa 提升至 88.01%, 实现了更为稳定和均衡的分类效果。

在 Shanghai-Hangzhou 数据集中, 由于城市间场景差异复杂, 既存在光谱特性变化, 也存在空间布局和噪声水平差异, DAN 方法难以有效迁移, OA 仅为 78.12%。

表 4.3 MLUDA 与主流方法在不同数据集上的性能对比（单位：%）

不同方法	Houston			Pavia			Shanghai-Hangzhou		
	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa
DAN	62.48	61.27	45.01	81.53	84.62	77.12	78.12	81.04	69.25
TAADA	70.53	69.77	55.72	88.04	89.64	86.33	82.75	86.27	75.30
CLDA	72.07	71.34	57.60	89.15	90.12	87.21	83.57	87.01	76.23
MLUDA	74.78	73.21	60.29	89.88	91.74	88.01	87.09	90.69	78.55

TAADA 方法通过多分支对抗结构提升了局部特征迁移能力，OA 提升至 82.75%。CLDA 方法通过置信伪标签机制进一步增强了目标域学习，OA 达到 83.57%。相比之下，MLUDA 方法凭借多层次域适应策略，在图像风格、深层特征、类别结构三个层面同时进行优化，最终在 Shanghai-Hangzhou 数据集上取得了 87.09% 的 OA，AA 达到 90.69%，Kappa 系数也提高到 78.55%，全面领先于其他方法。

从对比实验可以总结出以下几点：

- 存在图像风格差异明显的场景（Houston），只靠特征对齐无法带来良好的迁移，需要图像级域适应。
- 在特征分布接近但类别边界模糊的场景（如 Pavia），逻辑级适应（如监督对比学习）可以提高类别判别能力。
- 在复杂跨城场景（Shanghai-Hangzhou）中，三层次域适应协同，可以全面覆盖层面上的域偏移，提升整体迁移性能和模型鲁棒性。

综上所述，本文介绍的 MLUDA 方法在不同类型的跨域任务中均展现了优异的适应能力和广泛的适用性，验证了多层次协同域适应设计的合理性和有效性，为高光谱图像跨场景分类任务提供了一种有效的解决方案。

4.3.3 消融实验分析

为了进一步验证所介绍的多层级无监督域适应方法中各模块的有效性，本文设计了系统的消融实验。通过分别去除图像级域适应（A）、特征级域适应（B）和逻辑级域适应（C）模块，并组合成不同的子结构（如 AB、AC、BC），观察模型性能变化，从而评估各模块在整体框架中的作用。消融实验在 Houston、Pavia 和

Shanghai-Hangzhou 三个数据集上分别进行,评估指标采用总体分类准确率 (Overall Accuracy, OA)、平均分类准确率 (Average Accuracy, AA) 和 Kappa 系数 (Kappa)。

实验结果如表 4.4 所示。可以观察到,在所有数据集上,完整使用图像级、特征级和逻辑级三个适应模块 (即 ABC 组合) 时,模型性能最高。而去除任一模块,分类性能均出现明显下降,且不同模块对最终结果的影响程度在不同数据集上有所差异。

具体分析,在 Houston 数据集中,去除图像级域适应 (A) 对性能影响最大。总体分类准确率 (OA) 下降约 6.7%, Kappa 系数下降超过 8%, 平均分类准确率 (AA) 也出现了约 6% 的下降。这主要是因为 Houston 源域 (2013 年) 和目标域 (2018 年) 采集时间跨度较大,成像设备不同,导致光照条件、色彩分布、噪声水平存在明显差异。图像级域适应通过伽马校正、颜色直方图匹配和引导滤波,有效减少了这类低层次特征的偏移,因此在 Houston 任务中具有关键作用。缺失图像级适应后,源域与目标域在外观特性上的巨大差异直接影响了后续特征提取与分类判别,导致性能明显下滑。

在 Pavia 数据集中,去除逻辑级适应 (C) 对性能影响最为明显。与完整结构相比,缺失逻辑级适应 (即 AB 组合) 使 OA 下降了近 4.5%, Kappa 系数下降了 5.5%。由于 Pavia 源域与目标域虽然拍摄场景不同,但使用的是同一型号传感器,光谱特性分布相对接近,图像级差异较小。因此,在该数据集上,后续通过监督对比学习机制和局部最大均值差异方法进行类别特征对齐,对提升跨域判别能力尤为重要。当缺少逻辑级域适应时,虽然基本特征提取尚可,但类内聚合不足、类间可分性下降,导致最终分类性能受限。

在 Shanghai-Hangzhou (SH2HZ) 数据集中,三种模块对性能的贡献较为均衡。无论去除图像级、特征级或逻辑级中的任意一项,分类准确率均下降约 4% 至 5%,且 Kappa 系数波动也较大。这表明,在城市间跨域分类任务中,由于光谱分布、空间结构、成像风格等多方面存在差异,仅依赖单一层级适应很难实现全面对齐,必须同时在图像级、特征级和逻辑级进行多层次协同适配,才能取得最佳的跨域分类效果。

为了进一步探究不同模块的具体贡献,可以从功能视角进行细分理解:

图像级域适应主要负责降低源域与目标域在亮度、颜色、风格等低层特征上的差异;特征级域适应通过引入跨域交叉注意力机制,增强源目标特征的局部到

表 4.4 不同模块组合在各数据集上的性能对比（单位：%）

模块组合	Houston			Pavia			Shanghai-Hangzhou		
	OA	AA	Kappa	OA	AA	Kappa	OA	AA	Kappa
ABC	74.78	73.21	60.29	89.88	91.74	88.01	87.09	90.69	78.55
AB	70.12	67.31	52.41	85.23	87.16	82.43	82.24	86.47	71.84
AC	71.33	68.92	54.37	86.01	88.02	83.65	83.09	87.12	73.12
BC	68.04	67.15	51.67	86.57	88.74	84.33	81.89	85.74	70.32

全局交互；而逻辑级域适应则在类别特征分布层面进行精细调整，提升了模型的判别边界。

从实验现象来看，不同模块之间不仅是简单叠加关系，而是具有明显的互补性和协同效应。当仅使用单一或部分模块时，模型无法充分挖掘跨域共有特征，导致泛化能力下降；只有同时结合图像风格对齐、深层特征交互和类别级判别优化，才能最大程度缓解跨域偏移，提升整体分类性能。本节消融实验充分证明了所介绍的多层级域适应机制在不同类型数据集上的普适性和有效性，也验证了各模块在跨场景高光谱图像分类中的不可或缺性。

4.4 本章小结

本章围绕多层级无监督域适应方法（MLUDA）的有效性与实用性，开展了系统全面的实验验证。首先介绍了所使用的高光谱跨场景数据集（Houston、Pavia 和 Shanghai-Hangzhou），并给出了实验平台与硬件环境的配置详情。随后对模型结构进行了说明，并结合实际任务设置了相应的训练超参数与优化策略。在实验结果部分，通过在多个数据集上的分类性能评估，展示了本文方法在总体分类准确率、平均分类准确率以及 Kappa 系数等指标上的优越表现。与多种主流无监督域适应方法的对比实验进一步验证了 MLUDA 在跨域任务中的性能提升与泛化能力。同时，通过消融实验深入分析了各模块在整体性能中的贡献，说明了图像级、特征级和逻辑级结构的协同作用对于模型最终效果的重要性。整体实验结果充分表明，所采用的 MLUDA 方法在跨场景高光谱图像分类任务中具有良好的适应性与有效性。

第五章 总结与展望

5.1 本文工作总结

随着人工智能和深度学习技术的迅速发展，如何在缺少目标域标签的状况下达成高光谱图像的跨域分类变成了遥感图像剖析范畴里的重大难题，针对传统无监督域适应办法在应付繁杂分布转移，高光谱特征差异以及跨场景运用时所具有的缺陷，文章围绕无监督域适应技术展开了全面探究，选用了一种多层次无监督域适应（Multilevel Unsupervised Domain Adaptation, MLUDA）方法，并实施了充足的试验论证及剖析工作。

本文主要完成了以下几个方面的工作：

针对源域和目标域在成像风格、特征分布以及类别结构等不同层面上存在的差异性问题的，构建了图像级、特征级和逻辑级协同对齐的多层次域适应框架，利用图像级的伽马校正和颜色直方图匹配来降低由于成像条件变化造成的低层次差异，利用特征级的多分支交叉注意力机制 (MBCA) 增强源域和目标域之间的深层特征交互与融合，利用逻辑级的监督对比学习 (SCL) 和局部最大均值差异 (LMMD) 损失实现类别判别空间的优化与细粒度对齐，进而提升跨域分类性能。

本文在三个有代表性的跨场景高光谱数据集 (Houston、Pavia、Shanghai-Hangzhou) 上做了大量的实验，全面考察了本文所引入的方法，实验结果显示，相比于传统的 MMD 对齐方法、对抗性注意力域适应方法、基于置信伪标签学习的方法，本文所介绍的 MLUDA 在总体分类准确率、平均分类准确率和 Kappa 系数等指标上都取得了较好的性能，在不同的场景中也表现出了较好的泛化能力和稳定性。

本文通过详尽的消融试验来证明各个模块（图像层级，特征层级，逻辑层级）于整体框架里的必要性及其相互补充之处，分析得出，不一样的模块针对不同种类的数据集合而言，其性能改善所起的主要作用也有所区别，而且，这种三层级的协作适应设计对于解决复杂多变的跨领域场景来说十分关键。

本文所介绍的 MLUDA 方法在理论设计和实验验证这两方面都表现出较强的可行性和实用性，在一定程度上补充了传统无监督域适应方法在高光谱图像分类任务上的不足，并且为之后跨场景、跨模态的遥感图像分析研究给予了新的思路和借鉴。

5.2 研究不足及未来展望

虽然本文所介绍的多层级无监督域适应方法在跨场景高光谱图像分类任务中获得了良好的实验结果，在多个数据集上也明显优于现有主流方法，但仍存在一些局限性与改进空间。

首先，在训练过程中，本文方法仍面临较大的计算开销问题。多层级适应结构中，尤其是特征级域适应所使用的多分支交叉注意力机制（MBCA），以及逻辑级域适应中引入的监督对比学习（SCL）和局部最大均值差异（LMMD）损失函数，均带来了较大的模型参数量和训练计算复杂度，导致整体训练耗时较长、资源消耗较大，限制了方法在计算资源受限场景中的部署与应用。

其次，在图像级域适应阶段，尽管引入了伽马校正与颜色直方图匹配等具备物理可解释性的处理手段，但在阴影严重、强反光等极端场景下，全局风格对齐可能会引入噪声，使得低层特征过于平滑，进而影响后续特征提取的有效性。同时，图像级适应尚未充分考虑空间上的局部变化，可能导致局部区域适应不足的问题。

此外，本文主要围绕单源到单目标的无监督迁移任务展开研究，而在实际应用中更具挑战性的任务如多源域适应、源无关域适应等尚未涉及。面对真实场景中源域数据难以获取、目标域样本极度稀缺等复杂情况，现有方法的适用性仍有待提升。

针对以上问题，未来研究工作将围绕多个方向展开。首先，可尝试引入模型剪枝、知识蒸馏等轻量化策略，以降低计算负担并提高模型部署效率^[32]。其次，在图像级域适应中引入区域注意机制或局部风格匹配方法，进一步增强模型对局部变化的鲁棒性。再次，研究将扩展到多源、源无关等复杂迁移场景，探索如何在源数据不可访问、目标数据极度有限的条件下实现稳定有效的适应^[6]。同时，可将大规模预训练模型（如 ViT、Swin Transformer）引入到高光谱图像跨域任务中，结合无监督学习提升特征迁移能力^[21,28]。最后，也将进一步关注伪标签质量对训练的影响，尝试通过置信度调节、自训练稳定机制等手段提升伪标签的可靠性^[16]。

本文采用的方法为高光谱图像的跨域分类任务提供了一种有效思路，但仍有若干方面值得深入优化与拓展。后续将围绕模型效率、适应稳定性与适用广度等方面持续改进，为高光谱图像智能分析的现实应用奠定更坚实的基础。

致 谢

时光飞逝，岁月如歌，转眼间我的大学本科四年就要结束，回想起过去的四年，从年幼无知到渐渐成长，每一步的成长都离不开身边亲人们、老师们以及朋友们的陪伴和支持，在这篇论文即将完成的时候，我想对一直以来关心我、帮助我、指导我的人说声谢谢！

首先我要感谢我的论文指导老师郭雨薇老师，从毕业设计开始到毕业设计结束，老师在选题方向上给予了我详细的指导，在论文写作、实验设计、思路整理等方面，耐心地给我点拨、仔细地给我指正。老师严谨求实的工作作风，敏锐深刻的科研思维，无私奉献的师者风范，给我留下了深刻的印象，开阔了我的视野，教会了我坚持，教给了我专注。

同时也要感谢家人一直以来的无条件支持与鼓励，感谢父母的理解与包容，让我有了最坚强的后盾，让我可以安心学习、专心科研，勇敢地去面对成长路上的困难与不易，感谢家人无声的陪伴与付出，给了我前进的力量。

感谢一路走来陪伴我的朋友们。在大学四年的时光里，是你们用温暖的友情，陪伴着我度过最美好的青春时光，是你们让我在课业学习中互相鼓励，在生活中互相陪伴，是你们让我拥有了最美好的青春回忆。

回顾在西安电子科技大学度过的四年时光，我不但学到了专业知识，而且在无数次的挑战和磨砺当中，锻炼出坚强的意志，充实了自己的内心世界，找到了未来的发展方向，大学的生活教会我要学会独立思考，坚守自己最初的想法，还要明白在艰难处境下勇往直前的价值所在，这四年时间里我的成长，并非仅仅局限于知识层面，更多体现在心智方面的成熟以及个人性格的形成上。

未来还有很长的路要走，但西电四年沉淀，将会是我一生的底气和力量。谢谢这四年时光，让我在不断的探索与学习中遇见更好的自己。

谨以此文，向所有关心、支持和陪伴我的人致以最诚挚的谢意！

参考文献

- [1] GOODFELLOW I, BENGIO Y, COURVILLE A. 深度学习[M]. 北京: 机械工业出版社, 2018.
- [2] BISHOP C M. 模式识别与机器学习[M]. 赵炜等, 译. 北京: 清华大学出版社, 2009.
- [3] AZUNRE P. 图像分类的迁移学习[M]. 北京: 机械工业出版社, 2019.
- [4] 武嘉成. 基于无监督领域自适应的图像分类方法研究[D]. 北京: 北京交通大学, 2023. DOI: 10.26944/d.cnki.gbfju.2023.001027.
- [5] CSURKA G. 计算机视觉应用中的域适应[M]. 北京: 人民邮电出版社, 2017.
- [6] LI X, PAN C, HE L, et al. Unsupervised Domain Adaptation for Cross-domain Histopathology Image Classification[J]. Springer Nature, 2023, 83: 23311-23331.
- [7] FERNANDO B, HABRARD A, SEBBAN M, et al. Unsupervised visual domain adaptation using subspace alignment[C]//IEEE ICCV. 2013: 2960-2967.
- [8] SINGH I P, GHORBEL E, KACEM A, et al. Discriminator-Free Unsupervised Domain Adaptation for Multi-Label Image Classification[C]//IEEE/CVF WACV. 2024: 3936-3945.
- [9] LI Z, XIE W, FANG Z, et al. Supervised contrastive learning-based UDA for hyperspectral image classification[J]. IEEE Trans. Geosci. Remote Sens., 2023, 61: 1-14.
- [10] ZHANG N, LU J, LI K, et al. Source-Free Unsupervised Domain Adaptation: Current research and future directions[J]. Neurocomputing, 2024, 564: 1-14.
- [11] FANG Y, YAP P T, LIN W, et al. Source-free unsupervised domain adaptation: A survey[J]. Neural Networks, 2024, 174: 1-14.
- [12] CAI M, XI B, LI J, et al. Mind the Gap: Multilevel Unsupervised Domain Adaptation for Cross-Scene Hyperspectral Image Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-14. DOI: 10.1109/TGRS.2024.3407952.
- [13] PENG D, KE Q, AMBIKAPATHI A, et al. Unsupervised Domain Adaptation via Domain-Adaptive Diffusion[J]. IEEE Trans. Image Process., 2024, 33: 4245-4260.
- [14] WANG Q, YIN C, SONG H, et al. UTFNet: Uncertainty-Guided Trustworthy Fusion Network [J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5. DOI: 10.1109/LGRS.2023.3322452.
- [15] DUAN P, KANG X, GHAMISI P, et al. Hyperspectral remote sensing benchmark for oil spill detection[J]. IEEE Trans. Geosci. Remote Sens., 2023, 61: 1-5.
- [16] HONG D, et al. Cross-city matters: A multimodal dataset for cross-city semantic segmentation [J]. Remote Sens. Environ., 2023, 299: 231-244.
- [17] 葛彦齐. 基于 data-mixing 的域适应语义分割算法研究[D]. 成都: 电子科技大学, 2024. DOI: 10.27005/d.cnki.gdzku.2024.003506.

- [18] LIU Q, PENG J, ZHANG G, et al. Deep contrastive learning network for small-sample hyperspectral image classification[J]. *Journal of Remote Sensing*, 2023, 3: 99-107. DOI: 10.34133/remotesensing.0025.
- [19] LIU Q, et al. Refined prototypical contrastive learning for few-shot hyperspectral image classification[J]. *IEEE Trans. Geosci. Remote Sens.*, 2023, 61: 290-307.
- [20] YAN J, LUO L, DENG C, et al. Adaptive hierarchical similarity metric learning with noisy labels [J]. *IEEE Transactions on Image Processing*, 2023, 32: 1245-1256. DOI: 10.1109/TIP.2023.3242148.
- [21] XI B, LI J, LI Y, et al. Semisupervised cross-scale graph prototypical network for hyperspectral image classification[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, 34(11): 9337-9351. DOI: 10.1109/TNNLS.2022.3158281.
- [22] 谭诚. 基于自注意力编解码网络的高光谱图像开放集分类方法研究[D]. 武汉: 华中师范大学, 2024. DOI: 10.27159/d.cnki.ghzsu.2024.002187.
- [23] FAROOQUE G, LIU Q, SARGANO A B, et al. Swin transformer with multiscale 3D atrous convolution[J]. *Eng. Appl. Artif. Intell.*, 2023, 126: 107-130.
- [24] 唐震. 基于深度学习的辐射源个体识别技术研究 with 实现[D]. 南京: 南京信息工程大学, 2023. DOI: 10.27248/d.cnki.gnjqc.2023.001327.
- [25] YAN J, DENG C, HUANG H, et al. Causality-invariant interactive mining for cross-modal similarity learning[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024, 46(9): 6216-6230. DOI: 10.1109/TPAMI.2024.3379752.
- [26] TANG Y, et al. An object fine-grained change detection method based on frequency decoupling interaction[J]. *IEEE Trans. Geosci. Remote Sens.*, 2024, 62: 56-66.
- [27] 王明. 基于自监督图神经网络和混合神经网络的入侵检测[J]. *网络安全与数据治理*, 2024, 43(09): 21-25. DOI: 10.19358/j.issn.2097-1788.2024.09.004.
- [28] 容俊. 融合相关系数与低秩稀疏表示的高光谱影像分类方法研究[D]. 青岛: 中国石油大学(华东), 2020. DOI: 10.27644/d.cnki.gsydu.2020.001274.
- [29] 孔祥羽. 基于域迁移的气象卫星图像云分类技术研究[D]. 北京: 北京邮电大学, 2023. DOI: 10.26969-/d.cnki.gbydu.2023.000172.
- [30] HONG D, et al. SpectralGPT: Spectral remote sensing foundation model[Z]. 2023. eprint: arXiv:2311.07113.
- [31] ZHANG J, LEI J, XIE W, et al. SuperY-OLO: Super resolution assisted object detection[J]. *IEEE Trans. Geosci. Remote Sens.*, 2023, 61: 21-25.
- [32] KUMARI S, SINGH P. Deep learning for unsupervised domain adaptation in medical imaging [J]. *Computers in Biology and Medicine*, 2024, 170: 107912.