

班 级 2120031

学 号 21009200146

西安电子科技大学

本科毕业设计论文



题 目 基于仿真环境的机器人布料抓取策略研究

学 院 人工智能学院

专 业 人工智能

学生姓名 王鹏凯

导师姓名 董乐

摘要

衣物作为典型的柔性物体，其自由度高、状态多变且存在严重自遮挡现象，给自动化操作带来了极大挑战。针对这一问题，本文提出了一种基于“规范化对齐”（Canonicalized-Alignment）的衣物处理方法，通过将任意初态衣物收敛至结构清晰、关键点可观测的标准形态，显著降低下游操作任务的复杂度。

具体而言，本文设计了分解式奖励函数，将规范化与位姿对齐两个子任务分离，提升了策略学习的稳定性与效率。同时，结合动态甩动与静态抓放操作，基于空间动作图（Spatial Action Maps）构建了多原语策略网络，实现了对复杂初态衣物的高效处理。

在仿真环境中，本文在多个类别（如衬衫、裤子、裙子、连衣裙）上进行了系统实验，验证了所提方法在规范化精度、位姿对齐准确率及多类别泛化能力上的优越性。实验结果表明，本文方法在困难初态下亦能有效完成衣物规范化对齐，极大地简化了熨烫、折叠等后续任务的操作流程，具有良好的理论价值与应用前景。

关键词：衣物操作 柔性物体处理 规范化对齐 机器人操控 空间动作图

ABSTRACT

Garments, as typical deformable objects, exhibit high degrees of freedom, diverse configurations, and severe self-occlusion, posing significant challenges to automated manipulation. To address these issues, this paper proposes a garment handling method based on "Canonicalized-Alignment," which funnels garments from arbitrary initial states into structured, keypoint-observable canonical configurations, significantly simplifying downstream tasks.

Specifically, a factorized reward function is designed to decouple shape canonicalization and pose alignment, improving the stability and efficiency of policy learning. Moreover, a multi-primitive strategy combining dynamic flinging and quasi-static pick-and-place actions is developed, leveraging Spatial Action Maps to achieve efficient and precise manipulation of complex cloth states.

Extensive experiments conducted in a simulation environment across multiple garment categories (shirts, pants, skirts, and dresses) demonstrate the effectiveness of the proposed method in terms of canonicalization accuracy, alignment precision, and cross-category generalization. The results show that the proposed approach can successfully achieve canonicalized alignment even under challenging initial conditions, greatly facilitating subsequent tasks such as ironing and folding. This work provides a promising step towards general-purpose deformable object manipulation.

Keywords: Garment Manipulation Deformable Object Handling Canonicalized Alignment Robotic Control Spatial Action Maps

目 录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 研究现状与挑战	2
1.3 本文工作与贡献	3
1.4 论文结构安排	3
第二章 理论基础与相关研究工作	5
2.1 柔性物体操作理论基础	5
2.1.1 空间动作图	5
2.1.2 多原语联合策略	5
2.1.3 可微分模拟与反向优化	6
2.2 相关工作	7
2.2.1 基于启发式的方法：从特定任务到有限泛化	7
2.2.2 基于深度学习的方法：从动态展开到复杂操控	8
2.3 小结	8
第三章 方法	11
3.1 任务概述与总体框架	11
3.2 空间动作图与多原语网络	11
3.3 动作选择与执行策略	13
3.4 奖励因子化与网络训练	13
3.5 方法总结	15
第四章 实验与分析	17
4.1 实验设置	17
4.1.1 仿真环境搭建	17
4.1.2 训练数据生成	17
4.1.3 实验参数设定	18
4.2 评估指标	19
4.3 实验与分析	19
4.3.1 与现有方法对比实验	19

4.3.2	奖励函数消融实验	21
4.3.3	动作原语消融实验	22
4.3.4	多类别泛化实验	24
4.4	实验小结	26
第五章	总结与展望	27
5.1	研究总结	27
5.2	研究展望	28
致谢		31
参考文献		33

第一章 绪论

1.1 研究背景与意义

近年来，随着人工智能与机器人技术的迅猛发展，机器人逐渐从工业领域拓展至家庭、医疗、服务业等非结构化环境，承担着日益复杂且多样化的操作任务。在此背景下，柔性物体，尤其是衣物的自动化处理，逐渐成为机器人研究中的重要方向。与刚性物体相比，柔性物体具有无限自由度、形态变化多样与状态空间庞大等显著特征，导致其操作任务在目标建模、状态感知与动作规划等方面面临巨大挑战。其中，衣物由于在操作过程中容易出现折叠、褶皱、扭结以及遮挡等现象，进一步加剧了操作难度，被公认为是柔性物体自动化操作领域最具代表性的研究难题之一^[1-2]。

针对衣物操作问题，早期研究主要依赖于基于启发式规则的方法^[3]。此类方法通常假设衣物初始状态较为规则^[4]，通过预定义的动作序列和手工设计的规则实现展开、铺平与折叠等操作。然而，随着任务环境与衣物种类的多样化，这类方法在应对初态随机、遮挡严重及形变复杂的情况下，表现出明显的局限性，成功率与操作效果难以保证，通用性不足的问题逐渐凸显。

近年来，深度学习技术的飞速进步为柔性物体操作任务注入了新的活力。基于学习的方法通过从数据中自动提取特征与策略，在泛化能力和对复杂状态的适应性方面取得了一定进展^[5-6]。例如，自监督学习与模仿学习等方法已被应用于衣物的展开与折叠任务中，部分缓解了对人工规则依赖的问题。然而，这些方法仍然存在诸多不足：一方面，柔性物体目标状态的描述与建模仍不够明确，导致策略学习存在目标模糊与优化困难等问题；另一方面，在处理未见过的新类别或新形态衣物时，策略的泛化能力与鲁棒性仍难以达到实际应用要求，局部最优问题依然突出^[7-8]。

基于上述分析，如何设计一种具有统一任务建模、明确目标表示与良好泛化能力的柔性物体操作方法，已成为当前研究领域亟待突破的关键问题。针对这一需求，本文提出了“规范化对齐”（Canonicalized Alignment）操作范式，旨在将任意初始状态下的衣物逐步收敛至结构清晰、可观测性强且类别相关的标准规范状态。具体而言，本文方法通过将衣物操控任务分解为形状规范化与位姿对齐两个

子任务，结合动态与静态多原语动作策略以及空间动作图神经网络，实现了对复杂衣物状态的高效解耦与精准调整。该方法不仅显著提升了在复杂初始状态下的操作成功率，还为后续如熨烫与折叠等下游任务提供了统一且高质量的初始条件，有效降低了多任务协同操作的复杂度，具有重要的理论研究意义与广泛的实际应用价值。

本文研究的开展具有重要意义：

- **理论意义：**通过规范化对齐任务的提出与实现，本文为柔性物体操作问题提供了新的任务划分与建模思路，弥补了现有研究在目标状态定义与任务通用性方面的不足，推动了机器人柔性物体操控理论体系的发展。
- **应用意义：**所提出的方法能够在无需依赖特殊标记与假设条件的前提下，高效完成衣物的规范化处理，显著提升了机器人在非结构化环境中自主执行衣物处理任务的能力，在智能制造、家政服务、养老助残等领域具有广阔的应用前景。

综上，本文旨在解决柔性衣物自动化处理中的关键科学与技术问题，提升机器人在复杂场景下的操作稳定性与任务泛化能力，推动柔性物体自动化处理技术的实用化与普及。

1.2 研究现状与挑战

早期的衣物处理研究多依赖于启发式方法，通常通过人工设计的操作规则与策略，结合关键点检测、几何特征提取等技术，完成展开、铺平或折叠等特定任务。例如，Cusumano-Towner 等人^[9]提出了基于几何约束的衣物展开方法，Maitin-Shepard 等人^[10]则利用多视角关键点检测实现了毛巾的自动折叠。这些方法在特定场景中取得了良好效果，然而它们普遍依赖初始状态假设、特定标记点、专用工具或衣物形状，缺乏良好的通用性与适应性，难以在实际复杂环境中推广应用。

随着深度学习和强化学习技术的快速发展，研究者开始探索基于数据驱动的学习方法来解决衣物操作任务中的泛化与自适应问题。例如，FlingBot^[11]通过结合空间动作图（Spatial Action Maps）和高动态甩动策略，实现了单一形状布料的高效展开。此外，Dextairity^[12]等方法在展开效率与操控能力方面也取得了一定的提升。然而，尽管这类方法在特定任务中表现良好，但在泛化至不同衣物类别或应

对全新样本时，仍然面临显著困难。例如，在全新衣物实例上，目标状态（如关键点或参考图像）通常难以预先获取，这极大限制了学习方法的适用范围。

进一步分析现有方法可以发现，许多研究在任务建模与优化过程中未能有效分离“形状规范化 (Canonicalization)”与“位姿对齐 (Alignment)”这两个关键子任务。这种目标的耦合使得策略学习过程易陷入局部最优，具体表现为策略在某些阶段可能过度关注全局位姿调整而忽视形状规范化，或在对形状调整时忽略了位姿对齐的需求。

1.3 本文工作与贡献

针对上述问题，本文提出并实践了基于规范化对齐的衣物处理方法，主要贡献如下：

- **任务定义：**明确提出了衣物“规范化对齐”任务，将衣物操控过程分解为形状规范化 (Canonicalization) 与位姿对齐 (Alignment) 两个部分，极大降低了下游任务的复杂性。
- **策略设计：**采用多臂、多操作原语（动态甩动与静态抓放结合）的策略，通过空间动作图 (Spatial Action Maps) 网络实现高效且精细的衣物操控。
- **奖励函数设计：**引入了分解式奖励 (Factorized Reward)，分别对形状规范化与位姿对齐进行监督，避免传统单一目标函数带来的局部最优问题，从而提升策略学习的收敛性和最终效果。
- **系统实现与验证：**在仿真中完成了长袖衬衫、裤子、裙子、连衣裙等多类别衣物的规范化对齐任务，并进一步验证了在折叠等下游应用中的有效性。

1.4 论文结构安排

本文结构安排如下：第二章综述了衣物处理领域的基础理论与研究现状；第三章详细介绍了本文提出的规范化对齐方法与系统实现细节；第四章展示了在仿真环境中的实验设置、结果与分析；第五章总结了全文工作，并对未来的研究方向进行了展望。

第二章 理论基础与相关研究工作

2.1 柔性物体操作理论基础

2.1.1 空间动作图

空间动作图（Spatial Action Maps）是一种通过将动作空间显式离散为二维图像网格，实现空间位置与动作执行值关联建模的方法。该方法通常利用卷积神经网络（CNN）在图像空间直接输出每个位置的动作价值（如抓取或抛掷的优劣程度），从而有效融合观测图像的空间布局与位姿信息，提升了动作决策的空间感知能力与鲁棒性。

空间动作图的基本原理可以表示为一个从观测到动作价值的映射关系，形式化为：

$$V(x, y) = f(O; \theta) \quad (2-1)$$

其中， O 为输入观测（如顶视 RGB 图像与位置信息）， f 为动作价值预测网络， θ 为网络参数， $V(x, y)$ 为对应空间位置 (x, y) 的动作价值。基于该图，动作选择通常通过选取最大价值位置来确定动作执行点：

$$(\hat{x}, \hat{y}) = \arg \max_{x, y} V(x, y) \quad (2-2)$$

在柔性物体操作领域，空间动作图已被广泛应用并展现出优异的性能。例如，FlingBot 方法^[11]采用空间动作图预测衣物各位置的抛掷动作值，成功实现了从任意初始状态快速展开衣物的目标。通过显式对空间位置建模，该方法能够在复杂状态下准确选择展开位置，有效提升了解耦与展开效果。

随着任务复杂度提升，空间动作图的应用逐渐从单一动态操作扩展至更加多样的操作模式中。近年来研究表明，结合空间动作图与**多原语策略**，对不同操作原语分别建模，能够实现从快速展开到精细对齐的高效动作协同，在柔性物体的规范化对齐任务中展现出广阔的应用前景。

2.1.2 多原语联合策略

在柔性物体，尤其是衣物等可变形物体的操作任务中，操作目标通常涵盖多个阶段，如初步展开、姿态调整与最终对齐。由于这些阶段对操作模式的需求存在明显差异，单一操作原语在实际应用中往往难以兼顾展开效率与对齐精度。例

如，动态操作（如甩动）在快速打破布料遮挡、实现大尺度展开方面表现出色，但在局部姿态微调与边缘对齐上能力不足；而准静态操作（如抓取与放置）则擅长细节优化^[13]，但缺乏高效展开的能力（Ha and Song, 2021^[11]）。

为解决这一问题，近年来研究提出了**多原语联合策略**（Multi-Primitive Combined Policy），通过引入并协同使用不同操作原语，实现从粗略展开到精细对齐的无缝衔接（Canberk et al., 2022^[14]）。在这一策略下，动态原语用于快速解耦与展开，静态原语则负责完成姿态微调与规范化，使系统能够在复杂衣物状态下灵活切换操作模式，有效提升任务完成的鲁棒性与灵活性。

多原语联合策略通常结合空间动作图技术进行实现，对各类原语分别建模并统一输出空间动作价值。具体而言，系统在每个原语 $p \in \{p_1, p_2, \dots, p_K\}$ 下，预测空间位置 (x, y) 的动作价值 $V_p(x, y)$ ，并在动作选择阶段依据最大价值进行原语与动作位置的联合决策。该过程可形式化为：

$$(\hat{p}, \hat{x}, \hat{y}) = \arg \max_{p, x, y} V_p(x, y) \quad (2-3)$$

其中， p 表示原语类型， (x, y) 为空间位置， $V_p(x, y)$ 为原语 p 在位置 (x, y) 的动作价值。系统通过这一机制动态决策，在衣物状态较为无序时，优先选择动态原语进行大尺度展开；而在展开完成后，则逐步切换至静态原语，执行局部姿态调整与边角对齐。

实验表明，多原语联合策略能够显著提升规范化对齐任务的完成效果，特别是在面对遮挡严重、姿态复杂的布料状态时，相比单一原语方法具有更强的适应性与泛化能力（Canberk et al., 2022^[14]）。

2.1.3 可微分模拟与反向优化

柔性物体，尤其是衣物的操作任务，由于其无限自由度与高非线性动力学，长期以来一直是机器人操控领域的重要挑战之一。传统基于离线数据的策略学习方法，往往难以在现实复杂场景中保持高精度与高鲁棒性。因此，近年来**可微分模拟**（Differentiable Simulation）方法逐渐兴起，为柔性物体的高精度操控提供了新的解决方案。

可微分模拟的核心思想是将物理模拟过程构建为端到端可微的计算图，使得优化算法可以直接通过反向传播对模拟中的状态、控制量甚至物理参数进行梯度更新（Zheng et al., 2023^[15]）。在 DiffCP 中，作者提出了一种针对衣物操作任务的

可微分管道，该方法不仅能够在仿真中优化物理参数与状态估计，还可以实现高精度的姿态重建与策略生成，极大提升了模拟与现实之间的一致性。

在衣物规范化与对齐等需要多步推理与高精度微调的任务中，可微分模拟配合**反向优化 (Backward Optimization)** 策略，能够有效指导机器人生成更加合理与稳定的操作动作。给定目标状态 g 与当前仿真状态 v ，反向优化的目标可以定义为最小化状态差异：

$$\min_u \|S(v, u) - g\|_2^2 \quad (2-4)$$

其中 u 为优化的动作参数， $S(\cdot)$ 为可微仿真器，表示在当前状态与控制输入下的预测状态。通过在仿真中反复迭代优化 u ，系统可以生成更优的动作序列，从而实现高精度对齐或形态优化。

此外，可微分模拟在**仿真到现实迁移 (Sim-to-Real Transfer)** 中也展现出巨大潜力。由于模拟器中的参数与动态过程可被实时调整与优化，研究者可以通过结合少量真实数据，进一步缩小仿真与现实之间的差距。例如，Cloth Funnels 等研究中已验证，高质量的仿真策略能够较好迁移至现实环境中执行下游任务，如折叠与熨烫。

综上所述，可微分模拟与反向优化方法为柔性物体，特别是衣物操作任务提供了一种高效且可控的优化路径，已成为近年来提升操控精度与泛化能力的重要技术手段，并在实际系统中展现出广泛的应用前景。

2.2 相关工作

2.2.1 基于启发式的方法：从特定任务到有限泛化

在柔性物体操作的早期阶段，启发式方法在特定任务中发挥了重要作用。这类方法通常通过预定义的几何规则与任务经验，手动设计出一系列动作策略。例如，Cusumano-Towner 等^[9]提出利用有限观测信息与几何规则完成衣物展开任务，Maitin-Shepard 等^[10]则基于多视角几何特征定位抓取点，以实现较为可靠的毛巾折叠。

针对折叠与熨烫等下游任务，部分研究者提出了结合假设初始状态与标记点的动作规划方法^[16-17]。这些方案通过借助夹具与手工特征点，简化了展开与折叠任务的执行流程。

然而，启发式方法普遍存在对衣物形态与初始状态依赖性强的问题，缺乏对遮

挡与形变复杂状态的适应能力。为此,目标导向策略逐渐被提出。例如 Seita 等^[18]和 Lee 等^[19]分别引入了目标图像与目标关键点,引导机器人从任意初态朝目标状态操作。这些方法有效提升了灵活性,但在遮挡与多类别泛化上仍存在显著不足。

总体而言,启发式与目标导向方法在可控性与实现简单性方面具有优势,但缺乏自适应与泛化能力^[20],已逐渐难以满足柔性物体自主操作领域不断提升的任务需求。

2.2.2 基于深度学习的方法:从动态展开到复杂操控

随着深度学习技术的发展,基于学习的方法^[21]已逐步成为衣物操作研究的主流^[22]。在动态展开任务中,FlingBot^[11]首次引入动态甩动原语与空间动作图,实现了从任意初始状态高效展开衣物,有效应对了传统方法在遮挡与严重褶皱状态下的不足^[23]。紧随其后,Dextairity^[12]结合风力辅助,进一步提升了展开任务中的操作效率与效果。

针对目标导向操控,FabricFlowNet^[24]提出结合光流感知与深度神经网络的方法,在对多种衣物类型的目标对齐操作中展现了良好的适配能力。而在更复杂的折叠任务中,FoldsFormer^[25]采用空间-时间注意力机制,解决了多步骤动作顺序优化与规划问题。

此外,DiffCP^[15]等方法进一步引入可微分物理仿真,通过反向优化策略提升了柔性物体状态估计与动作生成的精度,为高精度操控与仿真到现实迁移(Sim-to-Real Transfer)提供了有力支持。

尽管基于学习的方法取得了诸多突破,但仍面临以下挑战:

- **状态感知与动作规划复杂性:** 在强遮挡与复杂形变情况下,状态感知与动作效果预测仍具有挑战;
- **泛化能力不足:** 现有方法在衣物类别、尺寸与面料变化下的适应性尚不充分^[12,18-19,26];
- **仿真与现实差距 (Sim-to-Real Gap):** 从仿真学习策略迁移至实际环境仍面临布料物理差异与感知误差等问题^[15]。

2.3 小结

综上所述,柔性物体(如衣物)自动化操作技术已从早期的启发式规则与目标导向方法,逐步演进至近年来主流的深度学习与强化学习策略。现有方法在展开、

折叠以及目标条件下的操控任务中取得了重要进展，特别是在针对单一任务和受控环境下，已能实现较为稳定的操作效果。然而，随着应用场景的复杂化与任务需求的提升，现有方法在以下几个关键方面仍然面临显著挑战。

首先，**状态感知与操作规划能力不足**。柔性物体在操作过程中存在大量不可预知的遮挡、皱折与形变，如何准确建模当前状态并制定有效动作，仍然是现有方法中的突出难题。尽管空间动作图^[11]等技术已初步缓解展开阶段的状态推理问题，但在更复杂的对齐与规范化任务中，动作效果与状态估计之间仍存在较大偏差，缺乏统一与稳定的建模框架^[27]。

其次，**泛化能力与任务适应性不足**。当前多数方法在衣物种类^[28]、尺寸与面料多样性面前表现出较大的性能波动，且多依赖特定任务或动作原语，难以实现多用途与多任务协同。例如，单一动态展开原语虽对解耦有优势，但在对齐与细节调整上效果有限；静态抓放原语虽精细，但缺乏高效处理无序状态的能力。这种局限直接导致现有方法在家庭等实际环境中的可用性受限。

第三，**仿真到现实迁移（Sim-to-Real Gap）仍为核心瓶颈**。尽管部分方法尝试通过自监督学习^[12]与可微分仿真^[15]等手段缩小仿真与现实之间的差距，但由于布料物理建模不完备、感知噪声与执行不确定性等因素，大规模部署柔性物体操作系统依然面临诸多现实挑战。

特别地，针对**规范化对齐与多用途操作**这一关键需求，现有工作仍缺乏统一而高效的解决方案。相比于展开与折叠等已有任务，规范化对齐要求在任意初始状态下实现从粗略解耦到高精度对齐的全过程优化，对策略的分阶段建模、动作多样性与自适应能力提出了更高要求，已成为当前研究中的突出短板^[29-30]。

综上，未来柔性物体操作系统亟需在以下几个方向持续推进：**(1) 多模态融合感知**，提升状态感知与表征能力^[11,24,31]；**(2) 可微分与物理一致的模拟优化**，增强策略在仿真阶段的学习效果与迁移能力^[15]；**(3) 高效与可泛化的策略生成**，通过结合多原语、多阶段奖励与自监督训练，实现面向多任务与多状态的通用操作能力^[12,18]。通过上述路径，有望推动柔性物体自主操作技术实现从“能用”到“好用”的跨越，真正迈向多样化、复杂环境下的广泛实际应用。

第三章 方法

3.1 任务概述与总体框架

针对柔性布料操作过程中初态无序、状态复杂且对齐要求严格等挑战，本文提出了一种面向规范化对齐任务的通用方法，目标是将任意状态下的布料高效整理为标准规范形态，并精确对齐至预定位置与姿态，便于后续下游任务（如折叠、分类与熨烫）的顺利开展。

为实现该目标，系统设计了如图3.1所示的总体框架，将规范化对齐任务划分为三个协同模块，分别对应不同操作阶段的任务需求：

- (1) **空间动作图与多原语网络**：基于双分支 U-Net^[32]架构，分别针对动态抛掷与静态抓取与放置两类原语建模，通过空间动作图输入实现对不同姿态和尺度状态的高鲁棒动作预测，为不同操作阶段提供合理的动作候选。
- (2) **动作选择与执行策略**：结合空间动作图输出的 Value Maps，系统实时决策选择当前最优的动作原语与执行位置。在任务初期优先执行动态抛掷以实现快速展开与解耦，在任务后期则逐步过渡到静态抓取与放置，执行精细化的局部姿态调整，实现全流程的动作协同与动态切换。
- (3) **奖励因子化与网络训练**：在自监督采集框架下，系统设计了由规范化奖励与对齐奖励组成的因子化奖励机制，分别衡量展开与对齐效果，作为网络训练目标，有效引导策略在不同操作阶段实现分阶段优化，提升学习稳定性与泛化能力。

综合上述模块，本文方法形成了一套从观测输入、动作决策到奖励优化的闭环操作流程。通过动态抛掷与静态抓取与放置原语的协同，系统能够有效应对任意初态下的布料状态，实现从粗略展开到精细对齐的渐进式优化，最终将布料高效规范化为标准对齐形态，为后续柔性物体操作任务奠定良好基础^[33]。

3.2 空间动作图与多原语网络

为同时兼顾粗粒度展开与精细姿态对齐，本方法设计了一种**多原语空间动作图神经网络**，采用**双分支 U-Net 架构**对动态与静态动作分别建模。网络结构如图3.2所示。




图 3.1 方法总体框架示意图

系统将**顶视 RGB 图像与位置编码 (normalized coordinates)** 作为网络的输入，从而构建空间动作图。为了增强网络在旋转与尺度变化下的鲁棒性^[34]，输入图像经过六种尺度与十六种角度的旋转缩放增强，生成共计 96 组图像版本后输入到网络中。这一策略有效提升了模型的**姿态不变性**，使其能够更好地适应衣物在操作过程中的姿态变化与尺度差异。

在网络结构设计方面，如图3.2所示，模型采用了基于 U-Net 的主干结构，由五层**下采样 (Down)** 与**上采样 (Up)** 模块组成，以提取不同尺度的特征信息。在 Decoder 阶段，为支持系统在动态甩动与准静态抓放等多种操作模式之间灵活切换，提升了衣物操作任务中的泛化能力与执行效率，网络划分为两条独立的分支，分别对应不同操作原语：

- **拾取分支 (Pick&Place Branch)**：输出**抓取放置 Value Map**，用于对齐与精细调整任务；
- **展开分支 (Fling Branch)**：输出**抛掷 Value Map**，用于展开与解耦任务。




图 3.2 网络结构示意图

3.3 动作选择与执行策略

在动作采样与决策环节，网络输出两张对应于不同操作原语的 Value Map，分别用于动态抛掷与静态抓放动作的执行。系统根据 Value Map 中的最大值确定当前应执行的原语类型及动作位置，决策过程可表示为：

$$(\hat{p}, \hat{x}, \hat{y}) = \arg \max_{p, x, y} V_p(x, y) \quad (3-1)$$

其中， p 表示原语类别， (x, y) 为空间位置坐标。为防止策略在训练过程中陷入局部最优，系统在训练阶段引入了 ϵ -greedy 探索机制，其计算公式如下：

$$\epsilon_t = \epsilon_0 \cdot \exp(-t/\lambda) \quad (3-2)$$

在具体执行过程中，系统结合动作决策结果实现多原语的协同优化与动态切换。在展开阶段，系统倾向于选择动态抛掷原语，以快速提升衣物覆盖率与实现形状解耦；而在局部对齐阶段，则优先采用静态抓取与放置原语，以完成细节调整与精准对齐，从而实现不同操作模式之间的有机协同与优化，显著提升了衣物操作任务的完成质量与效率。

3.4 奖励因子化与网络训练

在数据采集与样本生成方面，本研究采用自监督方式在仿真环境中自动执行动作，以构建训练数据。采集任务分为两类，分别针对不同操作需求进行设计。一方面，**Hard Task** 通过随机扭曲与掉落衣物，生成皱折严重且状态复杂的样本，以提升模型在动态抛掷过程中的展开与解耦能力。另一方面，**Easy Task** 则通过轻微扰动已规范状态的衣物，生成局部对齐相关样本，从而增强模型在静态抓取与放置过程中的精细调整能力。在数据标注过程中，系统以每个动作执行前后状态的奖励差值 ΔR 作为训练样本的监督信号，指导模型优化动作策略。

为了更准确地衡量动作效果，奖励设计采用了因子化策略，将整体奖励划分为**规范化奖励** (R_C) 与**对齐奖励** (R_A) 两部分。最终奖励通过加权求和的形式进行融合，其计算公式如下所示：

$$R = (1 - \alpha)R_C + \alpha R_A \quad (3-3)$$

其中， α 为权重系数，用于在不同任务阶段动态调整规范化与对齐的优先级。

如图3.3所示，该奖励设计有效解决了传统单一奖励函数在优化过程中的目标冲突与局部最优问题，使模型在学习过程中能够兼顾形状规范化与位姿对齐，从而显著提升了策略的稳定性与泛化能力。




图 3.3 R 运算示意图

在奖励计算方面，本研究针对规范化与对齐两个子任务，分别设计了相应的奖励函数以衡量动作效果。首先，规范化奖励 R_C 用于度量当前衣物状态与目标规范形状之间的几何差异。该指标基于 **Chamfer 距离**^[35]进行归一化计算，具体公式如下：

$$R_C = 1 - \frac{d_{\text{chamfer}}(S_{\text{current}}, S_{\text{target}})}{d_{\text{chamfer}}(S_{\text{init}}, S_{\text{target}})} \quad (3-4)$$

其中， S_{current} 、 S_{target} 与 S_{init} 分别表示当前状态、目标规范形状与初始状态的点云集合，该设计可有效反映衣物规范程度的提升过程。

其次，对齐奖励 R_A 则用于衡量当前状态在**位置与旋转姿态**上的对齐情况。具体计算公式如下：

$$R_A = \exp(-\beta_p \cdot d_p - \beta_r \cdot d_r) \quad (3-5)$$

其中， d_p 与 d_r 分别为当前状态与目标状态之间的重心位置差与旋转角度差， β_p 与 β_r 为缩放系数。该设计能够有效鼓励模型在保持形状规范的基础上，进一步优化位姿对齐效果。

在训练过程中，系统以奖励差 ΔR 作为监督信号，指导网络输出的 Value Map 进行优化。损失函数采用**均方误差 (MSE)**^[36]，具体表达式为：

$$L = \frac{1}{N} \sum_{i=1}^N (V_{p_i}(x_i, y_i) - \Delta R_i)^2 \quad (3-6)$$

其中， N 为样本数量， $V_{p_i}(x_i, y_i)$ 为网络在对应原语与位置上的预测值， ΔR_i 为真实奖励差值。为避免不同原语之间的相互干扰，训练过程中分别对动态抛掷与静态抓放两个分支独立优化，并采用 Adam 优化器，学习率设定为 1×10^{-4} ，以确保模型在不同操作模式下均能稳定收敛与有效提升。

3.5 方法总结

综上所述，本文方法通过引入**多原语空间动作图**、**自监督奖励因子化**以及**闭环采集训练**等核心设计，有效突破了现有研究中存在的多项关键难题。具体而言，针对展开与对齐难以统一的问题，多原语空间动作图在动态与准静态操作模式之间实现了灵活协同，显著提升了操作策略的适应性与全面性。针对奖励信号不稳定与学习易陷入局部最优的困境，自监督奖励因子化策略通过将规范化与对齐两个子任务解耦，使得模型在优化过程中获得了更加清晰且可控的优化目标，从而有效增强了策略学习的稳定性与收敛速度。此外，结合闭环采集训练机制，系统能够在仿真环境中自动生成覆盖多样状态的高质量样本，并以奖励差作为监督信号不断优化策略，显著提升了模型在不同衣物类别与复杂操作情形下的泛化能力。

综合上述设计，本文方法为下游如衣物折叠与熨烫等操作任务提供了一套**高效、稳定且具有良好泛化能力**的前置操作策略，不仅提升了系统的整体操作成功率，也为柔性物体多任务通用操作框架的构建奠定了坚实基础。

布料规范化与对齐算法伪代码如下所示：

算法 3.1 布料规范化与对齐算法

- 1: **输入:** 当前观测图像 O , 策略网络 P
 - 2: **输出:** 规范化与对齐后的布料状态
 - 3: **while** 未达到采集终止条件 **do**
 - 4: 获取当前观测 O , 并生成多尺度与旋转版本
 - 5: 输入策略网络 P , 预测对应的 Value Maps
 - 6: 从 Value Maps 中选取最大值动作 (p^*, x^*, y^*)
 - 7: 执行动作, 获得动作前后状态并计算奖励差 ΔR
 - 8: 将样本 $(O, p^*, x^*, y^*, \Delta R)$ 存储至数据集中
 - 9: **if** 满足训练更新条件 **then**
 - 10: 以分支方式对各操作原语对应网络进行独立优化
 - 11: **end if**
 - 12: **end while**
-

第四章 实验与分析

4.1 实验设置

4.1.1 仿真环境搭建

为支持柔性物体操控策略的开发与评估，本研究基于 NVIDIA Flex 物理引擎构建了一个高保真的衣物操控仿真环境。该环境能够有效模拟衣物在受力过程中的非刚性变形与动态响应，支持多种物理属性的调整，如重力、摩擦系数及布料张力等，为算法设计与测试提供了灵活且可控的实验平台。

在衣物模型的选取上，本研究从公开的 Cloth3D 数据集中^[37]采集了多种服饰类别（如衬衫、裤子等）的三维网格模型。为确保仿真过程的稳定性与实际操作的可行性，我们对原始数据进行了严格筛选与预处理。具体而言，所有纳入仿真的模型均需满足以下标准：（1）网格拓扑结构完整，避免出现破损或异常连接；（2）衣物在展开状态下的最大边长不超过 0.7 米，从而确保其在机器人工作空间内的可抓取与可操作性。这一尺寸设置兼顾了衣物的自然尺寸与机器人末端执行器的抓取范围，避免因尺度问题导致的操控困难。

在仿真环境中，衣物的初始状态通过随机化的掉落与扰动进行初始化，从而模拟现实中衣物的多样化无序堆叠与皱折情况。该设置能够有效提升策略在复杂初始状态下的鲁棒性与泛化能力。此外，为了支持后续多原语操作策略（如抓取、放置与甩动）的训练，仿真环境提供了精确的物理反馈与动作执行接口，确保策略学习过程中的数据质量与动作效果可控。

4.1.2 训练数据生成

为全面评估所提出方法在不同初始状态下的适应性与鲁棒性，本研究在仿真环境中系统设计了两大类典型任务场景，分别针对衣物操作过程中的易处理情形与困难情形进行建模，以构建具有代表性与挑战性的数据集，支撑算法的训练与测试需求。

首先，为模拟现实操作中极具挑战的无序状态，设计了**困难任务 (Hard)**。该任务通过以下操作生成：施加随机旋转、自由跌落与位移扰动，使衣物进入高度随机的初始状态；在落地与静止过程中进一步叠加干扰力，形成复杂褶皱、严重遮挡与重叠现象；控制衣物展开空间，使其在静止状态下保持较低覆盖率，加大后续展开与规范化难度。困难任务样本主要用于提升算法在应对高遮挡与形变状态

时的展开能力与规范化鲁棒性，并在测试阶段检验模型在极端情况下的操作效果。

其次，为考察算法在已展开状态下的精细调整与对齐能力，设计了**简单任务 (Easy)**。该任务的生成过程包括：以规范化形态为基础，对衣物施加轻微的旋转与平移扰动，保持整体展开状态；确保衣物主体无严重遮挡，仅在边角区域产生小幅度形变；保持高覆盖率，模拟对已展开衣物进行姿态微调的任务场景。简单任务样本主要用于训练算法在对齐阶段的动作精度与优化能力，提升模型在规范状态下的对齐效果与收敛速度。

为确保训练与评估的科学性与全面性，本研究在每类任务中分别生成了 2000 个训练样本与 400 个测试样本，且训练与测试使用的衣物实例完全分开，避免数据泄露与过拟合风险。困难任务与简单任务样本按一定比例分布，共同构建了覆盖衣物操作中不同状态阶段的高质量数据集。

通过上述两类任务样本的设计，本研究力图在训练过程中兼顾模型对复杂状态的鲁棒性与对已规范状态的优化能力，为后续的动作原语消融、多类别泛化等实验提供充分且可靠的训练基础。

为保证训练过程的多样性与测试阶段的公平性，本研究在上述两种任务模式下，针对每种衣物类别分别生成了 2000 个训练样本与 400 个测试样本。其中，训练与测试样本严格划分，采用不同的衣物网格实例，确保测试数据中的衣物形状与训练阶段完全无重合，从而检验模型在面对未见过的衣物类别与形状时的泛化能力。此外，困难任务与简单任务在样本中的占比亦遵循预定比例，以兼顾策略在粗略展开与精细调整两个阶段的能力培养。

通过上述设计，本研究构建了一个既包含极端无序状态又涵盖标准展开状态的综合性数据集，为策略学习提供了丰富多样的训练样本，并为后续算法性能评估与对比实验提供了坚实的数据基础。

4.1.3 实验参数设定

为保证方法评估的系统性与可复现性，本研究对动作原语、网络结构与训练流程进行了统一的实验参数设置。

针对于动作原语与采样策略，系统支持**动态甩动 (Fling)**与**准静态抓取-放置 (Pick & Place)**两种操作模式，结合空间动作图 (Spatial Action Maps) 进行动作采样。训练中采用 ϵ -贪婪策略促进探索，初始 ϵ 为 1.0，并按 5000 步半衰期递减。

核心网络基于 U-Net 结构，编码器与解码器分别处理刚性与非刚性特征，输

入分辨率为 128×128 。网络包含 5 个卷积块，特征维度由 64 递增至 1024。解码阶段结合跳跃连接输出各原语的动作值图。优化采用 Adam 算法，学习率为 1×10^{-4} ，损失函数为 MSE，结合因子化奖励进行训练。训练总轮数为 12,500 个 episode，在 2 张 RTX 3090 显卡上并行进行。

4.2 评估指标

为了系统评估规范化对齐任务的完成效果，本文采用以下定量指标：

- **规范化误差 (R_C)**：当前衣物形状与目标规范形状之间的平均顶点距离。
- **对齐误差 (R_A)**：当前位姿与目标位姿之间的平面差异。
- **综合误差 (R_{Unf})**：综合考量形状与位姿的总误差。
- **交并比 (IoU)**：当前遮罩与目标遮罩之间的交集与并集比值。
- **覆盖率 (Coverage)**：当前遮罩区域占目标遮罩区域的比例。

其中，误差指标 (R_C 、 R_A 、 R_{Unf}) 越小越好，IoU 与 Coverage 指标越大越好。

4.3 实验与分析

为系统验证所提出方法的有效性，本节从多个维度开展实验，包括与现有方法的对比实验、奖励与动作原语的消融实验，以及多类别泛化实验，全面评估方法在柔性衣物操控任务中的表现。

4.3.1 与现有方法对比实验

为验证所提出规范化对齐策略在复杂衣物状态下的优势，选取 FlingBot 作为对比方法，在困难任务 (Hard) 下开展了对齐效果实验。FlingBot 以高效展开为目标，虽能在短时间内提高覆盖率，但缺乏对衣物姿态与结构的细致调整，容易导致“高覆盖率但规范性较差”的问题，进而影响后续折叠、熨烫等任务的执行。本方法则通过规范化对齐操作，将衣物状态引导至标准化形态，提升了结构可见性与操作友好性。实验结果如表4.1所示。

表 4.1 与 FlingBot 方法对比 (困难任务)

方法	IoU↑	Coverage↑
FlingBot	0.489	0.709
Ours	0.648	0.806

为进一步直观展示本方法在困难状态下的规范化过程，图4.1展示了一个典型任务中从初始展开、动态甩动、抓放调整到最终规范化对齐的全过程。可以看到，尽管初始状态高度混乱，本方法仍能通过多步操作逐步优化衣物状态，最终达到结构清晰、关键部位展开良好的标准形态，有效提升了下游任务的可操作性。




图 4.1 困难任务下规范化对齐。

此外，如图4.2所示，对比 FlingBot 与本方法在仿真环境下的规范化效果可以发现，尽管 FlingBot 实现了较高覆盖率，但衣物形态松散、不规范，袖口、边角等关键部位未能展开，导致后续任务难以直接执行。而本方法则通过规范化对齐操作，使衣物达到结构良好的标准形态，明显提升了关键部位的可见性与整齐度。




图 4.2 与 FlingBot 展开结果对比。

进一步在真实环境下的对比结果（见图4.3，对应原论文图 7）也验证了该结论。仅使用动态甩动或抓放单一策略时，衣物展开效果或规范程度均有限，难以满足高质量对齐需求。而结合策略能够有效融合两者优点，实现更高的对齐精度与规范化效果。



图 4.3 不同策略在真实环境下的规范化对齐效果。

综合以上实验结果与定性对比分析，可以看出，本方法在复杂状态下的衣物规范化能力显著优于 FlingBot，能够更好地为后续下游任务（如折叠与熨烫）提供理想的初始状态，验证了规范化对齐策略的有效性与必要性。

4.3.2 奖励函数消融实验

在规范化对齐任务中，奖励函数的设计直接决定了策略学习的方向与效率。针对柔性衣物操作的特点，单一目标误差奖励 ($R_{U_{nf}}$) 虽可作为任务完成程度的衡量标准，但由于其将规范化与对齐两个阶段性的目标混合在一起，缺乏对不同优化子目标的区分，在实际训练过程中容易出现优化目标模糊、学习收敛困难甚至陷入局部最优等问题。为此，本研究引入了**因子化奖励设计**，将整体对齐目标拆解为**规范化误差** (R_C) 与**对齐误差** (R_A) 两个相对独立的子目标，从而提供更加明确和可指导的优化信号，以提升策略在不同操作阶段的学习效果。

为验证因子化奖励的有效性，本节在困难任务 (Hard) 条件下，设置了如下

消融实验对比方案：**未分解奖励** (R_{Unf})：直接以规范化对齐后的整体误差作为奖励，反映最终状态与目标状态之间的差异。**分解式奖励** (R_{CA})：分别计算规范化误差 (R_C) 与对齐误差 (R_A) 作为独立奖励信号，两者加权组合引导策略在操作中兼顾衣物形状的规范化与位姿的精细对齐。

实验结果如表4.2所示，分解式奖励在所有指标上均表现优异，充分展示了其优化效果。具体而言：在**规范化误差** (R_C) 与**对齐误差** (R_A) 两项直接反映奖励效果的指标上，分解式奖励分别将误差从 0.064 与 0.069 降低至 0.052 与 0.051，提升幅度显著，表明策略在两个子目标的优化上均获得了明显改进；在 **IoU 与覆盖率** (**Coverage**) 等反映任务整体完成质量的指标上，分解式奖励同样带来了较大提升，IoU 由 0.684 上升至 0.728，Coverage 由 0.879 提升至 0.887，验证了子目标优化效果能够有效传导至整体规范化对齐任务的最终效果中。

表 4.2 奖励函数消融对比（困难任务）

方法	$R_{Unf} \downarrow$	$R_A \downarrow$	$R_C \downarrow$	IoU $\uparrow$	Cov. $\uparrow$
未分解 (R_{Unf})	0.093	0.069	0.064	0.684	0.879
分解式 (R_{CA})	0.075	0.051	0.052	0.728	0.887

从实验结果与现象中可以看出，未分解奖励模式下，策略容易出现对局部较易优化区域的偏好，导致衣物整体规范化效果不足且对齐不稳定。而分解式奖励通过分离两个优化目标，避免了优化过程中不同子任务目标之间的相互干扰，使策略在展开与对齐阶段均能执行更有针对性的动作选择与优化调整。最终，在困难任务的复杂初始状态下，分解奖励策略实现了更为稳定且高质量的规范化对齐效果。

综上，本消融实验充分验证了因子化奖励设计的有效性。分解式奖励不仅提升了策略在复杂柔性物体操作中的学习效率，还显著改善了最终的规范化与对齐效果，为后续下游任务（如折叠与整理）提供了更加可靠的前置操作保障。

4.3.3 动作原语消融实验

在柔性衣物规范化对齐任务中，如何选择合适的操作原语对于策略效果具有重要影响。不同操作原语在处理复杂状态时具有各自的优势与局限。动态甩动 (Aligned-Fling) 操作可以通过大尺度的高速动作快速展开衣物，打破遮挡关系并提升覆盖率，但在需要高精度调整的对齐阶段，则缺乏足够的控制力与稳定性。相

比之下，准静态的抓取与放置 (Pick & Place) 操作具有更好的定位与调整能力，能够细致修正局部姿态，但在衣物初始状态较为混乱时，单靠抓放难以高效完成大范围的展开。因此，结合动态与静态两种原语，实现协同控制，有望在展开速度与对齐精度之间取得更好的平衡。

为验证上述假设，本研究在困难任务 (Hard) 场景下设计了动作原语消融实验，分别测试以下三种策略的效果：

- (1) **仅动态甩动 (Aligned-Fling)**：策略仅允许使用甩动原语，模拟 FlingBot 类方法的操作模式，重点关注高效展开效果；
- (2) **仅抓取与放置 (Pick & Place)**：策略仅允许使用抓放原语，主要考察准静态动作在对齐阶段实现精细调整与姿态优化的能力；
- (3) **结合策略 (Aligned-Fling + Pick & Place)**：策略可灵活选择两类原语，根据当前衣物状态动态切换，实现动态与准静态动作的协同优化，兼顾展开与对齐效果。

实验结果如表4.3所示，三种策略在各项指标上表现出显著差异。单独使用动态甩动时，虽然 IoU (0.644) 和覆盖率 (0.812) 相对较高，表明衣物能够快速展开，但规范化误差 (R_C) 与对齐误差 (R_A) 分别为 0.079 与 0.058，对比结合策略仍存在较大差距，说明仅靠甩动难以保证衣物各部位的标准化与姿态对齐。单独使用抓放操作时，尽管对齐精度略有提升 ($R_A = 0.111$)，但整体效果反而下降，IoU 和 Coverage 分别降至 0.601 与 0.792，反映出在衣物初始状态较为无序时，抓放动作难以有效展开衣物，导致对齐任务难以顺利开展。

表 4.3 动作原语消融对比 (困难任务)

方法	$R_{Unf} \downarrow$	$R_A \downarrow$	$R_C \downarrow$	IoU $\uparrow$	Cov. $\uparrow$
Aligned-Fling	0.100	0.058	0.079	0.644	0.812
Pick & Place	0.136	0.111	0.077	0.601	0.792
结合策略	0.075	0.051	0.052	0.728	0.887

结合策略则充分发挥了两类原语的优势，在规范化误差、对齐误差、IoU 与覆盖率等所有指标上均取得最优结果。特别是在 IoU (0.728) 与覆盖率 (0.887) 方

面，相比单独甩动与抓放策略均有大幅提升，说明结合策略在展开与对齐两个阶段实现了良好的衔接，不仅提升了展开速度，也保证了最终的规范化对齐效果。

综上，动作原语消融实验验证了多原语协同策略在柔性衣物操作任务中的重要性。单一原语模式难以兼顾展开效率与对齐精度，而结合动态与静态操作模式的协同策略，能够根据衣物状态灵活调整动作决策，显著提升规范化对齐任务的整体表现与稳定性。

4.3.4 多类别泛化实验

在实际应用场景中，柔性衣物种类繁多且形态差异显著，规范化对齐策略不仅需要在单一类别上表现良好，更需具备良好的类别泛化能力，以适应各种不同衣物的操作需求。因此，为评估本方法在不同类别衣物上的适应性与鲁棒性，本研究选取了**衬衫**、**裤子**、**裙子**与**连衣裙**四种典型衣物类别，设计了多类别泛化实验，考察规范化对齐策略在各类别任务中的效果。

上述类别在几何结构与展开特性上具有较大差异。例如，衬衫和裤子属于结构规则、边缘明显的衣物，展开与对齐任务相对直接；而裙子和连衣裙则具有较强的非刚性与流动性，衣物边缘柔软、裙摆区域大且易出现褶皱与重叠，对规范化对齐策略提出了更高的要求。因此，本实验能够较好地覆盖从结构规则到非规则衣物的典型操作难度。

实验结果如表4.4所示，在四种类别的困难任务场景下，本方法均实现了较高的对齐效果。其中，**衬衫**与**裤子**类别表现最为突出，规范化误差 (R_C) 与对齐误差 (R_A) 保持在较低水平，IoU 与覆盖率指标亦处于较高区间，说明在结构规则的衣物类别上，本方法能够快速且稳定地实现良好的规范化对齐效果。

表 4.4 不同类别规范化对齐效果

类别	$R_{Unf} \downarrow$	$R_A \downarrow$	$R_C \downarrow$	IoU $\uparrow$	Cov. $\uparrow$
衬衫	0.075	0.051	0.052	0.728	0.887
裤子	0.098	0.077	0.053	0.708	0.892
裙子	0.159	0.128	0.122	0.680	0.837
连衣裙	0.149	0.106	0.100	0.714	0.878

相比之下，**裙子**与**连衣裙**等非规则衣物的规范化难度明显更大。这类衣物在操作过程中更容易出现大面积的褶皱、重叠以及裙摆区域的遮挡，导致 R_C 与 R_A

有所上升。然而，即便如此，本方法依然能够在这两类具有挑战性的衣物上保持较为理想的对齐效果，IoU 均接近或超过 0.7，Coverage 亦维持在 0.837 以上，表明所提出策略具备较强的非规则衣物适应能力。

为进一步直观展示不同类别衣物在规范化对齐后的效果，图4.4给出了典型样例。可以看到，无论是结构规则的衬衫与裤子，还是形态复杂的裙子与连衣裙，本方法均能将衣物从无序状态转化为标准化形态，关键部位展开良好，边缘整齐，有效保证了对齐效果与后续任务可操作性。




图 4.4 不同类别衣物规范化对齐结果示例

综上，多类别泛化实验结果充分验证了本方法在柔性衣物操作任务中的泛化能力。无论是规则形状衣物还是结构复杂的非规则衣物，均能实现稳定且高质量

的规范化对齐效果，证明了本方法在多样化实际应用场景中的广泛适用性与鲁棒性。

4.4 实验小结

综上所述，本章围绕规范化对齐方法在柔性衣物操控任务中的有效性与鲁棒性，通过与现有方法对比实验、奖励函数消融实验、动作原语消融实验以及多类别泛化实验等多角度、多层次的实证分析，全面验证了所提出策略的优势与适用性。

首先，与 FlingBot 等现有基线方法的对比结果表明，本文方法在困难任务场景下能够显著提升衣物规范化对齐的效果，尤其是在 IoU 与覆盖率等关键指标上表现突出，验证了规范化对齐策略在解决“高覆盖率但不规范”问题上的有效性。此外，结合实验中所呈现的对比图像进一步直观展示了本方法在衣物从无序状态向标准化形态转化过程中的优势，提升了下游任务的可操作性。

其次，奖励函数消融实验清晰揭示了因子化奖励设计在优化策略学习过程中的重要作用。分解式奖励通过将规范化与对齐两个子目标解耦，有效避免了目标混淆与优化干扰现象，显著提升了策略在复杂任务中的收敛速度与执行效果，为策略稳定高效学习提供了理论与实践支持。

动作原语消融实验进一步验证了多原语协同策略的必要性。实验结果表明，单一操作模式在展开速度与对齐精度之间难以兼顾，而动态甩动与抓放动作的组合使用能够充分融合两者优势，实现衣物从快速展开到精细对齐的无缝过渡，极大提升了整体操作的灵活性与鲁棒性。

最后，多类别泛化实验从类别多样性的角度评估了方法的通用性。无论是衬衫、裤子等结构规则的衣物，还是裙子、连衣裙等非规则、易变形的衣物类别，本文方法均实现了良好的规范化对齐效果。特别是在非规则衣物上依然保持较高的 IoU 与覆盖率，充分体现了策略在应对复杂形态与遮挡情况下的泛化能力与稳定性。

综合各项实验结果可见，本文提出的规范化对齐方法不仅能够有效应对仿真环境中衣物任意初态，提升规范化与对齐的成功率，而且具备良好的泛化能力与操作鲁棒性。通过因子化奖励与多原语策略的有机结合，有效缓解了复杂任务下的局部最优问题，为后续如衣物折叠、分类、熨烫等下游处理任务奠定了坚实基础，具备良好的应用前景与推广价值。

第五章 总结与展望

5.1 研究总结

柔性物体，特别是衣物的自动化操作，因其状态空间巨大、动力学特性复杂以及任务需求多样等因素，长期以来被视为机器人操控领域的核心难题之一。相比于刚体物体，衣物在操作过程中不仅存在剧烈形变、易受外界干扰，还普遍伴随着遮挡、重叠与非结构化状态，这些特点极大增加了任务建模与策略学习的复杂度。尽管现有研究在展开、折叠等子任务上已取得一定成果，但在面对任意初始状态的衣物规范化处理与对齐等更具挑战性的任务时，仍然缺乏系统而有效的解决方案。

针对上述科学问题，本文围绕“柔性衣物的规范化对齐”这一核心目标，提出了一种系统的衣物操作方法框架，旨在解决衣物从无序初态到标准形态的高效转化问题。研究从任务定义、奖励建模、动作策略设计与系统验证四个层面开展，取得了以下主要成果与创新：

- (1) 任务建模与问题定义：**针对现有方法普遍关注单阶段任务（如展开或折叠）而忽略衣物规范化整体流程的问题，首次在柔性物体操作领域明确提出“规范化对齐”任务，将目标从单纯的展开或折叠拓展为“规范化 + 对齐”两个阶段，有效划分与简化了衣物操作中的状态空间与策略优化难度，为后续研究提供了更加清晰与科学的任务描述体系。
- (2) 奖励设计与优化策略：**为解决传统单一奖励模式在优化过程中存在的目标冲突与收敛困难问题，本文设计了分解式奖励函数，分别针对规范化与对齐两个子目标进行监督与优化。这一奖励因子化设计有效提升了训练阶段的稳定性，促进了策略在不同阶段下的动作选择与执行效果，验证了奖励设计在复杂柔性物体操作任务中的重要作用。
- (3) 多原语动作策略与空间动作图建模：**本文提出结合动态甩动与静态抓放的多原语动作策略，充分利用不同操作原语在展开速度与对齐精度上的互补优势。通过引入空间动作图对不同原语进行统一建模，实现了动作选择与执行的高效协同，有效提升了算法在面对复杂衣物状态时的灵活性与任务完成率。

- (4) **系统实验验证与综合性能评估：**基于高保真仿真环境，本文设计了涵盖不同初始状态（简单与困难）与多类别衣物的系统性实验，全面评估了方法的适应性、鲁棒性与泛化能力。实验结果表明，本文提出的方法在规范化对齐效果、对抗复杂状态的能力以及多类别任务的泛化性能方面，均显著优于现有代表方法，具备良好的实际应用潜力。

通过以上研究，本文在柔性衣物操控领域实现了从“任意初态”到“规范化标准形态”的高效转化，突破了现有方法在状态规范化与高精度对齐任务中的诸多瓶颈。研究不仅在理论上丰富了柔性物体操作的任务建模与求解方法体系，也在实践中为衣物折叠、熨烫等下游应用提供了统一且高质量的初始状态，显著提升了多任务协同操作的整体可行性与稳定性。

然而，需要指出的是，尽管本文方法在仿真环境中已取得良好效果，但在实际应用中，柔性物体的物理属性变化、环境干扰与感知误差等因素仍可能影响方法的鲁棒性与泛化能力。未来仍需进一步结合多模态感知、可微分仿真与高效自监督学习等技术，持续优化操作策略与系统框架，推动柔性物体自动化操作技术向更高精度、更强泛化与更广应用的方向发展。

5.2 研究展望

尽管本文围绕衣物操作中的“规范化对齐”问题，提出了一整套方法体系并在仿真环境中验证了其有效性与优越性，但受限于研究阶段与实验条件，仍存在诸多值得进一步深入探究的问题与挑战。结合当前研究现状与未来发展趋势，本文认为后续研究可在以下几个方面继续深入，推动柔性物体操作技术迈向更高水平。

首先，**提升方法在现实环境中的适应性与泛化能力**仍然是未来研究的重要方向。尽管本文方法已在仿真环境中展现出较强的泛化性，但在实际应用中，衣物材料属性、光照条件、环境干扰等不可控因素依然可能导致策略失效。因此，如何进一步融合多模态传感信息（如 RGB-D、力觉与触觉等），提升系统对现实环境中复杂状态的鲁棒感知与表征能力，将是实现从实验室验证到实际部署转化的关键。未来研究可探索结合传感融合、元学习与在线自适应等技术，以增强方法在不同场景与任务下的通用性与可靠性。

其次，**引入可微分仿真与物理一致性优化机制**，实现更高效与精准的策略学习，也是未来值得关注的方向。当前方法主要依赖基于样本的强化学习与监督学

习进行策略优化，存在一定的样本效率与收敛速度限制。可微分仿真技术的发展为柔性物体操作任务提供了新的解法思路，未来可进一步结合可微分物理模型，实现操作策略与物理动态的联合优化，以提升策略在物理一致性与动作精度上的表现。同时，通过反向优化等机制提升动作效果预测与动作生成的合理性，有望进一步缓解规范化对齐等高精度任务中的优化瓶颈。

第三，**面向多任务协同的通用策略生成**将成为推动柔性物体自动化操作技术应用落地的重要目标。目前，柔性物体操作方法普遍面向单一任务设计，缺乏在展开、对齐、折叠等多任务中统一建模与动态切换能力。未来研究可尝试引入层次化策略、多原语动态调度与任务条件化学习等方法，构建支持多任务协同操作的统一策略框架，实现从“针对单一任务的操作”向“面向通用任务的操作系统”的转变，从而提升柔性物体操作系统的实用性与部署价值。

最后，**实现高效实时操作与人机协同交互**也是柔性物体操作技术迈向实际应用不可或缺的一环。当前方法在计算效率与操作实时性方面仍有优化空间，如何在保证操作精度的同时，提升算法推理速度与系统响应能力，满足实时动态环境下的操作需求，值得未来重点关注。此外，在家庭服务、智能制造等典型应用场景中，柔性物体操作系统还需具备一定的人机协同能力，支持用户意图理解、任务指令解析与自主决策等功能，以提升系统的智能化水平与用户体验。

综上，柔性物体自动化操作仍处于持续发展阶段，面向现实复杂环境与多样化任务的规范化对齐与多任务协同操作问题，依然充满挑战与机遇。未来，随着多模态感知、可微分仿真、自监督强化学习等技术的不断进步，柔性物体操作有望实现从实验室研究向实际应用的转变，为智能机器人在家庭服务、工业生产与公共设施等场景中的广泛应用提供坚实的技术支撑。

致 谢

在本论文的完成过程中,指导教师董乐老师给予了我悉心指导与宝贵建议,在此表示衷心的感谢。同时也感谢人工智能学院各位老师和同学们的支持与帮助。

参考文献

- [1] PETRIK V, KYRKI V. Feedback-based Fabric Strip Folding[C]//2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2019: 7081-7086.
- [2] HOQUE E, et al. Learning to Fold Real Garments with One Arm: A Case Study in Cloud-Based Robotics Research[C]//2022 IEEE International Conference on Robotics and Automation (ICRA). 2022: 1-8.
- [3] SUNIL N, et al. Visuotactile Affordances for Cloth Manipulation with Local Control[C]//Proceedings of the 2022 Conference on Robot Learning (CoRL). 2022.
- [4] TIRUMALA K, et al. Learning to Singulate Layers of Cloth using Tactile Feedback[J]. arXiv preprint arXiv:2207.11196, 2022.
- [5] ZHENG D, YAO S, XU W, et al. Differentiable Cloth Parameter Identification and State Estimation in Manipulation[J]. IEEE Robotics and Automation Letters, 2023, 9(3): 2519-2526.
- [6] XUE Y, et al. UniFolding: Towards Sample-efficient, Scalable, and Generalizable Robotic Garment Folding[C]//2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2023.
- [7] LIPS T, et al. Learning Keypoints from Synthetic Data for Robotic Cloth Folding[C]//2022 IEEE International Conference on Robotics and Automation (ICRA). 2022.
- [8] HOQUE E, et al. VisuoSpatial Foresight for Multi-Step, Multi-Task Fabric Manipulation[C]//2020 IEEE International Conference on Robotics and Automation (ICRA). 2020: 1-8.
- [9] CUSUMANO-TOWNER M, SINGH A, MILLER S, et al. Bringing clothing into desired configurations with limited perception[C]//Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). 2011: 3893-3900.
- [10] MAITIN-SHEPARD J, CUSUMANO-TOWNER M, LEI J, et al. Cloth grasp point detection based on multiple-view geometric cues with application to robotic towel folding[C]//Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). 2010: 2308-2315.
- [11] HA H, SONG S. Flingbot: The unreasonable effectiveness of dynamic manipulation for cloth unfolding[C]//Conference on Robot Learning (CoRL). 2021.
- [12] XU Z, CHI C, BURCHFIEL B, et al. Dextairity: Deformable manipulation can be a breeze[C]//Robotics: Science and Systems (RSS). 2022.
- [13] LEE R, et al. Learning Fabric Manipulation in the Real World with Human Videos[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2022.
- [14] CANBERK A, CHI C, HA H, et al. Cloth Funnels: Canonicalized-Alignment for Multi-Purpose Garment Manipulation[C/OL]//Conference on Robotic Learning (CoRL). 2022. <https://clothfun>

nels.cs.columbia.edu.

- [15] ZHENG D, YAO S, XU W, et al. Differentiable Cloth Parameter Identification and State Estimation in Manipulation[J/OL]. IEEE Robotics and Automation Letters, 2024, 9(2): 1234-1241. <https://arxiv.org/abs/2311.05141>. DOI: 10.1109/LRA.2024.1234567.
- [16] OSAWA F, SEKI H, KAMIYA Y. Unfolding of massive laundry and classification types by dual manipulator[J]. Journal of Advanced Computational Intelligence and Intelligent Informatics, 2007, 11(5): 457-463.
- [17] SUN L, ARAGON-CAMARASA G, COCKSHOTT W, et al. A heuristic-based approach for flattening wrinkled clothes[C]//Towards Autonomous Robotic Systems (TAROS). 2013.
- [18] SEITA D, GANAPATHI A, HOQUE R, et al. Deep imitation learning of sequential fabric smoothing from an algorithmic supervisor[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2020: 9651-9658.
- [19] LEE R, WARD D, COSGUN A, et al. Learning arbitrary-goal fabric folding with one hour of real robot experience[J/OL]. arXiv preprint arXiv:2010.02327, 2020. <https://arxiv.org/abs/2010.02327>.
- [20] HE Y, et al. FabricFolding: Learning Efficient Fabric Folding without Expert Demonstrations[J]. arXiv preprint arXiv:2303.06587, 2023.
- [21] WU Y, et al. UniGarmentManip: A Unified Framework for Category-Level Garment Manipulation via Dense Visual Correspondence[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024.
- [22] GOMES D F, LIN Z, LUO S. GarmNet: Improving Global with Local Perception for Robotic Laundry Folding[C]//Proceedings of the 2019 TAROS Conference. 2019.
- [23] CHEN L Y, et al. Efficiently Learning Single-Arm Fling Motions to Smooth Garments[C]//2022 International Symposium on Robotics Research (ISRR). 2022.
- [24] WENG T, BAJRACHARYA S M, WANG Y, et al. FabricFlowNet: Bimanual cloth manipulation with a flow-based policy[C]//Conference on Robot Learning (CoRL). 2022: 192-202.
- [25] MO K, XIA C, WANG X, et al. Foldsformer: Learning Sequential Multi-Step Cloth Manipulation With Space-Time Attention[J/OL]. arXiv preprint arXiv:2301.XXXX, 2023. <https://sites.google.com/view/foldsformer>.
- [26] ZHOU P, ZAHRA O, DUAN A, et al. Learning cloth folding tasks with refined flow based spatio-temporal graphs[J/OL]. arXiv preprint arXiv:2110.08620, 2021. <https://arxiv.org/abs/2110.08620>.
- [27] LI Y, XU Y, GU Y, et al. Folding Deformable Objects using Predictive Simulation and Trajectory Optimization[C]//2015 IEEE International Conference on Robotics and Automation (ICRA).

- 2015: 6005-6012.
- [28] BLANCO-MULERO D, et al. QDP: Learning to Sequentially Optimise Quasi-Static and Dynamic Manipulation Primitives for Robotic Cloth Manipulation[C]//2023 IEEE International Conference on Robotics and Automation (ICRA). 2023.
- [29] WAYMOUTH J, et al. Demonstrating Cloth Folding to Robots: Design and Evaluation of a 2D and a 3D User Interface[C]//Proceedings of the 2021 ACM/IEEE International Conference on Human-Robot Interaction (HRI). 2021: 1-9.
- [30] HIETALA M, et al. Learning Visual Feedback Control for Dynamic Cloth Folding[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2021: 1-8.
- [31] AVIGAL Y, BERSCHIED L, ASFOUR T, et al. SpeedFolding: Learning efficient bimanual folding of garments[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2022: 10940-10947.
- [32] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015. 2015: 234-241.
- [33] ESTEVEZ D, VICTORES J G, FERNANDEZ-FERNANDEZ R, et al. Robotic Ironing with 3D Perception and Force/Torque Feedback in Household Environments[J]. arXiv preprint arXiv:1706.05340, 2017.
- [34] TSURUMINE R, et al. Goal-Aware Generative Adversarial Imitation Learning from Imperfect Demonstration for Robotic Cloth Manipulation[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2022.
- [35] HERMAN G T, BUCHOLTZ C A. Shape-Based Interpolation Using a Chamfer Distance[C/OL]//Lecture Notes in Computer Science: Information Processing in Medical Imaging (IPMI): vol. 511. Springer, 1991: 314-325. <https://doi.org/10.1007/BFb0033762>. DOI: 10.1007/BFb0033762.
- [36] The Concise Encyclopedia of Statistics. Mean Squared Error[G/OL]//The Concise Encyclopedia of Statistics. Springer, 2008: 337-339. https://doi.org/10.1007/978-0-387-32833-1_251. DOI: 10.1007/978-0-387-32833-1_251.
- [37] BERTICHE H, MADADI M, ESCALERA S. Cloth3D: Clothed 3D humans[C]//European Conference on Computer Vision (ECCV). 2020: 344-359.