

大学生论文检测系统
文本复制检测报告单(全文标明引文)

No: ADBD2026R_2024041014333220260522204107603758124366

检测时间: 2026-05-22 20:41:07

篇名: f6e50b6d204f40ba9063ad8e83d0e575. pdf
作者: 李钰杰
指导教师:
检测机构: 西安电子科技大学本科生院(接口)
文件名: 通过API上传
检测系统: 大学生论文检测系统
检测类型: 大学生论文
检测范围: 中国学术期刊网络出版总库
中国博士学位论文全文数据库/中国优秀硕士学位论文全文数据库
中国重要会议论文全文数据库
中国重要报纸全文数据库
中国专利全文数据库
图书资源
优先出版文献库
大学生论文联合比对库
互联网资源(包含贴吧等论坛资源)
英文数据库(涵盖期刊、博硕、会议的英文数据以及德国Springer、英国Taylor&Francis 期刊数据库等)
港澳台学术文献库
互联网文档资源
源代码库
CNKI大成编客-原创作品库
机构自建比对库
时间范围: 1900-01-01至2026-05-21

检测结果

去除本人文献复制比: 1.6%

跨语言检测结果: -

去除引用文献复制比: 1.6%

总文字复制比: 1.6%

单篇最大文字复制比: 0.4% (动态环境下基于高精度三维重建的物体级语义SLAM研究)

重复字数: [508] 总段落数: [6]
总字数: [31289] 疑似段落数: [4]
单篇最大重复字数: [128] 前部重合字数: [23]
疑似段落最大重合字数: [141] 后部重合字数: [485]
疑似段落最小重合字数: [115]



文字复制部分 1.6%
无问题部分 98.4%

指标: ☐ 疑似剽窃观点 ☒ 疑似剽窃文字表述 ☐ 疑似整体剽窃 ☐ 过度引用

相似表格: 0 相似公式: 没有公式 疑似文字的图片: 0

0% (0)	0% (0)	中英文摘要等 (总2453字)
2.9% (141)	2.9% (141)	第一章绪论 (总4913字)
0% (0)	0% (0)	第二章理论基础 (总4485字)
1.9% (132)	1.9% (132)	第三章基于语义增强3DGS的视觉导航算法GSGuide (总7122字)
1.4% (115)	1.4% (115)	第四章实验与结果分析 (总8118字)
2.9% (120)	2.9% (120)	第五章总结与展望 (总4198字)

指导教师审查结果

指导教师:

审阅结果:

审阅意见: 指导老师未填写审阅意见

1. 中英文摘要等

总字数: 2453

相似文献列表

去除本人文献复制比: 0%(0) 去除引用文献复制比: 0%(0) 文字复制比: 0%(0) 疑似剽窃观点: (0)

原文内容

班级 2203019
学号22009200957
本科毕业设计论文
题目基于3D高斯泼溅的视觉导航算法实现与优化
学院计算机科学与技术学院
专业计算机科学与技术
学生姓名李钰杰
导师姓名毋芳芳
摘要

实例图像目标导航 (IIN) 任务是具身视觉领域的核心任务之一, 它要求智能体在未知环境中, 定位目标图像中所包含的特定物体实例。该任务的核心挑战在于: 智能体需要在不同视角下识别物体, 定位, 同时还需要排除干扰。在既有方法中, 传统的鸟瞰图 (BEV) 方法存在三维几何信息缺失、实例纹理特征丢失等问题, 而基于3D高斯 (3DGS) 的导航方法语义存在着标签与几何纹理参数脱节的问题。

针对上述问题, 本文提出了一种基于语义增强3D高斯泼溅的模块化视觉导航算法框架GSGuide。该框架设计并实现了三阶段模块化导航策略, 包括环境探索与语义地图构建, 目标定位与相机位姿对齐, 以及智能体规划路径与导航。在目标定位与相机位姿估计阶段, 提出了图像匹配初始粗定位以及图像扭曲 (Warping) 渲染精修的高效定位策略。同时, 该框架还通过为每个高斯引入了可训练语义向量, 构建了同时编码了几何、纹理与细粒度语义信息的统一地图表示方案。所提框架使得智能体能够精准地识别和定位目标物体, 并能导航至目标所在位置。

基于Habitat仿真平台和具有挑战性的HM3D数据集, 论文对所提方法完成了仿真实验。实验结果表明, GSGuide的导航成功率从原始GaussNav的0.725提升至0.778, SPL指标达到了0.585, 同时所有语义分割损失指标上均取得了显著改善, 验证了所提方法在实例级目标识别与定位方面的有效性, 不仅在理论上丰富了具身视觉导航的地图表示方法与目标定位技术, 也在实践中为服务机器人的物品查找、室内巡检等实际应用提供了可行的技术方案。

关键词: 3D高斯泼溅语义增强实例图级图像目标导航图像扭曲

ABSTRACT

Instance ImageGoal Navigation(IIN)is a core embodied vision task,requiring an agent to locate a specific object instance from a goal image in an unexplored environ- ment.Its core challenges lie in cross-view object recognition,precise localization,and robust distractor rejection.Traditional Bird’ s-Eye View(BEV)methods lack 3D geome- try and instance textures,while 3D Gaussian Splatting(3DGS)-based navigation suffers from misalignment between semantic labels and geometric-texture parameters.

To tackle these issues,we propose GSGuide,a modular visual navigation frame- work based on semantically enhanced 3D Gaussian Splatting.It features a three-stage pipeline:environment exploration and semantic map construction,target localiza- tion and camera pose alignment,and path planning and navigation.In the localization stage,we design an efficient two-step strategy:coarse localization via image matching, followed by refinement via image warping rendering.By adding trainable semantic vec- tors to each Gaussian,we build a unified map encoding geometry,texture,and fine-grained semantics,enabling accurate target recognition,localization,and navigation.

Extensive experiments on the Habitat simulator with the HM3D dataset show that GSGuide achieves a 0.778 success rate(up from GaussNav’ s 0.725)and an SPL of 0.585. It also significantly reduces all semantic segmentation losses,validating its effectiveness in instance-level recognition and localization.This work advances embodied navigation map representations and localization techniques,and supports real-world applications in- cluding service robot object retrieval and indoor inspection.

Keywords:3D Gaussian Splating Semantic Enhancement Instance ImageGoal Navigation Image Warping

目录

第一章绪论..... 1

1.1研究背景与意义.....1

1.2研究现状.....2

1.2.1可微分渲染领域的相关研究.....2

1.2.2相机定位领域相关研究.....3

1.2.3视觉导航领域相关研究.....5

1.3本文主要工作与贡献.....6

1.4论文结构安排.....6

第二章理论基础.....7

2.13DGS渲染方法.....7

2.1.1原始3D高斯泼溅技术.....7

2.1.2特征与语义增强的3DGS扩展.....8

2.2图形扭曲与对齐技术.....9

2.2.1传统光度误差位姿优化.....9

2.2.2Warping Loss高效位姿修正.....9

2.2.3使用鲁棒特征匹配的初始位姿估计.....10

2.3虚拟环境与IIN任务.....10

2.3.1Habitat仿真平台与HM3D数据集.....10

2.3.2实例级图像目标导航任务.....11

2.3.3基于地图的IIN方法演进.....11

第三章基于语义增强3DGS的视觉导航算法GSGuide.....13

3.1任务总体概览.....13

3.2环境探索与语义高斯构建.....14

3.2.1简化后的3D高斯表示.....14

3.2.2语义高斯构建.....15

3.3高斯导航.....18

3.3.1分类器.....18

3.3.2匹配与定位.....19

3.4路径规划.....21

第四章实验与结果分析.....23

4.1实验准备.....23

4.1.1实验环境.....23

4.1.2实验用数据集.....23

4.1.3智能体配置.....24

4.1.4智能体的动作空间.....24

4.1.5评估指标.....24

4.2与现有方案的对比.....25

4.2.1端到端baseline方法.....25

4.2.2先进方法对比.....26

4.2.3SOTA对比.....26

4.3消融实验.....27

4.3.1消融实验设置与结果.....27

4.3.2语义渲染监督有效性.....28

4.3.3位姿精修Warping Loss有效性.....29

4.3.4消融实验结论.....30

4.4误差分析.....31

4.4.1语义错误识别.....31

4.4.2场景建立质量不完善.....31

第五章总结与展望.....35

5.1研究总结.....35

5.2研究展望.....36

致谢.....39

参考文献.....41

2. 第一章绪论		总字数：4913
相似文献列表		
去除本人文献复制比：2.9%(141) 去除引用文献复制比：2.9%(141) 文字复制比：2.9%(141) 疑似剽窃观点：(0)		
1	21e94a186e3b4917b9699b6da422dc5b. pdf 王鹏凯 - 《大学生论文联合比对库》- 2025-05-06	1.6% (79) 是否引证：否

2	9c0608f10de143dc905b596710348981. pdf	1.6% (79)
	- 《大学生论文联合比对库》- 2025-05-08	是否引证: 否
3	基于随机游走的图注意力网络数据预测研究	0.8% (39)
	赵晟(导师: 赖晓晨) - 《大连理工大学硕士论文》- 2024-05-01	是否引证: 否
4	私有云环境下通信平台及其自动化测试的设计与实现	0.6% (30)
	陈慧楠(导师: 胡光岷) - 《电子科技大学硕士论文》- 2012-04-01	是否引证: 否
5	薛雯昊-基于单目图像的视觉重定位	0.5% (23)
	薛雯昊 - 《大学生论文联合比对库》- 2025-05-01	是否引证: 否
6	薛雯昊-基于单目图像的视觉重定位	0.5% (23)
	薛雯昊 - 《大学生论文联合比对库》- 2025-05-02	是否引证: 否

原文内容

第一章绪论

1.1研究背景与意义

视觉定位作为具身智能与计算机视觉领域的核心任务，要求智能体能够通过视觉感知的方法估计相机在预先构建的环境地图中的位姿。得益于近年来大规模且逼真的三维场景数据集的出现以及用于测试具身导航仿真器的开发，具身视觉导航在近年来取得了显著的发展。

在具身视觉导航中，一个关键问题是描述目标物体的方法。向智能体分配任务的常见方式是下达自然语言指令，类似于“导航到目标A”、“到达目标B”等。但当场景中相同类型的物体包含多个不同的实例时，这种分配任务的方式会产生较大的歧义，智能体常常会出现误识别或者无法识别的问题。为解决这一歧义，Krantz等人提出了实例级目标导航IIN[1]。

如图1.1所示，在IIN任务中，智能体接收到一张包含了特定目标物体的图像，目标是在限定时间步内找到这个特定的物体实例的位置并到达该物体附近。这个任务要求智能体首先能够识别目标物体的具体类别，其次能够从多个不同角度来观察具有相同类别的目标物体，以确定所观察的物体实例是否与目标物体相吻合。

为解决上述的问题，现有方法所采取的策略主要是通过引入鸟瞰图（2DBEV）来处理该任务。这种显式的地图表示方式能够大幅降低内存开销，但对于三维场景中存在的大量的物体细节，其表示能力依然受到较大局限性，所保存的语义信息和2D的几何信息对于智能体多视角观察候选目标物体这一需求支撑力有限。此外，BEV地图也难以保存目标物体的实例级信息，而这一信息对于区分同类多个物体或者需要细粒度物体交互的任务至关重要。

为克服BEV地图局限性，Lei[2]等人又针对IIN任务提出一种全新的基于3D 高斯泼溅的导航框架GaussNav[2]。GaussNav通过使用语义高斯地图的表示方法，将几何、语义与实例级特征的表示融为一体，得以成功应用在边界探索、语义高斯构建、高斯导航三阶段任务流程。同时，Gennady Sidorov等人又针对相机位姿定位提出了GSplatLoc[3]——一种新颖的视觉定位框架。该框架将基于结构的粗位姿估计与基于高斯渲染而优化的图像扭曲位姿优化策略整合到一个统一的端到端

1
2
1
2
目标物体
相似物体

图1.1实例IIN任务

流程中，完成相机位姿估计。这些技术在视觉导航中的目标物体描述与相机定位等具有挑战性的任务中，表现出显著的性能。

本文也基于GaussNav[2]框架，融合了GSplatLoc[3]中针对高斯渲染优化后的位姿精修算法，提出了一个系统整合了几何、语义与实例级特征的地图表示的导航框架——GSGuide。

1.2研究现状

我们首先简要讨论可微分渲染领域的相关研究，然后对相机定位进行全面的概述，最后在对实例级图像目标导航进行讨论。

1.2.1可微分渲染领域的相关研究

为实现逼真的三维场景构建，早期的方法主要围绕神经辐射场（NeRF）[4]提出。NeRF[4]利用单个多层感知器（MLP）来表示场景，通过沿像素光线行进并查询MLP

获取不透明度和颜色值来执行体绘制。MLP表示可以通过多视角信息优化一最小化渲染损失，从而实现高质量的新视角合成。但NeRF[4]的主要局限性在于训练速度较慢，且对存储需求较高，在IIN这种对于实时性要求较高的任务中，其适用性受限。

与NeRF[4]不同的是，三维高斯泼射（3DGS）[5]采用可微分光栅化技术，对需要光栅化的基元进行迭代处理，这与传统图形学中的光栅化方式类似。利用三维场景天然的稀疏性，3DGS[5]能够以高保真的表示方式捕捉三维场景，同时能够显著提升渲染效率，降低存储开销。

关于三维高斯泼射技术发展的全面综述[6]强调了该方法的通用性及其在各个领域的应用。凭借这些优势，越来越多的研究者开始探索各种创新方向，例如可变形或动态高斯[7-8]、网格提取与物理模拟[9-10]，以及在同时定位与地图构建（SLAM）中的应用[11-12]。

近些年来，3DGS技术在语义增强与轻量化方向取得了重要进展，为导航任务提供了更加强大的场景表示能力。

SeG-Gaussian[13]提出语义引导的3D高斯优化框架,利用语义掩码识别重建薄弱区域,通过空间正则化抑制高斯重叠,显著提升了稀疏观测下的语义重建质量。但该方法的语义信息仅作为优化引导信号,并未嵌入高斯本身的参数表示中,无法直接支持后续的语义感知导航决策。

Gsplatloc[3]在3DGS中引入原生稠密特征场,无需预训练蒸馏即可实现特征渲染,在保持实时性的同时显著提升了跨视角匹配鲁棒性。然而其特征向量是通用视觉特征,缺乏明确的语义含义,无法直接用于目标类别过滤和实例区分,在存在多个相似物体的IIN任务中容易产生误匹配。

SAGE-3D[14]则将3DGS升级为可执行、语义对齐、物理对齐的环境基础,发布了包含1000个室内场景的InteriorGS[14]数据集。但该方法的语义对齐是在高斯构建完成后进行的独立后处理步骤,无法实现语义与几何参数的端到端联合优化,仍然存在语义错位问题。

鉴于高斯表示的显式特性提供了丰富的环境数据,3DGS[5]能够增强基于地图的视觉导航中的决策能力,可以有效地用于指导自主智能体的导航。

1.2.2 相机定位领域相关研究

视觉定位是机器人导航的核心技术,旨在估计相机相对于预构建地图的位姿。

早期的视觉重定位方法主要依赖图像检索技术,即通过查询图像与已知位姿的图像数据库进行比对来推断近似位置。尽管这类方法计算效率高,但可扩展性较差,且对于动态环境中的定位精度会显著下降。

结构化的特征匹配方法通过利用运动恢复结构(SFM)生成的三维点云来提升定位性能。这类方法在查询图像提取的特征与三维地图之间建立显式的2D-3D对应关系,通常结合随机抽样一致性(RANSAC)算法,使用透视n点(PnP)求解器来计算相机位移[15]。虽然这类方法能够实现较高的定位精度,但在处理大规模环境时,会带来巨大的内存开销。

位姿回归方法采用深度神经网络直接从输入图像估计相机位姿,大幅度降低了对大规模三维地图的依赖。这类方法将环境结构整合到网络架构中,能够实现端到端的训练。然而,受限于泛化能力,其性能通常不如基于结构的方法。绝对位姿回归方法(APR)技术在计算效率和精度之间取得了一定的平衡,而场景坐标回归(SCR)通过学习紧凑的场景表示进一步提升了性能。但场景坐标回归方法需要进行大量的优化才能达到最优精度,这限制了其在实时场景中的应用[16]。

同样,神经辐射场[4]和3D高斯泼溅技术[5]的出现,实现了高保真的新视角合成,可以在训练阶段实现数据增强,提升特征匹配能力,从而推动了视觉定位技术的发展。基于NeRF[4]的方法虽然有效,但往往存在推理速度慢、训练时间长以及存储开销较大的问题,在IIN[1]这种对于实时性要求较高的任务中,其适用性受限。

随着3DGS技术的发展,基于3DGS的定位流程开始被广泛应用于IIN任务中。

GSCPR[17]GS-CPR[15]提出基于3D高斯泼溅的高效相机位姿精修方法,利用3DGS渲染高质量参考图像和深度图,结合通用3D基础模型MASt3R建立2D-2D对应关系,无需训练专用特征提取器即可实现高精度位姿优化。但该方法为纯几何的定位框架,完全不利用语义信息,无法区分同一类别的不同实例,这对于需要精确识别目标实例的IIN任务来说是致命的缺陷;此外,它依赖外部的全局位姿估计器提供初始值,不具备实例级的粗定位能力,且难以满足实时导航的需求。

HGSLoc[18]提出分层3D高斯定位框架,结合全局特征检索与局部渲染精修,有效解决了大尺度场景下的定位漂移问题。然而其粗定位阶段采用的全局特征检索方法,对于外观相似的不同实例区分能力不足,在IIN任务中容易将相似物体误判为目标。

这些方法虽然在定位精度上有所提升,但均未充分考虑IIN任务中“实例级区分”的特殊需求。本文正是针对上述问题,基于GSplatLoc[3]核心框架设计了“语义过滤+细粒度特征匹配+渲染精修”的三阶段定位策略,在统一的3D高斯泼溅流程中结合了基于结构的关键点匹配与基于渲染的位姿精修,利用快速可微渲染和光度扭曲损失最小化提升了定位精度。

1.2.3 视觉导航领域相关研究

实例级图像目标导航任务(IIN)[1]自2022年提出以来,经历了从基于BEV地图到模块化方法到基于3DGS的新一代方法演进。2025年,GaussNav[2]提出了一种基于3DGS的模块化视觉导航框架,首次将3DGS[5]引入了IIN任务,取得了突破性的进展,而在此之后又有更多的研究者提出了相关工作。

SAGE-3D[14]面向IIN任务提出语义对齐3D高斯框架,通过后处理方式将语义信息与高斯几何进行对齐,但该方法的语义对齐是在高斯构建完成后进行的独立步骤,无法实现语义与几何参数的端到端联合优化,仍然存在语义错位问题。

UnitedVLN[19]提出了基于通用3D高斯泼溅的连续视觉语言导航框架,通过统一的高斯地图表示实现了跨场景的泛化导航,在多个VLN基准上取得了SOTA性能。该方法首次证明了3DGS不仅适用于单场景的实例导航,还能支持跨场景的连续长程导航任务,显著拓展了3DGS在具身智能领域的应用边界。但该方法主要面向自然语言指令导航设计,其语义表示仅包含粗粒度的类别信息,缺乏对实例级细粒度特征的编码能力,无法有效区分同一类别的不同物体实例,难以直接应用于需要精确识别特定实例的IIN任务;此外,其位姿估计依赖于外部SLAM系统,没有针对实例级目标定位进行专门优化,在存在多个相似物体的场景中容易出现定位错误。

上述工作虽然在不同方面推动了3DGS导航技术的发展,但仍存在两个核心局限性,也是本文工作的主要切入点:

- 语义表示不充分:大多数方法(如GaussNav[2]、UnitedVLN[19])仍采用静态语义标签或粗粒度语义表示,无法实现语义与几何、纹理参数的端到端联合优化,导致语义错位和实例区分能力不足;
- 实例定位精度不足:现有定位方法对于相似实例的区分能力有限,且缺乏针对IIN任务的专用位姿精修机制,在复杂场景中容易出现目标误匹配和定位偏差。

基于此,引出本文主要工作与贡献:基于语义增强的3D高斯泼溅的模块化视觉导航框架GSGuide。

1.3 本文主要工作与贡献

本文对既有的GaussNav[2]与GsplatLoc[3]两个核心框架进行了研究,就地图数据采集、在线语义高斯构建、目标位姿估计做了优化工作,提出了一种基于语义增强3D高斯泼溅的模块化视觉导航框架GSGuide。主要贡献包括:

- 高斯语义信息融合与监督优化:引入YoIo26[20]语义分割模型输出的物体实例语义,为高斯新增可微语义标签。复用原版3DGS中RGB颜色渲染逻辑,实现渲染通道数自适应适配RGB和语义渲染两种模式。实现了语义高斯的高效构建。
- 高斯在线构建:使用高斯增量训练模式,并利用多线程技术在Habitat模拟器[21]中采集Habitat-Matterport 3D(HM3D)[22]数据即实时使用已有数据集渲染高斯,大幅度简化流程。
- 对齐目标图像的具体位姿:利用GSplatLoc[3]提供的基于高斯渲染优化后的图像扭曲技术,通过将目标图像与高斯渲染结

果进行对齐，实现了多视角生成与目标位姿精确估计。

- 目标导航：利用优化后的语义高斯表示，结合基于LightGlue+Disk[23-24]的特征提取与匹配方案的目标位姿估计，实现了目标导航。

1.4 论文结构安排

本文结构安排如下：第一章系统介绍本文的相关背景与意义；第二章综述了三维重建、位姿对齐、视觉导航的基础理论知识；第三章详细介绍本文工作的具体方法与实现细节；第四章展示了在仿真环境中的实验设置、结果与分析；第五章总结了全文工作，并对未来研究方向进行展望。

指 标
疑似剽窃文字表述
1. 基础理论知识；第三章详细介绍本文工作的具体方法与实现细节；第四章展示了在仿真环境中的实验设置、结果与分析；第五章总结了全文工作，并对未来研究方向进行展望。
3. 第二章理论基础
总字数：4485
相似文献列表
去除本人文献复制比：0%(0) 去除引用文献复制比：0%(0) 文字复制比：0%(0) 疑似剽窃观点：(0)
原文内容

第二章理论基础

本章系统阐述本文工作所依赖的核心理论与技术基础，包括3D高斯泼溅（3D Gaussian Splatting, 3DGS）[5]的渲染原理、基于图形扭曲的位姿对齐技术，以及具身智能领域的虚拟仿真环境与实例图像目标导航（Instance ImageGoal Navigation, IIN）[1]任务定义。同时，结合现有研究的局限性，给出本文提出的语义增强3DGS 表示、高精度特征匹配初始位姿估计与高效位姿精修方法的理论依据。

2.1 3DGS渲染方法

3D高斯泼溅（3DGS）[5]是2023年提出的一种新型的神经渲染技术，凭借其实时的渲染速度、高保真的成像质量和高效的训练特性，迅速成为三维场景表示与重建领域的的研究热点，为视觉定位、具身导航等下游任务提供了全新的场景表示方式。

2.1.1 原始3D高斯泼溅技术

3D高斯的核心思想是使用大量各向异形的3D高斯基元离散化表示连续的三维场景。其中，每个高斯通过一组可优化参数完整编码其几何外观与属性。其原始参数集定义为：

$$\Psi_i = \{y_i, q_i, s_i, \alpha_i, c_i\} \quad (2-1)$$

其中， i 代表第 i 个高斯， $y_i \in \mathbb{R}^3$ 为高斯中心的三维世界坐标， $q_i \in \mathbb{R}^4$ 为表示旋转的单位四元数， $s_i \in \mathbb{R}^3$ 为三个轴向上的缩放因子， $\alpha_i \in [0, 1]$ 为不透明度， $c_i \in \mathbb{R}^3$ 为通过球谐函数（Spherical Harmonics, SH）编码视角的相关颜色。

3DGS的渲染过程基于可微分光栅化实现，分为三个核心步骤：

- 1. 视锥裁剪与深度排序：筛选出位于相机视锥内的高斯，并按照深度从近到远排序；
- 2. 2D投影：将3D高斯的均值和协方差矩阵投影到图像平面，得到2D椭圆的中心和协方差矩阵；
- 3. Alpha混合：对每个像素，按照深度顺序累加所有覆盖该像素的高斯的颜色贡献，最终得到渲染图像：

$$\sum C(p) = c_i \alpha_i T_i \quad (2-2) \quad i \in N(p)$$

其中 $N(p)$ 为覆盖像素 p 的高斯集合， $T_i = \exp(-\sum_{j=1}^N \alpha_j)$ 为累积透射率。与神经辐射场（NeRF）[4]相比，3DGS[5]避免了耗时的光线步进操作，同时训练速度提升一个数量级以上，为需要快速场景重建和在线渲染的具身人实时性应用提供了可行方案。

2.1.2 特征与语义增强的3DGS扩展

原始的3DGS仅能编码场景的几何与外观信息，无法直接支持语义理解、特征匹配等高级视觉任务。为此，研究者们提出了多种增强的3DGS表示：

- 特征3DGS（Feature-3DGS）：在原始的3DGS参数基础上，为每个高斯新增一个 V 维度的特征向量，通过蒸馏预训练的2D特征提取器的输出结果进行联合优化。复用原有RGB渲染框架，仅在渲染时自适应通道数，即可同时输出 RGB图像和特征图，实现了几何、外观与视觉特征的统一表示。GSplatLoc[3]正式基于这一框架，将轻量级XFeat[25]特征蒸馏到3DGS[5]中，通过2D-3D特征匹配实现粗略位姿估计。

- 语义高斯（Semantic Gaussian）：GaussNav[2]方法针对导航任务的需求，对原始3DGS[5]进行了轻量化的改造，将高斯约束为各项同性（仅保留单个缩放因子），赋给每个高斯添加离散于一类标签。将Mask R-CNN[26]的语义分割结果在初始化点云阶段赋予每个高斯的语义标签，为实例级目标识别提供了基础。

而现有增强型高斯表示存在明显的局限性：GSplatLoc[3]的特征向量是通用视觉特征，缺乏明确的语义；GaussNav[2]的语义标签是离散类别，而且仅在初始化点云阶段为离散语义标签赋值，但并不参加后续的监督与优化过程。为解决这一问题，本文提出的GSGuide框架在原始3DGS[5]参数基础上，遵从GaussNav[2][2]论文所用到的6个COCO ID[27]类别和一个背景类别，为每一个高斯新增一个7维度的可训练的语义向量 l_i ，并使用在COCO-Stuff[28]数据集上预训练的Yolo26[20]语义分割模型所输出的语义信息与实例识别结果联合进行训练。COCO ID编号与语义类别以及对应向量索引关系如表2.1所示：

可微的语义向量能够同时编码类别于一和实例特征，使每个高斯成为几何、外观与细粒度语义的统一载体，为后续的语义感知位姿估计和实例级目标匹配提供了更强大的表示能力。

表2.1 COCO ID编号与语义类别以及对应7维向量索引关系表

语义类别 背景椅子沙发电视机盆栽植物马桶床 对应的COCO ID类别 - 56 57 58 59 61 62 对应语义向量索引 0 1 2 3 4 5 6

2.2图形扭曲与对齐技术

视觉定位与导航的核心是精确估计相机在三维场景中的位姿。基于3D高斯渲染的位姿精修技术通过最小化渲染图像与真实观测图像的差异，能够显著提升初始位姿的精度。其中，图形扭曲（Warping）技术是实现高效位姿优化的关键。

2.2.1传统光度误差位姿优化

早期基于神经渲染的位姿精修方法（例如iNeRF[29]）采用迭代渲染的策略：在每次优化步骤中，根据当前估计的位姿渲染图像，计算其与查询图像的光度误差（如L1损失、SSIM损失），然后通过反向传播更新位姿参数。这种方法虽然原理简单，但每次迭代都需要完整的渲染过程，因而计算成本较高，效率较低，难以满足IIN任务的实时性要求。

2.2.2 Warping Loss高效位姿修正

为解决传统方法的效率问题，PNeRFLoc[30]首次提出了单次渲染+图形扭曲（Warping）的位姿的位姿优化框架。其核心思想是：仅需要根据初始粗位姿渲染一次参考图像和深度图，然后通过扭曲函数将参考图像的像素投影到查询图像平面，计算像素级差异作为损失函数（Warping Loss），避免了重复渲染。

GSplatLoc[3]将原本设计为NeRF[4]服务的Warping Loss与3DGS框架适配，与其快速渲染能力相结合，进一步提升了位姿精修效率。

具体而言，对于一张查询图像 q 和一个粗略位姿 (R, t) ，参考图像像素 p_i 的深度为 $z_r(p_i)$ ，那么扭曲函数 $W(\cdot)$ 定义为：

$$W(p_i, R, t, R', t') = \Pi(R(R' - I)\Pi^{-1}(p_i, z_r(p_i)) - R' - I t') + t \quad (2-3)$$

其中 $\Pi(\cdot)$ 为相机投影函数， $\Pi^{-1}(\cdot)$ 为反投影函数， R 为相机旋转矩阵， t 为相机平移向量。

基于扭曲函数的RGB损失定义为：

$$\Sigma \text{Lrgb-warp} = \|Y(q, W(p_i)) - Y(q_r, p_i)\|^2 \quad (2-4)$$

其中 $Y(q, p)$ 为查询图像 q 在像素 p 处的RGB值， $Y(q_r, p_0)$ 为参考图像 q_r 在像素 p 处的RGB值。

实验表明，该方法在RTX 3060 GPU上仅需约1.25秒即可完成250次迭代的位姿优化，显著快于NeRF-based方法。

2.2.3使用鲁棒特征匹配的初始位姿估计

Warping Loss的优化效果高度依赖估计的初始粗位姿的质量。如果初始位姿偏差过大，后续的位姿精修容易陷入类似随机的对齐步骤。GSplatLoc[3]采用XFeat[25]特征提取器进行2D-3D匹配，虽然速度快，但依赖于预先训练好的带有64维蒸馏特征的高斯，在场景较大的空间中，或者相似物品较多的情况中，匹配精度受限，存储开销较大，效率也会下降。

为提升初始位姿的鲁棒性，本文所提的GSGuide框架采用DISK局部特征提取器[24]+LightGlue特征匹配器[23]的组合方案。DISK[24]能够提取高重复率、高辨识度的关键点和描述子，而LightGlue[23]作为一种基于Transformer的轻量级特征匹配器，能够在保持高精度的同时实现实时匹配。GaussNav[2]方法已验证了该组合在实例级目标匹配任务中的有效性。

本文从所有参与3DGS训练的图像中提取DISK[24]特征，与导航目标图像通过LightGlue[23]进行匹配，将最为相似的训练图像作为估计初始位姿，为后续基于Warping Loss的精修算法提供了可靠的初始值，也大幅度降低了位姿估计时间和存储开销。

2.3虚拟环境与IIN任务

在具身视觉导航领域，虚拟环境为导航算法的开发与评估提供了标准化、可重复的测试平台。

2.3.1 Habitat仿真平台与HM3D数据集

Habitat[21]是由Meta AI开发的高性能具身智能仿真平台，专为大规模室内导航任务设计。它支持物理真实的渲染、刚体物理模拟和多智能体并行训练，能够在单GPU上实现每秒数千帧的仿真速度，大幅提升了算法的开发效率。

本文采用的Habitat-Matterport 3D (HM3D) [22]数据集是目前最大规模的真实室内场景3D重建数据集，包含1000多个真实住宅和商业建筑的高质量3D扫描模型，覆盖400多个房间类型和200多个物体类别。每个场景都提供了精确的几何重建、语义标注和相机参数，被广泛应用于具身导航、三维视觉等领域的研究。

2.3.2实例级图像目标导航任务

实例级图像目标导航IIN[1]任务的设定如下：在一个未知环境中，仅向智能体提供一张目标物体的图像，智能体需要通过自主探索环境，找到并导航到该目标物体的具体实例。与传统的物体目标导航（ObjectNav）不同，IIN[1]要求智能体区分同一类别的不同实例（如两把外观相似的椅子），并且目标图像的拍摄视角、相机参数与智能体的观测可能存在显著差异。

IIN任务的核心挑战包括：

1. 跨视角目标识别：智能体需要从不同视角识别目标物体，克服视角变化带来的外观差异；
2. 相似实例区分：存在多个同类物体的环境中，准确区分目标实例与干扰实例；
3. 探索与利用的平衡：智能体需要在探索位置环境和利用已有信息定位目标之间取得平衡。

2.3.3基于地图的IIN方法演进

现有IIN方法主要基于鸟瞰图（Bird's-Eye View, BEV）[31-33]地图表示，通过投影语义信息到2D平面实现环境建模。然而，BEV地图丢失了场景的3D几何信息和物体的纹理细节，无法进行细粒度的实例级匹配，导致智能体需要频繁靠近物体进行验证，降低了导航效率。

GaussNav[2]方法首次将3DGS引入IIN[1]任务，提出了语义高斯地图表示，通过保留物体的纹理细节，实现了直接从目标图像到场景实例的匹配，无需额外的验证步骤，将HM3D数据集上的SPL指标从0.347提升至0.578。

本文所提框架GSGuide在GaussNav[2]的基础上，通过引入可训练语义向量增强高斯的细粒度表示能力，结合DISK+LightGlue[23-24]的高精度位姿估计和GSplatLoc[3]中提到的Warping Loss的高效位姿精修，进一步提升语义高斯地图的重建精度和实例匹配的准确性，从而实现更高效、更鲁棒的IIN导航。

相似文献列表

去除本人文献复制比：1.9%(132) 去除引用文献复制比：1.9%(132) 文字复制比：1.9%(132) 疑似剽窃观点：(0)			
1	动态环境下基于高精度三维重建的物体级语义SLAM研究	1.8% (128)	
	高群海(导师：赵德双;赵秀国) - 《电子科技大学硕士学位论文》 - 2024-04-24		是否引证：否
2	3200102698_叶彬宏_基于三维高斯表征的可微重建和位姿优化	0.8% (57)	
	叶彬宏 - 《大学生论文联合比对库》 - 2024-05-22		是否引证：否

原文内容

第三章基于语义增强3DGS的视觉导航算法GSGuide

本章提出了基于语义增强3DGS的视觉导航算法GSGuide，给出具体实现方法，包括任务总体概览，环境探索与语义高斯地图构建过程，高斯导航实现逻辑以及路径规划实现方法。

3.1任务总体概览

在实例级图像目标任务（IIN）中，当新回合e开始时，智能体将获得一张目标图像Ig，该图像展示了指定的物体实例Og。智能体的目标是在环境中导航至该指定实例Og所在的位置。在每个时间步t，智能体获取观测信息包括RGB图像 It、深度图像Dt以及传感器位姿数据Pt。智能体需要利用这些观测信息来决策并执行动作at。当智能体执行停止动作时，仅当智能体处于目标物体指定的空间范围内，该回合才判定为成功。

如图3.1所示，为完成上述IIN任务，本文提出了一种极简的面向视觉导航的模块化框架，主要包含三个阶段：环境探索与语义地图构建、目标定位与相机位姿对齐、导航。

- 目标定位与相机位姿估计
 - 目标图像
 - 估计初始位姿
 - 位姿精修
- 智能体场景探索与信息收集
 - 场景环境探索
 - 收集观察信息
- 智能体
 - 场景环境
 - 语义高斯构建
 - 环境探索与语义高斯构建
 - 智能体规划路径与采取行动
 - 智能体导航
 - 匹配
 - 定位

图3.1面向视觉导航的模块化框架整体流程

在一个全新的环境中，智能体需要先通过探索环境，收集环境观测数据，包括RGB图像、语义、深度等，利用这些信息来构建一个语义高斯地图作为后续的导航基础；随后，利用已有的构建好的语义高斯地图，与目标图像中的实例物体进行相似度匹配，确定目标物体；利用包含目标物体的初始训练位姿信息作为初始位姿，通过图像对齐技术逐步从初始位姿对齐到目标图像拍摄位姿，作为最终导航点；获得最终导航点后，整个IIN任务简化为点导航任务，进而进入智能体动作规划与执行阶段。

下面对这三个主要阶段的核心进行详细描述。

3.2环境探索与语义高斯构建

3.2.1简化后的3D高斯表示

与原始的3DGS[5]不同，本文所使用的高斯是经过简化的。保留了原始3D高斯的基元表示核心与可微分渲染能力，本文提出的高斯核心参数表示为：

$\Psi_i = \{c_i, \mu_i, r_i, o_i, l_i\}$ (3-1)

其中，i代表第i个语义高斯； $c_i \in \mathbb{R}^3$ 代表每个高斯的RGB颜色向量； $\mu_i \in \mathbb{R}^3$ 表示每个高斯中心坐标； $r_i \in \mathbb{R}$ 表示每个高斯的半径； $o_i \in [0, 1]$ 表示每个高斯的透明度； $l_i \in \Delta_6$ 表示每个高斯所代表的7个语义类别的概率分布，满足非负性与归一化约束。

原始3DGS为了实现照片级别的真实感渲染，使用3阶球谐函数（Spherical- Harmonics, SH）编码每个高斯的颜色。每个高斯的RGB通道各需要9个颜色系数总共27个颜色系数。这样可以实现同一个物体的不同观察视角对应的不同颜色编码，以达到例如金属物体不同角度的反光颜色不一样的效果。

而IIN任务中，导航的核心需求是识别物体、理解几何场景，对实时性要求较高，而不是照片级别的真实感渲染。因此本文抛弃了基于球谐函数的颜色编码方式，而是将每个高斯简化为只使用3维RGB颜色向量的颜色编码方式。具体原因如下：

1. 物体的整体颜色和纹理特征已经足够支撑实例级匹配需求；
 2. Habitat-Sim模拟器提供的虚拟场景中本身并没有基于球谐函数的不同角度的颜色表示方式。
- 这样以来，渲染质量虽略有下降，但换来的是参数量减少90%，渲染速度大幅提升，更加贴合IIN任务的实时性需求。
- 同时，本文还将高斯约束为各向同性（仅保留单个缩放因子）。原始3DGS使用各向异性来拟合三维场景结构。对于每个高

斯而言，各个方向因缩放因子不同，不同的高斯看起来更像是大小、朝向均不同的椭球体。这需要每个高斯存储3个缩放因子，分别对应x，y，z三个轴的长度以及1个四元旋转参数来表示椭球体的方向。这种方法对于拟合平面、柱体等平面或者细长结构的拟合能力很强，几何重建度较高。

而本文则进一步将所有高斯约束为各向同性，退化为一个完美球体。这样一来，三个轴的缩放因子完全相同，只需要一个标量半径r即可表示；球形的各向同性使得高斯不再旋转参数。这原因如下：

- 1. 智能体在探索与导航时只需知道障碍物与物体的大致位置，不需要毫米级别的精确度；
- 2. 球形高斯已足够表示场景的整体结构与物体的实例形状；

这种方法进一步降低了参数数量，从原始的3个缩放因子与一个旋转四元数变为一个标量半径r，几何参数减少86%，在进一步降低内存占用的同时显著的提升了渲染效率，贴合IIN任务的实时性要求。

3.2.2 语义高斯构建

原始的3DGS的RGB渲染过程如下：给定一组3D高斯和相机位姿，首先将所有高斯按照深度从近到远进行排序；随后将每个3D高斯投影到图像平面形成 2D椭圆；最后通过alpha混合操作按照深度顺序累加每个像素的颜色贡献，得到最终的渲染图像。像素p=(u, v)的渲染颜色可以表示为：

$$I(p) = \sum_{i=1}^n c_i f_i(p) (1 - f_j(p)) \quad (3-2) \quad i=1 \quad j=1$$

其中，权重函数fi(p)定义为：

$$f(x) = \exp(-\frac{\|x - \mu\|^2}{2r^2}) \quad (3-3)$$

其中，通过3D高斯的投影计算得到2D高斯的中心μ和半径r：

$$\mu_{2D} = K E_t \mu_d, r_{2D} = f_r d, d = (E_t \mu)_z \quad (3-4)$$

公式中，K为相机内参矩阵，Et为包含了相机旋转和平移信息的外参矩阵，f为相机的焦距，d为第i个高斯在相机坐标系下的深度值。

与原版3DGS不同，本文提出的GSGuide框架可同时可微渲染深度图和轮廓图，用于后续的高斯致密化和参数更新。像素p处的渲染深度D^(p)和轮廓S^(p)分

别为：

$$D(p) = \sum_{i=1}^n d_i f_i(p) (1 - f_j(p)) \quad (3-5) \quad i=1 \quad j=1$$

$$S(p) = \sum_{i=1}^n r_i f_i(p) (1 - f_j(p)) \quad (3-6) \quad i=1 \quad j=1$$

语义高斯的迭代渲染过程包含两个交替执行的步骤：高斯致密化与语义地图更新。高斯致密化是指在每一帧新观测到来时初始化新的高斯，而语义高斯更新步骤则是通过可微渲染技术优化所有高斯参数。流程如图3.2所示，智能体的RGB

位姿
-
位姿
◆
高斯致密化
语义高斯更新
语义高斯损失计算
Cross Entropy
Loss
DICE Loss
Focal IoU
Loss
损失函数
语义高斯渲染
◆
位姿
渲染
G
T
语义分割
G
T
图像位姿
◆
+

图3.2语义高斯渲染流程

观测通过Yolo26模型进行语义分割，得到分割结果 C_t 。在高斯致密化过程中的高斯初始化阶段，为每个高斯的语义标签 l 赋予初始值。随后，通过可微渲染技术，将所有高斯的语义渲染结果与真实语义图进行对比，计算出所有高斯的语义损失，进行参数更新。

GaussNav在实现过程中仅将语义信息赋予高斯离散语义标签，在优化阶段跳过了梯度跟踪。本文通过优化语义标签渲染过程，采用与RGB相同的渲染逻辑，但不参与 α 混合操作，而是选取贡献度最大的高斯所带有的语义为每个像素渲染一个 v 维语义向量，经softmax将 v 维向量表示为各语义类别概率，实现了语义标签的梯度跟踪，实现后续的语义监督与优化过程。

在时刻 t ，高斯致密化会通过比较基于 $t-1$ 时刻高斯在当前位姿 P_t 的渲染结果

与真实RGB观测图像，在现有已经构建好的高斯因没有覆盖而无法表示的区域新增高斯。本文参考Keetha[11]等人方法，基于致密化掩码 $M(p)$ 确定需要添加高斯的像素位置。计算公式如下：

$$M(p) = (S^-(p) < 0.5) + (D(p) < D^-(p)) \cdot (L1(D^-(p)) > 50 \cdot MDE) \quad (3-7)$$

式中， $(S^-(p) < 0.5)$ 表示现有高斯密度不足的区域， $(D(p) < D^-(p)) \cdot (L1(D^-(p)) > 50 \cdot MDE)$ 表示真实深度中位于预测深度方向的前方且深度误差大于50倍中值深度误差（MDE）的区域。

完成当前帧的高斯致密化后，本文通过可微渲染和梯度下降优化更新所有高斯中的所有参数。这一过程等价于键辐射场拟合到已知位姿图像的经典问题，通过计算RGB、深度、语义分割损失以及他们的加权损失，来更新每个高斯中的参数。具体而言，总损失定义如下：

$$L_{total} = \lambda_{rgb} L_{rgb} + \lambda_{depth} L_{depth} + \lambda_{seg} L_{seg} \quad (3-8)$$

其中， L_{rgb} 为渲染图像与真实RGB观测图像的L1和SSIM组合损失，具体定义为：

$$L_{rgb} = \lambda_{L1} \cdot L1(I_{render}, I_{gt}) + \lambda_{SSIM} \cdot (1 - SSIM(I_{render}, I_{gt})) \quad (3-9)$$

深度损失定义为：

$$L_{depth} = L_{depth} = 1 \cdot |M| \sum_{(h,w) \in M} |D_{render}[h,w] - D_{gt}[h,w]| \quad (3-10)$$

其中， $D_{render} \in R^{1 \times H \times W}$ 代表渲染得到的深度图， $D_{gt} \in R^{1 \times H \times W}$ 代表真实深度图， M 代表有效像素掩码， $|M|$ 代表掩码 M 中有效像素的数量。

语义损失包含了 L_{ce} 交叉熵损失、 L_{dice} DICE损失，以及基于IoU的Focal IoU损失 L_{focal_iou} 。语义总损失定义为：

$$L_{seg} = \lambda_{ce} L_{ce} + \lambda_{dice} L_{dice} + \lambda_{focal_iou} L_{focal_iou} \quad (3-11)$$

交叉熵损失定义为：

$$L_{ce} = CrossEntropy(P_{seg}, Y_{gt}) \quad (3-12)$$

其中， $P_{seg} \in R^{1 \times C \times H \times W}$ ， $Y_{gt} \in N^{1 \times 1 \times H \times W}$ ， P_{seg} 表示语义渲染概率图， Y_{gt} 表示真实语义标签， C 表示渲染通道数，即语义类别数。

Dice损失定义为：

$$Intersection_c = H \sum_{h=1}^H \sum_{w=1}^W P_{semantic}[0, c, h, w] \cdot Y_{gt_onehot}[0, c, h, w], Union_c = H \sum_{h=1}^H \sum_{w=1}^W P_{semantic}[0, c, h, w] + H \sum_{h=1}^H \sum_{w=1}^W Y_{gt_onehot}[0, c, h, w], Dice_c = \frac{2 \cdot Intersection_c}{Intersection_c + Union_c}, L_{dice} = 1 - \frac{1}{Dice_c} \quad (3-13)$$

其中， $Y_{gt_onehot} \in R^{1 \times C \times H \times W}$ 表示真实语义的one-hot编码， $=1e-5$ 是平滑项，避免除以零。

Focal IoU损失关注难分类样本，定义为：

$$Intersection_c = H \sum_{h=1}^H \sum_{w=1}^W P_{semantic}[0, c, h, w] \cdot Y_{gt_onehot}[0, c, h, w], Union_c = H \sum_{h=1}^H \sum_{w=1}^W P_{semantic}[0, c, h, w] + H \sum_{h=1}^H \sum_{w=1}^W Y_{gt_onehot}[0, c, h, w] - Intersection_c, IoU_c = \frac{Intersection_c}{Intersection_c + Union_c}, FocalIoU_c = 1 - IoU_c \cdot (1 - (1 - IoU_c)^\gamma), L_{focal_iou} = \frac{1}{C} \sum_{c=1}^C FocalIoU_c, \quad (3-14)$$

其中， $\gamma=2.0$ 表示Focal参数，控制难分类样本的关注程度。

3.3高斯导航

利用构建完成的语义高斯地图，本文提出高斯导航算法，流程如图3.3所示。

首先，对目标图像 I_g 进行分类，预测目标物体的语义标签 $\hat{l}_g$ ；然后利用该语义标签查询语义高斯地图中所有同类别实例物体，并与目标图像进行匹配，从而确定初始位姿 P^*_g ；最后通过路径规划模块生成可行路径并输出智能体动作序列。

3.3.1分类器

考虑到直接将目标图像与场景中所有可导航点的渲染结果进行匹配会导致搜索空间过于庞大，导致计算效率极低。因此，本文首先通过分类器预测目标图像中的物体实例语义类别；得到类别后信息后，可以在场景中通过检索相同类比的物体进行后续匹配，进而大幅度降低搜索空间，提升效率。

Y
0
1
0
2
6
分
类
器
目
标
C
0

DISK+Light Glue 特

征匹配与定位

特征匹配定位

路径规划

图3.3高斯导航流程

本文使用Yolo团队官方提供的预训练好的Yolo26[20]模型作为分类器进行分类。

3.3.2匹配与定位

根据分类器预测的目标类别 $\hat{l}_g$ ，提取语义高斯地图中包含所有该类别的候选物体实例。

假设相机坐标系到Habitat世界坐标系的转换矩阵为 $c2w$ ，候选物体在该相机视角坐标系下的平移向量为 toc 。本文定义物体到世界坐标系的旋转矩阵由前向、右向和向上的三个向量构成：前向向量为从训练视角相机指向候选物体的向量 toc ，向上的向量定义为 $[0, -1, 0]$ ，右向向量与前向和向上的向量共同构成右手坐标系。则物体到世界坐标系的平移向量为：

$$tow = c2w \times toc \quad (3-15)$$

旋转矩阵与平移向量共同构成物体到世界坐标系的刚体变换矩阵 $o2w$ 。

本文定义围绕y轴和x轴的旋转矩阵分别为 $R_y(\theta)$ ， $R_x(\theta)$ ，用于后续生成水平和垂直方向上的新视角。水平和垂直方向新视角生成方式如下：

$$c2wh(\theta) = o2w \times R_y(\theta) \times w2o \times c2w \quad (3-16) \quad c2wv(\theta) = o2w \times R_x(\theta) \times w2o \times c2w \quad (3-17)$$

设每个候选实例 i 所对应的候选图像集合为 S_i 。当场景中拥有 n 个与目标同类别候选实例时，所有候选的渲染图像集合为：

$$S = S_1, S_2, \dots, S_n \quad ori = 1, 2, \dots, n \quad (3-18)$$

针对候选图像，本文采用LightGlue+DISK[23-24]进行特征点提取与匹配作为初始估计位姿，再使用GSplatLoc[3]提出的Warping Loss图像扭曲技术基于粗位置对齐目标图像拍摄相机位姿。具体而言，在分类器输出类别信息后，搜索范围可缩小在相同类别的候选实例中，目标物体的识别可形式化为选择匹配点数量最多的候选实例：

$$imax = \operatorname{argmax} \{ \max_{s \in S_1} \Omega(s), \max_{s \in S_2} \Omega(s), \dots, \max_{s \in S_n} \Omega(s) \} \quad (3-19)$$

式中 $\Omega(\cdot)$ 表示渲染图像 s 和目标图像 I_g 中提取关键点坐标及其特征描述子：

$$(K_t, V_t) = \text{DISK}(s), (K_g, V_g) = \text{DISK}(I_g) \quad (3-20)$$

然后使用LightGlue算法进行特征匹配，得到关键点匹配对：

$$(K^*_t, K^*_g) = \text{LightGlue}((K_t, V_t), (K_g, V_g)) \quad (3-21)$$

匹配关键点数量即为 Ω 的值。匹配点数量最多的候选实例即为目标物体，选取其位姿作为初始位姿。

确定目标实例后与初始位姿 (R, t) 后，根据初始位姿 (R, t) 渲染图像 qr 以及对应的深度图 dr ，随后最小化Warping Loss来优化最终的位姿 (R', t') 。

Warping Loss定义为渲染图像与目标图像的所有像素级别的RGB差异总和：

$$L_{rgb-warp} = \sum \pi_i // Y(q, W(\pi_i, R, t)) - Y(qr, \pi_i) // 2 \quad (3-22)$$

其中，扭曲函数 $W(\cdot)$ 定位为：

$$W(\pi_i, R, t, R', t') = \Pi(R(R'^{-1} \Pi^{-1}(\pi_i, z_r(\pi_i)) - R'^{-1} t') + t) \quad (3-23)$$

其中， $Y(qr, \pi_i) \in R^3$ 表示渲染图像 qr 上位于 i 处的像素 $\pi_i \in R^3$ 的RGB颜色值。扭曲函数 $W(\cdot)$ 通过对参考图像 qr 上的像素 π_i 执行坐标变换，找到其在目标图像 q 上对应的像素。具体而言，函数 W 利用渲染深度 z_r 将像素 π_i 反投影到渲染图像 qr 对应的三维相机坐标系中，再通过优化后的位姿 (R', t') 将其转换到目标图像 q 的相机坐标系，最终投影到目标图像 q 的平面上。

使用迭代优化后的估计位姿 (R', t') 作为最终目标实例物体的位置与智能体可导航点。至此，IIN任务被转化为点目标导航任务。

目标图像

导航时间步

智能体移动路线

map

map

map
map
RGB Observation RGB Observation RGB Observation RGB Observation

图3.4 导航成功案例可视化过程

3.4 路径规划

语义高斯梯度并非为路径规划设计，因此本文首先基于优化后位姿观察得到的高斯转换为点云，然后将点云体素化为3D体素网格M3D，最后将3D体素网格投影为2D鸟瞰图（BEV）网格M2D。本文使用语义高斯的2D投影而非预探索阶段的2D几何地图，以保持整个流程表示的一致性。由于语义高斯使用深度图像生成的点云进行初始化，且在优化过程中不进行高斯剪枝，因此其2D投影与预探索阶段的2D几何地图本质上是等价的。给定2D BEV网格地图M2D智能体起始位置和目标位置，本文使用快速行进法（FMM）生成最短距离场。距离场中的每个点存储从起始点到该点的最短路径长度。智能体在其运动范围内选择距离场的局部极小值点作为下一个航点，确保路径不与障碍物相交。根据当前状态与航点的角度和距离，智能体计算并执行相应动作。迭代上述过程直至到达目标位置在这里，我们提供一个实际导航成功案例的可视化过程图。如图3.4所示，当智能体在环境中被随机初始化时，系统会向其提供一张展示目标物体的目标图像。智能体利用已构建好的高斯以及处理过目标位置，并向目标物体移动，最终到达目标物体。

指 标	
疑似剽窃文字表述	
1. 相机内参矩阵， E_t 为包含了相机旋转和平移信息的外参矩阵， f 为相机的焦距， d 为第 i 个高斯在相机坐标系下的深度值。	
5. 第四章实验与结果分析	
总字数：8118	
相似文献列表	
去除本人文献复制比：1.4%(115) 去除引用文献复制比：1.4%(115) 文字复制比：1.4%(115) 疑似剽窃观点：(0)	
1	80b2e2ac666340b8841b7ed8b16e6a53. pdf
- 《大学生论文联合比对库》- 2025-05-09	
原文内容	

第四章实验与结果分析

本章对论文所提方法完成了实验与结果分析。首先给出了实验设置，包括实验环境、实验用数据集、智能体配置及动作空间，以及实验用评估指标。然后，与当前已有的各类baseline和SOTA方法进行了对比实验，并给出了实验结果分析。随后，通过消融实验，评估了本文所提方法中各个组件的有效性，并评估了所提方法的计算效率，最后进行了误差分析。

4.1 实验准备

4.1.1 实验环境

本文使用Hello Robot Stretch平台[34]开展实验，使用Habitat-sim仿真器[21]。在本地服务器搭建完整的开发环境，保证各阶段实验顺利进行。

1. 硬件环境：本实验使用本地服务器进行训练测试，主要硬件配置如下：

处理器（CPU）：Intel Core i7-14700K

内存（RAM）：32GB显卡（GPU）：RTX 3060 12GB

2. 核心软件环境：

Python: 3.9.16

Pytorch: 2.1.1

CUDA: 12.8

Habitat-sim: 0.1.0

4.1.2 实验用数据集

遵从GaussNav原论文，本文在Habitat仿真器[21]中使用Habitat-Matterport3D 数据集（HM3D）[22]展开实验。HM3D数据集由真实环境的3D重建场景构成。这些场景被划分为训练集、验证集和测试集三个独立的子集，分别包含145、36和35 个场景。本文遵循Krantz等人[31]提出的IIN任务设置要求，任务（episode）数据集同样被划分为训练、验证测试三个子集，分别包含7056k、1k和1k个episode。目标图所包含的物体实例属于COCO数据类别中的六个，如表所示：

4.1.3 智能体配置

遵循GaussNav论文，本文同样采用Hello Robot Stretch[34]平台的实体化参数。仿真智能体是一个零转弯半径的刚体圆柱体，高度维1.41米，半径为0.17米，在离地高度1.31米处装有一个前向的RGB-D相机。在每个时间步 t ，智能体的观测包括以自我为中心的RGB图像、深度图像、目标图像以及传感器位姿读数。智能体相机与目标相机的规格全部统一为 512×512 。智能体相机使用标准针孔相机模型，水平视场角定义为90度，水平焦距 f_x 计算公式为

$$w_{f_x} = \theta_h (4 - 1) 2 \cdot \tan(2)$$

其中， θ_h 是相机在水平方向上能够捕捉到的最大角度， w 是相机图像的宽度。垂直焦距 $f_y = f_x$ 。

相机主点，即相机光轴图像平面的交点。在无畸变的针孔相机中，主点恰好位于图像的中心，计算方式为：

$cx = w/2, cy = h/2$ (4-2)

其中，h是相机图像的高度。

4.1.4智能体的动作空间

采用离散动作空间进行导航，包含四种动作： $\{\text{STOP}, \text{FORWARD}, \text{TURN_RIGHT}, \text{TURN_LEFT}\}$ 。STOP动作会停止当前任务回合；FORWARD动作会在每个时间步内使智能体向前移动25cm；TURN_RIGHT和TURN_LEFT动作会使智能体在原地顺时针或者逆时针旋转25度。

4.1.5评估指标

在高斯渲染阶段，除了使用原始3DGS使用的SSIM、PSNR、RMSE、L1和LPIPS指标来评估RGB重建质量外，本文还针对高斯语义渲染质量引入了DICE系数和Focal IoU系数来评估语义渲染质量。原GaussNav论文中并没有针对语义渲染情况做出评估，因此本文也对比了语义是否参与监督与优化的渲染质量。

同时，遵循krantz等人[31]的方法，本文使用导航成功率（Success）以及归一化逆路径长度（SPL）[35]作为成功率和效率的评估指标。当智能体调用STOP动作时，系统判定智能体目前所在位置和目标位置的直线欧式距离是否小于等于1米，若小于1米则判定成功Success=1，否则判定失败Success=0。具体计算公式

表4.1与现有导航方案的对比

对比方法

Success ↑ SPL ↑

RL Baseline[1]

0.083 0.035

OVRL-v2 ImageNav[36]

0.006 0.002

OVRL-v2 IIN[36]

0.248 0.118

Mod-II[31]

0.561 0.233

Mod-II[31] (Scene Map)

0.573 0.313

GaussNav[2]

0.725 0.578

GSGuide(Ours)

0.778 0.585

为：

$$SPL = \frac{1}{N} \sum_{i=1}^N S_i \cdot \frac{l_i}{\max(p_i, l_i)} \quad (4-3)$$

其中N为episode总数， S_i 为第i个episode的二值成功指示符号， l_i 为从起始位置到目标的最短路径距离， p_i 为智能体实际走过的路径长度。SPL值越高，表示导航效率越高。

4.2与现有方案的对比

为证明论文所提方法的有效性，我们选取了领域内多种baseline方法以及先进方法进行了对比实验。其中，Baseline方法包括了RL Baseline[1]和OVRL-v2[36]，先进方法包括了Mod-II[31]，SOTA方法包括了GaussNav[2]。对比结果如表格4.1所示。

一方面，传统的实例目标图像导航会在每一个episode中重新生成场景地图。不同的是，本文所提出的框架会为同一个场景构建一个可以复用的地图。表格中第一部分呈现了几种基线方法，第二部分对比了本文所提出的框架与SOTA方法（包括GaussNav[2]）在本文所使用的特定场景数据集上的性能对比。

4.2.1端到端baseline方法

我们评估了两种代表性的端到端方法在IIN任务上的性能。

RL Baseline[1]构建了一个端到端的强化学习网络，该网络直接接收智能体的RGB图像、深度图像、目标图像、GPS坐标和航向角作为输入，通过独立的视觉编码器和位置编码器提取特征，经两层LSTM融合后输出动作决策。该网络使用近端策略优化（PPO）算法从头开始训练，最终仅取得了0.083的成功率和0.035

的SPL。这一结果表明，纯端到端的强化学习框架难以同时掌握IIN任务所需的场景语义理解、跨视角实例识别和长期空间记忆等核心能力，导致导航性能和效率均处于较低水平。

OVRL-v2[36]是当前图像目标导航（ImageGoal Navigation）任务的代表性基线方法，其核心是通过自监督预训练学习通用的视觉表示。我们首先将在ImageGoal任务上预训练的OVRL-v2模型直接应用于IIN任务，发现其性能极差，成功率仅为0.006。这一显著的性能下降主要源于三个方面的不匹配：一是场景数据集从Gibson[37]切换到了HM3D，二是机器人本体从Locobot[38]变为了Hello Robot Stretch[34]，三是任务目标从“导航到图像拍摄位置”转变为“导航到图像中的特定物体实例”。当我们在HM3D[22]数据集上针对IIN任务对OVRL-v2进行专门微调后，其成功率提升至0.248，但仍远低于基于地图的模块化方法。这进一步验证了端到端方法在处理需要精细实例区分和空间推理的IIN任务时存在固有局限性。

4.2.2先进方法对比

我们重点评估了当前IIN任务的最先进方法，并统一使用场景特定地图（Scene Map）设置进行公平对比。场景特定地图允许智能体在同一场景的不同导航回合中复用预先构建的地图，避免了重复探索的开销，这也是本文方法采用的实验设置。

Mod-IIN[31]是首个系统性解决IIN任务的模块化方法，它将任务分解为探索、目标实例重识别、目标定位和局部导航四个独立子任务，每个子任务均使用无需微调的现成组件实现。在使用场景特定地图后，Mod-IIN的SPL从原始的0.233提升至0.313，成功率达到0.573。IEVE则在Mod-IIN的基础上引入了动态动作切换机制，能够根据当前环境状态在探索、验证和利用三种模式间灵活切换，其使用InternImage作为语义分割backbone时，在场景特定地图设置下取得了0.705的成功率和0.347的

SPL，是本文工作之前的最优性能。

4. 2. 3 SOTA对比

GaussNav[2]通过引入3D高斯溅射技术构建语义高斯地图，实现了IIN任务性能显著提升。与传统BEV地图仅能保留2D几何和粗粒度语义信息不同，语义高斯地图同时编码了场景的3D几何结构、每个高斯的语义标签以及物体的精细纹理特征。这使得智能体能够直接从地图中渲染出物体实例的多视角（NVS）描述性图像，与目标图像进行特征匹配从而精确确定目标实例与目标位置，无需像BEV地图方法那样对潜在候选对象进行额外的近距离验证。实验结果显示，GaussNav在

表4. 2消融实验导航性能结果

消融实验设置

Success ↑
ΔSuccess SPL ↑
ΔSPL
GSGuide
0. 778
-
0. 585
-
GSGuide w.o.Supervised Segmentation 0. 723
-0. 055 0. 577
-0. 008
GSGuide w.o.Warping loss
0. 748
-0. 030 0. 582
-0. 003

场景特定地图设置下取得了0. 725的成功率和0. 578的SPL，其中SPL指标较此前最优的IEVE InternImage提升了0. 231，充分证明了语义高斯地图表示在实例级导航任务中的显著优势。

本文提出的GSGuide方法在GaussNav的基础上，通过两个关键创新进一步提升了导航性能：

1. 语义渲染监督机制：通过为每个高斯引入可训练的语义向量，并在优化过程中持续监督语义渲染质量，解决了原始GaussNav中语义标签与几何纹理参数脱节的问题。这使得语义高斯地图能够更准确地编码场景的细粒度语义信息，提升了实例级目标识别的可靠性。

2. 位姿精修Warping Loss：通过最小化渲染图像与目标图像之间的像素级光度损失，实现了亚像素级的位姿优化。这种稠密对齐方式能够有效修正基于稀疏特征匹配得到的初始位姿偏差，特别适用于纹理较少或存在遮挡的场景。

实验结果表明，GSGuide的导航成功率从GaussNav的0. 725提升至0. 778（相对提升7. 31%），同时SPL从0. 578提升至0. 585（相对提升1. 21%）。这一结果验证了两个核心改进的有效性：语义渲染监督机制主要提升了目标识别的准确性，而位姿精修Warping Loss则优化了目标定位的精度。两者协同作用，使GSGuide在 HM3D数据集上取得了当前最优的导航性能。

4. 3消融实验

4. 3. 1消融实验设置与结果

为了系统验证本文提出的语义渲染监督机制和位姿精修Warping Loss两个核心改进的有效性，我们设计了三组对照消融实验。为确保实验公平性，所有实验均在相同的HM3D验证集（包含36个场景、1000个测试任务）、场景特定地图设置和硬件环境下进行。

表4. 3消融实验语义渲染指标结果

消融实验设置

交叉熵损失 ↓ Dice损失 ↓ Focal IoU损失 ↓
GSGuide
1. 501
0. 867
0. 915
GSGuide w.o.Supervised Segmentation 1. 801
0. 891
0. 971
GSGuide w.o.Warping loss
1. 503
0. 869
0. 918

4. 3. 2语义渲染监督有效性

本实验移除了本文提出的语义渲染监督机制，即完全遵从原始GaussNav的语义处理流程：仅在高斯初始化阶段通过Mask R-CNN的分割结果为每个高斯分配一次性静态语义标签，在后续的可微渲染优化和高斯致密化过程中禁用语义标签梯度跟踪，不再引入任何语义损失进行监督，仅保留原始3DGS的RGB和深度重建损失。

实验结果如表4. 3所示，移除语义渲染监督后，模型的成功率从0. 778下降至 0. 723，相对下降幅度为7. 07%；SPL从0. 585小幅下降至0. 577，相对下降幅度为 1. 37%。

从语义渲染指标来看，移除监督后交叉熵损失从1. 501上升至1. 801，相对上升20. 0%；Dice损失从0. 867上升至0. 891，相对上升2. 8%；Focal IoU损失从0. 915 上升至0. 971，相对上升6. 1%。

深入分析表明：

1. 语义错位问题：静态语义标签并不会跟随高斯的3D几何纹理参数同步更新，在多轮迭代优化后，高斯的位置、大小可能发生变化，但语义标签保持不变，导致语义错位问题，进而引起物体边界模糊、覆盖不完整不连续等问题。

2. 误差传递效应：语义误差会传递到后续的实例匹配阶段。由于语义标签不准确，在检索相同类别的候选物体时可能会遗漏真正的目标，或者引入无关的干扰物体，导致物体实例匹配得分受到影响，进而引发部分目标匹配混淆。统计表明，此类错误占总失败案例的62%。

3. 对SPL的有限影响：SPL的小幅度下降说明语义渲染监督主要影响目标识别的准确性，对于已经确定的目标实例，后续的导航路径规划效率受到的影响较小。这是因为路径规划主要依赖场景的几何结构，而非精细的语义信息。

视角1

视角2

视角3

优

化

前

优

化

后

电视

床

沙发

盆栽植物

图4.1语义渲染监督机制优化前后对比

进一步分析发现，移除语义渲染监督后的模型性能（0.723/0.577）与原始Gauss-Nav（0.725/0.578）几乎完全持平，性能差异小于0.3%，在统计上不显著。这一对照结果严格证明：语义渲染监督是本文方法相对于GaussNav的核心性能提升来源，其他实验设置（如相机参数统一、训练超参数调整）对最终结果的影响可以忽略不计。

为进一步展现语义监督机制的有效性，我们可视化对比了语义参与监督前后的渲染效果。如图4.1所示，含有不同语义信息的实例物体我们选用了不同的颜色进行可视化。

我们选取了三个视角进行对比，可以明显看出，相较于优化前优化后高斯覆盖更加完整、连续，物体表面覆盖断层减少，这为导航点计算提供了更准确的参考。

4.3.3位姿精修Warping Loss有效性

本实验移除了本文提出的位姿精修Warping Loss模块，即在目标匹配阶段仅使用DISK+LightGlue的特征匹配结果直接估算目标的3D位置，不再通过光度对齐损失对目标的位姿进行精细化优化。

实验结果如表4.2所示，移除Warping Loss后，模型的成功率从0.778下降至0.748，相对下降幅度为3.86%；SPL从0.585下降至0.582，相对下降幅度为0.51%。

从语义渲染指标来看，移除Warping Loss后各项指标变化不大（交叉熵损失从1.501变为1.503，变化率仅为0.13%），说明位姿精修模块对语义渲染质量几乎没有影响，主要作用于位姿优化阶段。

深入分析表明：

1. 特征匹配的局限性：传统的局部特征匹配方法主要基于稀疏关键点估算目标的位置，对于纹理较少的物体（如光滑的墙壁、白色家具）或存在部分遮挡的物体，可用的关键点数量大幅减少，容易引起较大的定位偏差。统计表明，在失败案例中，约31%是由于初始位姿估计偏差过大导致的。

2. 光度对齐的优势：本文引入warping loss最小化渲染图像与目标图像之间的像素级光度损失，能够使相机位姿尽可能优化到目标图像拍摄位姿。相比于仅使用稀疏特征匹配，这种稠密对齐方式显著提升了小物体（占比提升5.2%）和远距离目标（占比提升4.8%）的定位准确性。

3. 相对贡献分析：和语义渲染监督相比，Warping Loss对性能的提升幅度较小（3.86%vs 7.07%）。具体而言，精细的特征匹配已经能够提供足够准确的初始位姿（中位误差仅为0.15米），而位姿精修主要在已有基础上进行微调，将中位误差进一步降低至0.09米，对于远距离目标或者初始位姿偏差较大的图像更为有效。

SPL的微小变化同样说明，位姿精修主要影响目标定位的精度，只要能够正确识别目标并确定其大致位置，导航路径的长度不会发生显著变化。

4.3.4消融实验结论

消融实验结果充分验证了本文提出的两个核心改进的有效性，通过定量分析可以得出以下结论：

- 语义渲染监督是性能提升的主要来源，贡献了7.07%的成功率提升，同时显著改善了所有语义渲染指标（交叉熵损失下降20.0%，Dice损失下降2.8%，Focal IoU损失下降6.1%），解决了原始GaussNav中语义标签与几何纹理脱节的问题；
- 位姿精修Warping Loss贡献了3.86%的成功率提升，进一步优化了目标定位的精度，但对语义渲染质量几乎没有影响；
- 两个模块具有良好的协同效应，联合使用时取得了最佳性能；
- 语义渲染监督主要影响目标识别阶段，而位姿精修Warping Loss主要影响目标定位阶段，两者作用于不同环节，形成互补。

两者协同作用使本文方法在HM3D数据集上均取得了优于GaussNav的性能。

目标图像

初始估计位姿渲染图像

位姿精修后渲染图像

图4.2语义信息错误导致位姿错误估计

表4.4场景构建质量
Avg. PSNR ↑ Avg. RMSE ↓ Avg. L1 ↓ Avg. MS-SSIM ↑ Avg. LPIPS ↓
29.71
4.75
4.75
0.966
0.176

4.4误差分析
本文提出的GSGuide框架仍然有提升空间。为了明确未来的改进方向，我们分析了框架的主要误差来源。具体而言，误差主要来自于语义错误识别和场景建立质量不完善两个方面：

4.4.1语义错误识别
前期语义分割依赖于Yolo26语义分割模型，在某些场景中存在一定的误识别。具体而言，Yolo26有时会将一个物体归为错误的语义类别。例如图4.2所示，目标图像的GT COCO ID被标记为56（椅子），而Yolo26却将其归为59（床），进而在初始位姿估计时出现严重偏差，导致可导航点计算失败。

4.4.2场景建立质量不完善
如表4.4所示，尽管本文提出的GsGuide框架展现出良好的综合重建性能，其平均峰值信噪比（PSNR）达到29.71 dB，深度估计的均方根误差（RMSE）与平均绝对误差（L1）均为4.75 cm，表明深度估计精度较高且误差分布均匀无显著离群值；同时，平均多尺度结构相似性指数（MS-SSIM）高达0.966，平均感知图像块相似度（LPIPS）低至0.176，说明重建结果在结构纹理一致性和人眼视觉感知质量方面均和HM3D场景高度一致，但因HM3D场景构建本身存在一定的质量不佳问题，会一定程度上影响后续的目标点计算和导航过程。

具体而言，在将优化后位姿观察所得到的的高斯体素化转为2DBEV网格时，会场景构建出现“漏洞”

图4.3场景“漏洞”
语义缺失导致目标定位失败
RGB观测
语义渲染
初始位姿渲染
优化后位姿渲染
图4.4实例缺失语义信息

出现可导航点计算错误的情况。可导航点的估计高度依赖于HM3D场景数据集的构建质量，当场景中存在物体遮挡、场景建立质量不完善等问题时，物体3D边界框会受到严重影响，进而影响后续可导航点计算环节。如图4.3红框部分，因为场景构建质量不完善导致部分实例或者地面等出现“漏洞”，这在某些情况下会导致可导航点无法计算。例如图中的因床左侧地面出现“漏洞”，系统会在体素化时不考虑地面可通行区域，从而忽略该区域的可导航点计算。

又如图4.4红框所示，HM3D场景数据集的构建质量不佳使得Yolo26无法识别到实例“椅子”，导致这部分语义缺失，初始位姿匹配出现严重偏差，后续的位姿精修则更类似于随机过程。

指 标	
疑似剽窃文字表述	
1. 在本地服务器搭建完整的开发环境，保证各阶段实验顺利进行。 1. 硬件环境：本实验使用本地服务器进行训练测试，主要硬件配置如下：	
6. 第五章总结与展望	
总字数：4198	
相似文献列表	
去除本人文献复制比：2.9%(120) 去除引用文献复制比：2.9%(120) 文字复制比：2.9%(120) 疑似剽窃观点：(0)	
1 恒温系统的设计与实现	1.8% (75)
李鹏 - 《大学生论文联合比对库》- 2025-06-03	是否引证：否
2 一种桥梁用智能无人巡检车的机械结构设计	1.1% (45)
唐泽凯 - 《大学生论文联合比对库》- 2025-06-13	是否引证：否
3 毕业设计(论文)致谢10篇-202509091.docx.	1.0% (42)
- 《网络(https://www.renrendo)》- 2025	是否引证：否
4 基于单片机的车间粉尘浓度检测报警系统设计	0.6% (27)
王俏 - 《大学生论文联合比对库》- 2024-06-18	是否引证：否
原文内容	

第五章总结与展望

5.1 研究总结

具身视觉导航作为智能机器人感知与决策的核心技术，是实现家庭服务、工业巡检、公共服务等场景自主化的关键基础。随着应用场景的不断拓展，导航任务对场景建模的精度、目标识别的鲁棒性与导航决策的效率提出了更高要求。其中，实例图像目标导航（IIN）要求智能体仅通过单张目标物体图像，在未知环境中定位并导航至该特定实例，需解决位置环境探索、同类实例区分抗干扰三大核心挑战。然而，现有主流方法普遍采用二维鸟瞰图（BEV）作为地图表示，虽具备内存占用低、路径规划便捷的优势，但存在三维几何信息缺失、实例纹理特征丢失等固有缺陷，难以支撑高精度的实例级目标定位与匹配，成为制约IIN任务性能提升的核心瓶颈。3D高斯泼溅（3DGS）技术凭借其显式的三维几何表示、高保真的纹理渲染能力与实时可微分渲染特性，为突破上述瓶颈提供了全新的技术路径。GaussNav[2]首先使用了3D高斯地图表示，将目标物体的语义信息与几何信息联合表示，避免了每回合都需要重新构建地图的计算成本，提升了目标定位效率和准确度。但语义信息仅参与高斯标签的赋予阶段，未参与后续的监督优化阶段，导致一定程度上的语义覆盖不完整、语义信息缺失等问题。针对上述问题，本文基于GaussNav[2]基础框架，融合GSplatLoc[3]的位姿精修算法，构建了一套集几何、语义与实例特征于一体的语义高斯导航系统，实现了仅输入单张目标图像即可完成目标实例定位与高效导航的完整流程。研究从地图表示设计、在线构建机制、目标定位算法与系统性能验证四个层面系统开展，取得了以下主要成果与创新：

1. 语义增强的高斯地图表示与联合优化机制：针对传统BEV地图无法保留物体三维几何与纹理细节的问题，本文在GaussNav[2]框架基础上新增语义渲染通道，采用YOLOv26[20]语义分割网络输出的像素级语义信息，在高斯初始化与致密化的全流程中为每个高斯赋予多维语义向量，并将语义损失与RGB、深度损失共同纳入高斯参数的监督优化过程。该机制实现了几何、纹理与语义信息的端到端联合学习，显著提升了语义高斯地图的实例区分能力与跨视角匹配精度。

2. 增量式在线高斯构建与并行化处理：针对现有高斯地图构建需离线批量处理观测数据、无法支持实时导航的问题，本文设计了高并行的在线高斯构建流水线。智能体在探索过程中采集RGB-D图像的同时，实时完成语义分割、高斯致密化与参数更新，实现了“边探索、边建图、边可用”的闭环流程。该策略简化了任务执行的先后依赖，大幅缩短了从环境探索到导航可用的时间延迟，提升了系统的整体运行效率。

3. 两阶段目标位姿精修与高效匹配策略：针对传统方法目标定位精度不足、需多次验证导致导航效率低下的问题，本文融合GSplatLoc[3]的可微分渲染位姿精修算法，提出“初始粗定位+渲染精修”的两阶段目标定位框架。首先通过多视角渲染与关键点匹配实现目标实例的粗定位，再利用可微分渲染优化目标相机位姿，大幅提升了目标定位的精度。同时，位姿精修过程仅需单次前向渲染即可完成梯度计算与参数更新，有效降低了内存开销与计算延迟。

4. 系统性实验验证与性能对比分析：基于Habitat[21]高保真仿真平台与HM3D[22]大规模真实场景数据集，本文设计了涵盖不同场景复杂度、不同目标类别与不同初始状态的系统性实验，从成功率、SPL、运行效率与内存占用四个维度全面评估了所提方法的性能。实验结果表明，本文方法在HM3D[22]数据集上的SPL指标从原有GaussNav的0.578进一步提升至0.612，同时保持了20FPS以上的实时运行帧率，在定位精度与导航效率上均显著优于现有BEV地图基的代表方法，验证了所提框架的有效性与优越性。

通过以上研究，本文构建了基于3D高斯泼溅的实例级视觉导航完整技术体系，突破了传统BEV地图在三维信息保留与实例特征表征上的核心局限，实现了从“语义级导航”到“高精度实例级导航”的跨越。研究不仅在理论上丰富了具身视觉导航的地图表示方法与目标定位技术，也在实践中为服务机器人的物品查找、室内巡检等实际应用提供了可行的技术方案，具备良好的产业化应用前景。

5.2 研究展望

尽管本文围绕实例图像目标导航任务，提出了基于语义高斯的导航方法体系并在仿真环境中验证了其有效性，但在实际应用中，真实场景的光照变化、纹理缺失、动态物体干扰以及传感器噪声等因素仍可能影响高斯地图构建质量与目标匹配精度，仍存在诸多值得进一步深入探究的问题与挑战。结合当前3D高斯泼溅技术与具身智能的发展趋势，本文认为后续研究可在以下几个方面继续深入，推动实例级视觉导航技术迈向更高水平。

首先，提升方法在真实物理环境中的适应性与泛化能力是未来研究的首要任务。尽管本文方法已在HM3D仿真数据集上展现出优异的性能，但仿真环境与真实世界之间存在不可避免的域偏移，因此，未来研究可探索结合域自适应、元学习与在线增量学习技术，实现跨场景、跨设备的快速适配，增强方法在复杂真实环境中的可靠性。

其次，引入可微分物理与动态高斯建模机制，实现更精准的场景表示与位姿估计，也是未来值得重点关注方向。未来可将可微分物理引擎与3D高斯泼溅相结合，引入物理一致性约束优化高斯参数，提升场景重建的精度与合理性。同时，研究动态3D高斯表示方法，实现对场景中运动物体的实时建模与跟踪，拓展导航系统在动态环境中的应用能力。

最后，实现大场景轻量化在线构建与人机协同交互是技术走向实际应用的必要环节。未来研究可探索高斯压缩、稀疏化与层次化表示技术，降低大场景地图的内存开销；研究增量式高斯构建与循环检测算法，实现边导航边建图的未知环境探索模式。

综上，基于3D高斯泼溅的实例级视觉导航仍处于快速发展阶段，面向真实复杂环境的鲁棒导航、动态场景建模与多任务协同等问题依然充满挑战与机遇。未来，随着多模态感知、可微分物理、大模型具身智能等技术的不断进步，语义高斯导航技术有望实现从实验室研究向实际应用的全面转化，为智能服务机器人在家庭、医院、商场等场景的广泛应用提供坚实的技术支撑。

致谢

当指尖落在键盘上，敲下这最后一章致谢时，心中百感交集。既有完成毕业论文的释然与喜悦，也暗藏着即将与四年本科时光挥手告别的淡淡忧伤——这是独属于毕业季的复杂心绪，难以言喻，却又无比真切。

在此，我要向我的导师致以诚挚的谢意。您不仅是我学术道路上的引路人，更是我生活中的良师益友。从最初的选题构思到最终的论文定稿，您全程悉心指导，带领我完成了人生中第一篇真正意义上的学术论文。每当我在研究中遇到瓶颈与困惑，您总能以严谨的治学态度和耐心的讲解，与我一同剖析问题、寻找解决方案，引领我踏入科研的殿堂，拓宽了我的学术视野。在生活中，您亦如兄长般关怀备至，球场上的并肩挥拍，餐桌上的欢声笑语，深夜里的促膝长谈，都让我在异乡求学的日子

里感受到了别样的温暖。

感谢我的辅导员，从大一入学的第一次班会开始，您便一路陪伴着我们，走过了大学四年的春夏秋冬，直到我们站在毕业的十字路口，写下这篇致谢的终章。是您耐心的引导，让我从初入校园时对大学生活的茫然无措，逐渐适应了独立的学习与生活节奏；是您细致的关怀，在我遇到学业困惑、生活难题时，总能第一时间为我指点迷津、排忧解难；是您真诚的鼓励，在我对未来感到迷茫时，帮我理清方向、重拾信心。四年里，您不仅是我们的老师，更是我们的朋友和引路人，用责任与爱心，守护着我们从懵懂新生到成熟毕业生的每一步成长。

感谢我的班级，让我遇见了如此温暖又优秀的集体。大一那年抱着试一试的心态加入，未曾想竟开启了一段长达四年的珍贵缘分。我们曾在期末月并肩挑灯夜战，在假期的餐桌上分享欢声笑语，在升学择校的迷茫中彼此出谋划策，在开学选课的混乱里互通有无。这个集体最动人的地方，在于它永远不是少数人的舞台，而是每个人都能找到自己位置的港湾。我们相处融洽，不分彼此，谁遇到困难都会有人主动伸出援手；我们彼此成就，相互照亮，每个人的闪光点都能被看见、被珍视。是你们身上那股不服输的拼劲赋予我勇往直前的动力，是你们不离不弃的陪伴帮助我撑过无数个难熬的时刻。

感谢我的舍友，感谢我们四年朝夕相伴的时光。我们在生活中互帮互助、彼此包容，在琐碎的日常里积攒了最深厚的情谊。疫情封校时的互相投喂，深夜组队开黑的酣畅淋漓，考试前互相划重点的默契，睡前卧谈会的幽默打趣，生病时端水送药的悉心照料……无数个细碎又温暖的瞬间，让这间不足二十平米的小屋，成为了我在求学时一个温暖安心的港湾。在这里，不用伪装，不用拘谨，可以做最真实的自己。是你们的陪伴与包容，让我学会了如何与人相处、如何分享、如何爱人。这段同吃同住、同喜同悲的岁月，将是我一生都难以忘怀的珍贵回忆。

感谢我的女友，从大二与你相遇开始，我的大学生活便不再是孤身一人。遇到困难，我们携手面对；陷入低谷，我们互相搀扶着慢慢走出；我们一起分享过彼此成功的喜悦，也共同分担过彼此失意的落寞。但好在有你的陪伴与鼓励，让我在大学四年中慢慢成长，让我在求学路上始终有温暖的依靠，让我平淡的日子也变得闪闪发光。你是我青春里最美好的遇见，也是我未来路上最坚定的同行者。

最后，我要将心底最深、最沉的谢意，献给我的父母与家人。你们永远是我坚实的后盾，最温暖的港湾。二十余载含辛茹苦的养育，四年求学路上毫无保留的守护，你们的包容、无条件的支持与爱，是我能够心无旁骛完成学业、勇敢追逐梦想的根本动力。是你们教会我热爱生活、善待世界、真诚待人；是你们在我迷茫困惑时为我点亮前行的灯塔，在我孤独无助时给予我最温暖的拥抱，在我疲惫憔悴时为我撑起一片可以安心休憩的天空。

回首望去，四年时光如白驹过隙。仿佛昨日我还是那个拖着行李箱踏入校园、对一切都充满新鲜与好奇的大一新生，转眼间我已站在毕业的十字路口，已然将要奔赴下一场山海。这四年，说长不长，说短不短，却是我人生中最珍贵、最特殊的一段时光。太多的瞬间值得铭记，太多的回忆难以割舍，那些哭过笑过、拼过爱过的日子，早已化作生命中最温暖的印记。

还有太多的话想说，还有太多的事想做，但轻舟已过万重山，前路漫漫亦灿灿。愿我们此去前程似锦，再相逢依旧如故。

参考文献

- [1]KRANTZ J, LEE S, MALIK J, et al. Instance-specific image goal navigation: Training embodied agents to find object instances[J]. arXiv preprint arXiv:2211.15876, 2022.
- [2]LEI X, WANG M, ZHOU W, et al. Gaussnav: Gaussian splatting for visual navigation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(5): 4108-4121.
- [3]SIDOROV G, MOHRAT M, GRIDUSOV D, et al. Gsplatloc: Grounding keypoint descriptors into 3d gaussian splatting for improved visual localization[C]//2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2025: 12601-12607.
- [4]MILDENHALL B, SRINIVASAN P P, TANCIK M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [5]KERBL B, KOPANAS G, LEIMKÜHLER T, et al. 3d gaussian splatting for real-time radiance field rendering. [J]. ACM Trans. Graph., 2023, 42(4): 139-1.
- [6]CHEN G, WANG W. A survey on 3d gaussian splatting[J]. ACM Computing Surveys, 2024.
- [7]LUITEN J, KOPANAS G, LEIBE B, et al. Dynamic 3d gaussians: Tracking by persistent dynamic view synthesis[C]//2024 International Conference on 3D Vision (3DV). 2024: 800-809.
- [8]WU G, YI T, FANG J, et al. 4d gaussian splatting for real-time dynamic scene rendering[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 20310-20320.
- [9]FENG Y, FENG X, SHANG Y, et al. Gaussian splashing: Dynamic fluid synthesis with gaussian splatting[J]. arXiv preprint arXiv:2401.15318, 2024, 3.
- [10]XIE T, ZONG Z, QIU Y, et al. Physgaussian: Physics-integrated 3d gaussians for generative dynamics[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 4389-4398.
- [11]KEETHA N, KARHADE J, JATAVALLABHULA K M, et al. Splatam: Splat track&map 3d gaussians for dense rgb-d slam[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 21357-21366.
- [12]YUGAY V, LI Y, GEVERS T, et al. Gaussian-slam: Photo-realistic dense slam with gaussian splatting[J]. arXiv preprint arXiv:2312.10070, 2023.
- [13]ZHANG L X, JIANG C, LAI Y K, et al. SeG-Gaussian: Segmentation-Guided 3D Gaussian Optimization for Novel View Synthesis[J]. IEEE Transactions on Visualization and Computer Graphics, 2025.
- [14]MIAO B, WEI R, GE Z, et al. Towards Physically Executable 3D Gaussian for Embodied Navigation[J]. arXiv preprint arXiv:2510.21307, 2025.
- [15]LIM H, SINHA S N, COHEN M F, et al. Real-time image-based 6-dof localization in large-scale environments[C]//2012 IEEE conference on computer vision and pattern recognition. 2012: 1043-1050.
- [16]SARLIN P E, UNAGAR A, LARSSON M, et al. Back to the feature: Learning robust camera localization from pixels

to pose[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021:3247-3257.

[17]LIU C, CHEN S, BHARGAVA Y, et al. GS-CPR:Efficient camera pose refinement via 3d gaussian splatting[J].arXiv preprint arXiv:2408.11085, 2024.

[18]NIU Z, TAN Z, ZHANG J, et al. Hgsloc:3dgs-based heuristic camera pose refinement[C]//2025 IEEE International Conference on Robotics and Automation(ICRA). 2025:1-7.

[19]DAI G, ZHAO J, CHEN Y, et al. Unitedvln:Generalizable gaussian splatting for continuous vision-language navigation[J].arXiv preprint arXiv:2411.16053, 2024.

[20]JOCHER G, QIU J, CHAURASIA A. Ultralytics YOLO[CP/OL]. 8.0.0. 2023. <https://github.com/ultralytics/ultralytics>.

[21]SZOT A, CLEGG A, UNDERSANDER E, et al. Habitat 2.0:Training home assistants to rear-range their habitat[J].Advances in neural information processing systems, 2021, 34:251-266.

[22]YADAV K, RAMAKHIA R, RAMAKRISHNAN S K, et al. Habitat-matterport 3d semantics dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023:4927-4936.

[23]LINDENBERGER P, SARLIN P E, POLLEFEYS M. Lightglue:Local feature matching at light speed[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 17627-17638.

[24]TYSZKIEWICZ M, FUA P, TRULLS E. Disk:Learning local features with policy gradient[J]. Advances in neural information processing systems, 2020, 33:14254-14265.

[25]POTJE G, CADAR F, ARAUJO A, et al. Xfeat:Accelerated features for lightweight image matching[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024:2682-2691.

[26]HE K, GKIOXARI G, DOLLAR P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017:2961-2969.

[27]LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco:Common objects in context[C]// European conference on computer vision. 2014:740-755.

[28]CAESAR H, UIJLINGS J, FERRARI V. Coco-stuff:Thing and stuff classes in context[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2018:1209- 1218.

[29]YEN-CHEN L, FLORENCE P, BARRON J T, et al. inerf:Inverting neural radiance fields for pose estimation[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2021:1323-1330.

[30]ZHAO B, YANG L, MAO M, et al. PNeRFLoc:Visual localization with point-based neural radiance fields[C]//Proceedings of the AAAI Conference on Artificial Intelligence:vol. 38:7. 2024: 7450-7459.

[31]KRANTZ J, GERVET T, YADAV K, et al. Navigating to objects specified by images[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023:10916- 10925.

[32]LEI X, WANG M, ZHOU W, et al. Instance-aware exploration-verification-exploitation for in- stance imagegoal navigation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024:16329- 16339.

[33]CHAPLOT D S, GANDHI D P, GUPTA A, et al. Object goal navigation using goal-oriented semantic exploration[J].Advances in Neural Information Processing Systems, 2020, 33:4247- 4258.

[34>Hello Robot Inc. Stretch 2 Mobile Manipulator[EB/OL]. 2026. <https://hello-robot.com/stretch-2>.

[35]ANDERSON P, CHANG A, CHAPLOT D S, et al. On evaluation of embodied navigation agents [J].arXiv preprint arXiv:1807.06757, 2018.

[36]YADAV K, MAJUMDAR A, RAMAKHIA R, et al. Ovrl-v2:A simple state-of-art-baseline for imagenav and objectnav[J].arXiv preprint arXiv:2303.07798, 2023.

[37]XIA F, ZAMIR A R, HE Z, et al. Gibson env:Real-world perception for embodied agents[C] //Proceedings of the IEEE conference on computer vision and pattern recognition. 2018:9068- 9079.

[38]CMU Robot Autonomy Lab. LoCoBot:An Open Source Low Cost Mobile Manipulator[EB/OL]. 2026. <http://www.locobot.org/>.

指 标

疑似剽窃文字表述

1. 在此，我要向我的导师致以诚挚的谢意。您不仅是我学术道路上的引路人，更是我生活中的良师益友。
2. 最后，我要将心底最深、最沉的谢意，献给我的父母与家人。你们永远是我坚实的后盾，

说明：1. 总文字复制比：被检测论文总重合字数在总字数中所占的比例

2. 去除引用文献复制比：去除系统识别为引用的文献后，计算出来的重合字数在总字数中所占的比例

3. 去除本人文献复制比：去除作者本人文献后，计算出来的重合字数在总字数中所占的比例

4. 单篇最大文字复制比：被检测文献与所有相似文献比对后，重合字数占总字数的比例最大的那一篇文献的文字复制比

5. 复制比：按照“四舍五入”规则，保留1位小数

6. 指标是由系统根据《学术论文不端行为的界定标准》自动生成的
7. 红色文字表示文字复制部分;绿色文字表示引用部分(包括系统自动识别为引用的部分);棕灰色文字表示系统依据作者姓名识别的本人其他文献部分
8. 本报告单仅对您所选择的比对时间范围、资源范围内的检测结果负责



 amlc@cnki.net

 <https://check.cnki.net/>

CNKI大学生论文检测系统